

Introdução à Ciência dos Dados

Aula 01 – Introdução
Prof. Fabrício Aguiar Silva

O que é Ciência dos Dados?

Inteligência Artificial / Artificial Intelligence

Aprendizado de Máquina / Machine Learning

Aprendizado Profundo / Deep Learning

Mineração de Dados / Data Mining

Grandes Dados / Big Data

Ciência dos Dados / Data Science

O que é Ciência dos Dados?


- Inteligência Artificial
 - Restrita x Geral



O que é Ciência dos Dados?



- Aprendizado de Máquina
 - Algoritmos que usam dados históricos para ajudar nas tomadas de decisões

*“Machine Learning é o que vem antes de Machine Killing”.
Jovem Nerd*



O que é Ciência dos Dados?

- Aprendizado Profundo
 - Rede neural com múltiplas camadas




O que é Ciência dos Dados?

- IA x Aprendizado de Máquina x Aprendizado Profundo

ARTIFICIAL INTELLIGENCE

Engineering of making Intelligent Machines and Programs




MACHINE LEARNING

Ability to learn without being explicitly programmed



DEEP LEARNING


Learning based on Deep Neural Network



1950's 1960's 1970's 1980's 1990's 2000's 2006's 2010's 2012's 2017's

O que é Ciência dos Dados?


- Mineração de Dados
 - Extração de padrões em dados, para obter conhecimento



O que é Ciência dos Dados?

- Big Data
 - Volume
 - Velocidade
 - Variedade
 - Veracidade

*Em 2020, o mundo irá
gerar 50x mais dados que
em 2011.*



40 ZETTABYTES

[43 TRILLION GIGABYTES]
of data will be created by 2020, an increase of 300 times from 2005

6 BILLION PEOPLE
have cell phones




WORLD POPULATION: 7 BILLION

Volume SCALE OF DATA



It's estimated that
2.5 QUINTILLION BYTES

[2.3 TRILLION GIGABYTES]
of data are created each day



Most companies in the U.S. have at least
100 TERABYTES
[100,000 GIGABYTES]
of data stored

The FOUR V's of Big Data

From traffic patterns and music downloads to web history and medical records, data is recorded, stored, and analyzed to enable the technology and services that the world relies on every day. But what exactly is big data, and how can these massive amounts of data be used?

As a leader in the sector, IBM data scientists break big data into four dimensions: **Volume, Velocity, Variety and Veracity**

Depending on the industry and organization, big data encompasses information from multiple internal and external sources such as transactions, social media, enterprise content, sensors and mobile devices. Companies can leverage data to adapt their products and services to better meet customer needs, optimize operations and infrastructure, and find new sources of revenue.

By 2015
4.4 MILLION IT JOBS
will be created globally to support big data, with 1.9 million in the United States



As of 2011, the global size of data in healthcare was estimated to be

150 EXABYTES
[161 BILLION GIGABYTES]



**30 BILLION
PIECES OF CONTENT**
are shared on Facebook every month



Variety DIFFERENT FORMS OF DATA



By 2014, it's anticipated there will be
**420 MILLION
WEARABLE, WIRELESS
HEALTH MONITORS**

**4 BILLION+
HOURS OF VIDEO**
are watched on YouTube each month



400 MILLION TWEETS
are sent per day by about 200 million monthly active users



The New York Stock Exchange captures

**1 TB OF TRADE
INFORMATION**
during each trading session



Velocity ANALYSIS OF STREAMING DATA

By 2016, it is projected there will be

**18.9 BILLION
NETWORK
CONNECTIONS**

— almost 2.5 connections per person on earth



Modern cars have close to
100 SENSORS
that monitor items such as fuel level and tire pressure



**1 IN 3 BUSINESS
LEADERS**

don't trust the information they use to make decisions



in one survey were unsure of how much of their data was inaccurate


Veracity UNCERTAINTY OF DATA

Poor data quality costs the US economy around
\$3.1 TRILLION A YEAR



O que é Ciência dos Dados?


O que é Ciência dos Dados?



Ciência da
Computação


Programação
Estruturas de dados
Banco de Dados
Sistemas distribuídos
Command line (bash)
Machine Learning
Regex

O que é Ciência dos Dados?



O que é Ciência dos Dados?

Objetivos
Métodos
Restrições
Requisitos de
Implantação




Probabilidade
Inferência
Teste de hipótese
Regressão
Análise descritiva
Análise preditiva
Séries temporais

Programação
Estruturas de dados
Banco de Dados
Sistemas distribuídos
Command line (bash)
Machine Learning
Regex

O que é Ciência dos Dados?

Objetivos
Métodos
Restrições
Requisitos de
Implantação



Probabilidade
Inferência
Teste de hipótese
Regressão
Análise descritiva
Análise preditiva
Séries temporais

Programação
Estruturas de dados
Banco de Dados
Sistemas distribuídos
Command line (bash)
Machine Learning
Regex

O que é Ciência dos Dados?


- Ciência dos Dados
 - Área multidisciplinar

Envolve coleta, limpeza, preparação e análise de dados com o objetivo de extrair informações úteis ao negócio.

Também é importante saber apresentar os resultados para a área de negócios.

Um cientista de dados precisa conhecer de programação, matemática, estatística e do negócio em si.

Um cientista de dados é melhor em estatística do que qualquer outro programador, e melhor em programação do que qualquer outro estatístico.” Josh Wills, Director of Data Engineering at Slack



O que é Ciência dos Dados?


- Ciência dos Dados
 - Área multidisciplinar




O que é Ciência dos Dados?

- Ciência dos Dados
 - Aplicação de algoritmos, estatística e conhecimento do negócio para extrair significado útil dos dados, visando trazer benefícios para os interessados
 - Foco nos objetivos do negócio, visando responder perguntas relevantes


O que é Ciência dos Dados?




O que é Ciência dos Dados?




O que é Ciência dos Dados?




O que é Ciência dos Dados?



O que é Ciência dos Dados?



O que é Ciência dos Dados?



O que é Ciência dos Dados?

- Conhecimentos importantes
 - Estatística
 - Banco de Dados (Relacionais e Não-Relacionais)
 - Sistemas Distribuídos
 - Processamento Paralelo
 - Computação na Nuvem
 - Machine Learning
 - Processamento de Linguagem Natural
 - Escrita e apresentação

O professor

- Experiência de mercado e acadêmica
- Desde 2006 trabalha em projetos acadêmicos e para empresas em assuntos relacionados à Ciência de Dados

Alguns projetos

- Sagacity
- SentWeet
- StockMood
- OpenCog
- Mobilidade Veicular (Doutorado)
- Outros...

Alguns projetos

- **Sagacity**

- Máquina de busca com re-alimentação
- Usuário classifica manualmente as indicações retornadas pelo Google, e essa classificação é utilizada para alterar o ranking das páginas
- Tecnologias: Recuperação de Informação, Machine Learning (Naive Bayes), Java/Lucene

Alguns projetos

- **SentWeet**

- Análise de sentimento de Tweets
- Classificação de postagens referentes a marcas em Positivas, Negativas ou Neutras
- Cálculo da tendência em relação à visão das marcas pelos clientes
- Tecnologias: Big Data, Machine Learning (SVM), Processamento de Linguagem Natural, Ruby on Rails

Alguns projetos

- **StockMood**

- Análise de sentimento de feed de notícias sobre empresas negociadas na bolsa de valores de NY
- Classificação das notícias automaticamente
- Análise da tendência dos preços das ações com base nas notícias
- Projeto selecionado pelo TechCrunch 50
- Tecnologias: Big Data, Processamento de Linguagem Natural, Java/Weka, Análise de Sentimento

Alguns projetos

- **OpenCog**

- Avatar de mundos virtuais inteligentes
- Comandos de texto elaborados para um avatar de cachorro
 - “Pegue a bola vermelha/azul”, “Pegue o osso”, etc
- Tecnologias: Hipergrafos, Processamento de Linguagem Natural, C++

Alguns projetos

- **Mobilidade Veicular (Doutorado)**
 - Análise de grandes volumes de dados de mobilidade veicular
 - Entendimento de comportamento urbano para proposta de algoritmos de entrega de conteúdo
 - Tecnologias: Estatística, Inferência de Distribuição (MLE), R, Data Mining, Processamento Paralelo

Alguns projetos

- **Outros**

- Análise de grandes volumes de dados móveis
- Elaboração de arquitetura para armazenamento e processamento de Big Data
- Descoberta de conhecimento para diferentes setores do negócio
- Tecnologias: Estatística, Processamento Paralelo (Spark), R, Python/Pandas, Machine Learning, Data Mining

Sugestão de Material

- [Why becoming a data scientist is NOT actually easier than you think](#)
- [Artificial Intelligence vs. Machine Learning: What's the Difference?](#)
- [Introdução à Ciência dos Dados \(Escola de Verão UFMG 2015 - Parte 1 de 4\)](#)
- [Tutorial Python para iniciantes](#)
- [Introdução a Python](#)

Dúvidas

Perguntas ou comentários?