

Introdução à Ciência dos Dados

Aula 02 – Estatística Descritiva

Sumário

- Dados x Conhecimento
- Estatísticas de tendência central
- Estatísticas de distribuição
- Estatísticas de dispersão

Dados

- O que pode-se afirmar sobre esses **dados puros/brutos**?

Mateus, 45
João, 37
Maria, 80
Ana, 67
Paulo, 51
Marcos, 77
José, 23
Carina, 56

Informação

- O que pode-se afirmar sobre essa **informação**?

Dados referentes à nota final de cálculo I, do professor Reginaldo:

#nome, nota
Mateus, 45
João, 37
Maria, 80
Ana, 37
Paulo, 51
Marcos, 17
José, 23
Carina, 56

Conhecimento

- O que pode-se afirmar sobre esse **conhecimento?**

Dados referentes à nota final de cálculo I, do professor Reginaldo:

- Média: 43,25

#nome, nota
Mateus, 45
João, 37
Maria, 80
Ana, 37
Paulo, 51
Marcos, 17
José, 23
Carina, 56

Conhecimento

- O que pode-se afirmar sobre esse **conhecimento**?

Dados referentes à nota final de cálculo I, do professor Reginaldo:

- Média: 43,25

1. A aluna com a melhor nota (Maria) obteve uma nota aproximadamente 85% maior que a nota média.

2. A média dos alunos do professor Reginaldo é 50% abaixo da média do outro professor de cálculo.

#nome, nota
Mateus, 45
João, 37
Maria, 80
Ana, 37
Paulo, 51
Marcos, 17
José, 23
Carina, 56

Qual o objetivo em se aprender estatística?

- Sintetizar enormes quantidades de dados
 - E bota enormes nisso....
- Tomar decisões melhores
 - Pessoais e profissionais
- Avaliar criticamente notícias e estudos publicados
 - Não aceitar de cara o que é recebido via redes sociais
- Reconhecer padrões em diferentes setores de atuação
 - Comportamento de clientes, fraudes, *churning*, mobilidade urbana, riscos, etc

Qual o objetivo em se aprender estatística?

- “Aveia ajuda a baixar as taxas de colesterol em 35% dos casos”, diz estudo independente patrocinado por uma indústria de cereais
- “Tomar café diariamente ajuda a melhorar a memória em 22%”, diz pesquisa de uma associação de produtores de café
- “Tomar café diariamente aumenta em 67% as chances de ter gastrite”, diz pesquisa de uma associação de produtores de leite

Estatística Descritiva

- Qual o melhor jogador de Beisebol de todos os tempos?

Estatística Descritiva

- Qual o melhor jogador de Beisebol de todos os tempos?



Derek Jeter:

Jogou 17 temporadas na liga principal
9.868 rebatidas

Estatística Descritiva

- Qual o melhor jogador de Beisebol de todos os tempos?



Derek Jeter:

Jogou 17 temporadas na liga principal
9.868 rebatidas

Taxa de rebatidas na carreira: 0,313

Estatística Descritiva

- Qual o melhor jogador de Beisebol de todos os tempos?



Derek Jeter:

Jogou 17 temporadas na liga principal
9.868 rebatidas

Taxa de rebatidas na carreira: 0,313

Sumarização fácil de entender e simples,
porém limitada.

Existem várias outras estatísticas no
Beisebol...

Estatística Descritiva

- O que está acontecendo com a saúde econômica da classe média?

Estatística Descritiva

- O que está acontecendo com a saúde econômica da classe média?

330 milhões de americanos. Uma tabela com uma linha por indivíduo e a sua renda anual resolveria o problema.


Estatística Descritiva

- O que está acontecendo com a saúde econômica da classe média?

PIB PER CAPITA

■ Brasil ■ Mundo ■ Europa Ocidental ■ EUA

(em US\$ de 1990)



330 milhões de americanos. Uma tabela com uma linha por indivíduo e a sua renda anual resolveria o problema.

PIB per Capita nos EUA foi de US\$20.000 em 1980 para US\$30.000 em 2010.


Estatística Descritiva

- O que está acontecendo com a saúde econômica da classe média?

PIB PER CAPITA

■ Brasil ■ Mundo ■ Europa Ocidental ■ EUA

(em US\$ de 1990)



Fonte: <http://www.antp.org.br>

330 milhões de americanos. Uma tabela com uma linha por indivíduo e a sua renda anual resolveria o problema.

PIB per Capita nos EUA foi de US\$20.000 em 1980 para US\$30.000 em 2010.

Sumarização fácil de entender e simples, porém limitada: um aumento na renda/capita não indica uma distribuição dessa renda para a classe média.

Existem outras estatísticas para isso....

Estatística Descritiva

- Cálculos para reduzir um complexo arranjo de dados a um punhado de números que descrevam esses dados
- Nos dão um resumo manejável e significativo dos fenômenos descritos nos dados
- Base para a Inferência Estatística
- Porém, requer cuidado na sua elaboração e interpretação

Estatística Descritiva

- Suponha que você trabalhe como analista de dados de um fabricante de impressoras. Seu chefe chega em uma 6a-feira à tarde com os seguintes dados para serem analisados:
 1. Solicitação de uso de garantia para cada uma das 57.334 impressoras vendidas na sua empresa, contendo o número de problemas de qualidade encontrados durante o período de garantia.
 2. A mesma informação para cada uma das 994.773 impressoras vendidas pelo principal concorrente.
- Seu chefe quer saber como as impressoras da sua empresa se comparam com a concorrência em termos de qualidade

Estatística Descritiva

- Por onde começar?

Estatística Descritiva

- Por onde começar?
 - Encontrar uma “medida do meio” ou “tendência central”

Estatística Descritiva

- Por onde começar?
 - Encontrar uma “medida do meio” ou “tendência central”
 - A medida mais básica do “meio” de uma distribuição é a **média**
 - Solução: calcular o número médio de problemas de qualidade por impressora vendida
 - Soma de todos os problemas encontrados dividido pelo total de impressoras vendidas
 - Concorrente: 2,8
 - Sua empresa: 9,1

Estatística Descritiva

- Por onde começar?
 - Encontrar uma “medida do meio” ou “tendência central”
 - A medida mais básica do “meio” de uma distribuição é a **média**
 - Solução: calcular o número médio de problemas de qualidade por impressora vendida
 - Soma de todos os problemas encontrados dividido pelo total de impressoras vendidas
 - Concorrente: 2,8
 - Sua empresa: 9,1



Estatística Descritiva

- Por onde começar?

Encontrar uma “medida de meio” ou “tendência central”

Não com tanta pressa.....

de impressoras vendidas

- Concorrente: 2,8
- Sua empresa: 9,1



Estatística Descritiva

- A **média** é uma estatística descritiva que deve ser usada com cuidado



A renda **média** das pessoas nesse bar é de US\$10 milhões por ano

Estatística Descritiva

- A **média** é uma estatística descritiva que deve ser usada com cuidado



A renda **média** das pessoas nesse bar é de US\$10 milhões por ano

Estatística Descritiva

- A **média** é uma estatística descritiva que deve ser usada com cuidado



A renda **média** das pessoas nesse bar é de US\$10 milhões por ano

Estatística Descritiva

- A **média** é uma estatística descritiva que deve ser usada com cuidado
- A **média** é sensível a valores extremos (*outliers*), que são observações que se situam mais longe do centro

E agora? O que fazer?

Estatística Descritiva

- Outra estatística existente também sinaliza o “meio” de uma distribuição, mas de maneira diferente:
 - **Mediana:** ponto que divide a distribuição ao meio, significando que metade das observações está acima da mediana, e metade abaixo.

Estatística Descritiva

- A **mediana** é uma estatística descritiva que divide a distribuição ao meio



A **mediana** da renda das pessoas nesse bar é de US\$35 mil por ano. Se o Bill Gates for embora, a **mediana** continuará sendo US\$35 mil.


Estatística Descritiva

- Outra estatística existente também sinaliza o “meio” de uma distribuição, mas de maneira diferente:
 - **Mediana:** ponto que divide a distribuição ao meio, significando que metade das observações está acima da mediana, e metade abaixo.
 - A mediana não é sensível a pontos extremos (*outliers*)
 - Para distribuições sem valores extremos, a **mediana** e a **média** serão similares

Estatística Descritiva

- Voltemos agora ao problema das impressoras

Distribuição de frequência de reclamações de qualidade para as impressoras da concorrente




Concorrente: Média=2,8 ; **Mediana=2.**

Estatística Descritiva

- Voltemos agora ao problema das impressoras

Distribuição de frequência de reclamações de qualidade da sua companhia



Sua empresa: Média=9,1 ; **Mediana=1.**


Estatística Descritiva

- Voltemos agora ao problema das impressoras

Sua empresa não tem um problema de qualidade uniforme: um pequeno número de reclamações tem uma quantidade enorme de problemas de qualidade.

Esses valores extremos inflam a média, mas não a mediana.

A boa notícia é que, para a sua empresa melhorar, tem que identificar o que está causando esses casos extremos.....



Sua empresa: Média=9,1 ; **Mediana=1.**

Estatística Descritiva

- Tanto a média quanto a mediana são fáceis de se calcular
- A dificuldade está em identificar qual a medida do “meio” é a mais acurada para a sua situação

Estatística Descritiva

- Exemplo: George W. Bush fez um ajuste tributário e disse que “92 milhões de americanos iriam ter uma redução **média** de US\$1.083 nos impostos”
 - Poucos americanos com renda muito alta teriam uma redução muito maior (valores extremos)
 - Mediana: US\$100

Estatística Descritiva

- Exemplo: Um tratamento para uma doença fatal pode dar uma sobrevida **mediana** de 2 semanas
 - Muitos pacientes não reagem e morrem, mas um bom número (30% ou 40%) fica inteiramente curado
 - Esses pontos extremos significativos não afetam a mediana, mas são muito relevantes para a decisão de se fazer o tratamento ou não

Estatística Descritiva


- Um bom estudo estatístico deve apresentar a média e mediana (e de preferência outras estatísticas)
- Se somente uma é apresentada, pode ser por similaridade, brevidade, ou malícia

Estatística Descritiva

- Podemos dividir a distribuição em partes diferentes da metade
 - Quartis: 4 partes de 25%
 - Decis: 10 partes de 10%
 - Percentis: 100 partes de 1%
 - Ex. Se sua renda está no último quartil (75%), você ganha mais que 75% da população
 - Ex. Se sua renda está no último percentil (99%), você ganha mais que 99% da população
 - Ex. Se sua renda está no primeiro decil (10%), você ganha menos que 90% da população
- Descreve onde uma observação particular se encontra em comparação com todo o restante

Estatística Descritiva

- Podemos dividir a distribuição em partes diferentes da metade



Estatística Descritiva

- Valores absolutos x relativos
 - Aluno do 3º ano da CEDAF tirou 400 no ENEM

Estatística Descritiva

- Valores absolutos x relativos
 - Aluno do 3º ano da CEDAF tirou 400 no ENEM
 - Esse valor absoluto não significa muito
 - Com essa nota de 400 ele ficou no 83º percentil, significando que ele foi melhor que 83% dos alunos
 - Essa informação relativa aos outros alunos é significativa
 - Não importa se a prova foi fácil ou difícil, pois foi fácil ou difícil para todos
- Ou seja, em muitas análises, é mais importante saber o resultado relativo do que o absoluto

Estatística Descritiva

- Outras estatísticas descritivas
 - **média ponderada:** pesos diferentes para termos diferentes
 - **moda:** valor com maior frequência na distribuição
 - **mínimo:** menor valor da distribuição
 - **máximo:** maior valor da distribuição

Estatística Descritiva

- **Desvio padrão:** medida de como os dados se dispersam em relação à média
 - Mede o quanto as observações estão espalhadas
- Média do peso de 250 passageiros em um avião para BH: 70KG
- Média do peso de 250 maratonistas da volta da Pampulha: 70KG
- Apesar de as médias serem as mesmas, as distribuições são diferentes!

Estatística Descritiva


- Os pesos dos passageiros estão mais espalhados
- O desvio padrão é a estatística descritiva que nos permite atribuir um número único a essa dispersão em torno da média
 - Ex. exame de colesterol
 - Ex. altura média de 1,75m com desvio de 8cm
 - Ex. nota média 400 com desvio de 100

Estatística Descritiva

- A Distribuição Normal
 - Dados são simétricos em torno de sua média, em um formato de sino
 - Descreve muitos fenômenos comuns: pipocas estourando, altura de pessoas, notas ENEM, etc.

Estatística Descritiva

- A Distribuição Normal: alicerce de várias análises estatísticas



A média é a linha do meio, frequentemente representada pela letra grega μ . O desvio padrão é frequentemente representado pela letra grega σ . Cada faixa representa um desvio padrão.

Estatística Descritiva

- Problema:
 - Imagine que a C&A esteja vendendo um vestido por R\$100 e um subgerente remarca o preço em 25% menos. Após encher a cara com o Bill Gates em um bar, esse subgerente é demitido e o novo subgerente reajusta o preço em 25%. Qual o preço final do vestido?

Estatística Descritiva

- Problema:
 - Imagine que a C&A esteja vendendo um vestido por R\$100 e um subgerente remarca o preço em 25% menos. Após encher a cara com o Bill Gates em um bar, esse subgerente é demitido e o novo subgerente reajusta o preço em 25%. Qual o preço final do vestido?
 - Resposta: **R\$93,75**

Estatística Descritiva

- Porcentagem

$$(\text{VALOR NOVO} - \text{VALOR ORIGINAL}) / \text{VALOR ORIGINAL}$$

- $-25 / 100 = (X - 100) / 100 \Rightarrow X = 75$
- $25 / 100 = (X - 75) / 75 \Rightarrow 1875 / 100 = X - 75 \Rightarrow X = 93,75$

Estatística Descritiva

- Porcentagem

- Mudança percentual não deve ser confundida com mudança em pontos percentuais
- Ex. Em uma cidade do interior de MG, cuja renda vem principalmente de alunos de uma universidade, o prefeito aumentou o imposto sobre a cerveja de 3% para 5%

Estatística Descritiva

- Porcentagem

- Mudança percentual não deve ser confundida com mudança em pontos percentuais
- Ex. Em uma cidade do interior de MG, cuja renda vem principalmente de alunos de uma universidade, o prefeito aumentou o imposto sobre a cerveja de 3% para 5%
 - Aumento de 2 pontos percentuais
 - Aumento de 67%
- Qual a resposta está correta?

Estatística Descritiva

- Porcentagem

- Mudança percentual não deve ser confundida com mudança em pontos percentuais
- Ex. Em uma cidade do interior de MG, cuja renda vem principalmente de alunos de uma universidade, o prefeito aumentou o imposto sobre a cerveja de 3% para 5%
 - Aumento de 2 pontos percentuais
 - Aumento de 67%
- Qual a resposta está correta? **Ambas estão corretas, mas a segunda reflete melhor o impacto do aumento**

Estatística Descritiva

- A **vantagem** de qualquer índice é que ele consolida um monte de informações complexas em um único número
- Podemos então ranquear e comparar coisas: jogadores de beisebol, universidades, alunos, impressoras, artigos científicos, etc.

Estatística Descritiva

- A **desvantagem** de qualquer índice é que ele consolida um monte de informações complexas em um único número
- Isso pode ser feito de várias maneiras, cada uma com potencial para produzir um resultado diferente

Sugestão de Estudo

- Capítulo 2 (Estatística, Charles Wheelan)
- Capítulo 1 (Data Mining, Zaki e Meira)
- Curso Online USP (Aulas 36 a 38)
- Estatística Descritiva