

2. Estatística descritiva

Quem foi o melhor jogador de beisebol de todos os tempos?

PONDEREMOS POR UM INSTANTE sobre duas perguntas aparentemente não relacionadas: (1) o que está acontecendo com a saúde econômica da classe média americana?; e (2) quem foi o maior jogador de beisebol de todos os tempos?

A primeira pergunta é profundamente importante. Ela tende a estar no cerne de campanhas presidenciais e outros movimentos sociais. A classe média é o coração dos Estados Unidos, então o bem-estar financeiro desse grupo é um indicador fundamental da saúde econômica total da nação. A segunda pergunta é trivial (no sentido literal da palavra), embora os aficionados do beisebol possam discutir interminavelmente sobre ela. O que as duas perguntas têm em comum é que podem ser usadas para ilustrar as forças e limitações da estatística descritiva, que são os números e cálculos que usamos para sintetizar dados brutos.

Se eu quiser demonstrar que Derek Jeter é um grande jogador de beisebol, posso fazer você se sentar e descrever cada rebatida em cada jogo da Major League (a Liga Principal de Beisebol) que ele jogou. Esses seriam dados brutos, e levaria algum tempo para digeri-los, uma vez que Jeter jogou dezessete temporadas no New York Yankees e segurou o taco 9.868 vezes para rebater.

Ou posso simplesmente lhe dizer que ao final da temporada de 2011 Derek Jeter teve uma média de rebatidas na carreira de 0,313. Essa é uma estatística descritiva, ou uma “estatística sumária”.

A média de rebatidas é uma simplificação grosseira das dezessete temporadas de Jeter. É fácil de entender, elegante em sua simplicidade – e limitada naquilo que pode nos dizer. Os especialistas em beisebol têm um bando de estatísticas descritivas que consideram mais valiosas do que a média de rebatidas. Liguei para Steve Moyer, presidente da Baseball Info Solutions (uma firma que fornece uma porção de dados brutos como os do filme *Moneyball*), e lhe perguntei: (1) quais são as estatísticas mais importantes para avaliar talento em beisebol? (2) Quem foi o maior jogador de todos os tempos? Contarei a resposta assim que tivermos mais contexto.

Por enquanto, vamos voltar para o tema menos trivial, a saúde econômica da classe média. Idealmente, gostaríamos de achar o equivalente econômico da média de rebatidas, ou algo ainda melhor. Gostaríamos de ter uma medida simples, mas precisa, de como o bem-estar econômico do trabalhador americano típico tem mudado nos últimos anos. Será que as pessoas que definimos como classe média estão ficando mais ricas, mais pobres ou simplesmente correndo sem sair do lugar? Uma resposta razoável – embora de modo algum a resposta “certa” – seria calcular a mudança na renda per capita nos Estados Unidos no decorrer de uma geração, que é aproximadamente trinta anos. A renda per capita é uma média simples: a renda total dividida pelo tamanho da população. Por essa medida, a renda média nos Estados Unidos subiu de

US\$7.787 em 1980 para US\$26.487 em 2010 (o último ano para o qual o governo tem dados).¹ *Voilà!* Parabéns para nós.

Só há um probleminha. Meu cálculo rápido está tecnicamente correto, mas totalmente errado em termos da pergunta que me propus a responder. Para começar, os valores acima não estão corrigidos pela inflação. (Uma renda per capita de US\$7.787 em 1980 equivale a cerca de US\$19,6 mil quando convertida em dólares de 2010.) Esse é um ajuste relativamente rápido. O problema maior é que a renda média nos Estados Unidos não é igual à renda do americano médio. Vamos deslindar essa frasezinha traiçoeira.

A renda per capita pega meramente toda a renda ganha no país e a divide pelo número de pessoas, o que não nos informa absolutamente nada sobre quem está ganhando quanto dessa renda – seja em 1980 ou em 2010. Conforme ressaltavam os caras do movimento Occupy Wall Street, um crescimento explosivo na renda do 1% que está no topo da pirâmide pode aumentar significativamente a renda per capita sem que nenhum centavo a mais entre no bolso dos outros 99%. Em outras palavras, a renda média pode subir sem ajudar o americano médio.

Da mesma forma que na pergunta sobre estatística de beisebol, busquei uma opinião especializada externa sobre como deveríamos medir a saúde econômica da classe média americana. Perguntei a dois proeminentes economistas do trabalho, incluindo o principal assessor econômico do presidente Obama, que estatística descritiva eles usariam para avaliar o bem-estar econômico de um americano típico. Sim, você também terá essa resposta, uma vez que tenhamos feito uma rápida excursão pela estatística descritiva para dar a ela mais significado.

Do beisebol à renda, a tarefa básica quando se trabalha com dados é sintetizar uma grande dose de informação. Há cerca de 330 milhões de habitantes nos Estados Unidos. Uma planilha com o nome e o histórico de renda de cada americano conteria toda a informação que poderíamos desejar sobre a saúde econômica do país – todavia, seria também tão difícil de manejar que não nos diria absolutamente nada. A ironia é que uma grande quantidade de dados frequentemente pode apresentar menos clareza. Então simplificamos. Realizamos cálculos para reduzir um complexo arranjo de dados a um punhado de números que descrevam esses dados, exatamente da mesma forma que poderíamos sintetizar uma complexa e multifacetada performance de ginástica olímpica com um número: 9,8.

A boa notícia é que essas estatísticas descritivas nos dão um resumo manejável e significativo dos fenômenos subjacentes. É disso que trata este capítulo. A má notícia é que qualquer simplificação convida ao abuso. A estatística descritiva pode ser como perfis de um site de encontros na internet: tecnicamente acurados e, ainda assim, terrivelmente enganosos.

SUPONHA QUE VOCÊ esteja no trabalho navegando despreocupadamente pela internet, quando se depara com um fascinante relato cotidiano do fracassado casamento de 72 dias de Kim Kardashian com o jogador profissional de basquete Kris Humphries. Você acabou de ler sobre o sétimo dia do casamento quando seu chefe aparece com dois enormes arquivos de dados. Um deles tem informações sobre a solicitação de uso de garantia para cada uma das 57.334 impressoras a laser que a sua firma vendeu no ano passado. (Para cada impressora vendida, o arquivo documenta o número de problemas de qualidade reportados durante o período da garantia.) O outro arquivo tem a mesma informação para cada uma das 994.773 impressoras a

laser que a sua principal concorrente vendeu no mesmo período. Seu chefe quer saber como as impressoras da sua firma se comparam em termos de qualidade com as da concorrência.

Felizmente, o computador que você estava usando para ler sobre o casamento de Kardashian tem um pacote básico de estatística, mas por onde você começa? Seus instintos provavelmente estão corretos: a primeira tarefa descritiva frequentemente é achar alguma medida do “meio” de um conjunto de dados, ou aquilo que os estatísticos descrevem como sua “tendência central”. Qual é a experiência de qualidade típica para as suas impressoras em comparação com as da concorrência? A medida mais básica do “meio” de uma distribuição é a média. Neste caso, queremos saber o número médio de problemas de qualidade por impressora vendida pela sua empresa e pela concorrente. Você simplesmente registraria o número total de problemas de qualidade reportados para todas as impressoras durante o período de garantia e então o dividiria pelo número total de impressoras vendidas. (Lembre-se, a mesma impressora pode ter múltiplos problemas enquanto está na garantia.) Você faria isso para cada firma, criando uma importante estatística descritiva: o número médio de problemas de qualidade por impressora vendida.


Suponha que se revele que as impressoras da concorrente têm uma média de 2,8 de problemas de qualidade por impressora durante o período de garantia, enquanto as da sua firma têm uma média de 9,1 defeitos reportados. Essa foi fácil. Você simplesmente pegou informações sobre 1 milhão de impressoras vendidas por duas empresas diferentes e destilou os dados até a essência do problema: as suas impressoras quebram um bocado. É claro que está na hora de mandar um breve e-mail para o seu chefe quantificando essa diferença de qualidade e, então, voltar ao oitavo dia do casamento de Kim Kardashian.

Ou talvez não. Fui deliberadamente vago antes quando me referi ao “meio” da distribuição. A média acaba revelando ter alguns problemas nesse contexto, especificamente, por ela ser propensa a distorções por “valores atípicos”^a (ou “valores extremos”), que são as observações que se situam mais longe do centro. Para sua mente absorver esse conceito, imagine dez sujeitos sentados em banquetas altas de um bar de classe média em Seattle. Cada um deles ganha US\$35 mil por ano, o que faz com que a renda média anual do grupo seja de US\$35 mil. Bill Gates entra no bar com um papagaio falante empoleirado no ombro. (O papagaio não tem nada a ver com o exemplo, mas meio que dá um tempero à história.) Vamos supor que Bill Gates tenha uma renda anual de US\$1 bilhão. Quando Bill se senta no 11.^o banco do bar, a renda média anual dos frequentadores sobe para cerca de US\$91 milhões. Obviamente, nenhum dos dez beberões originais ficou mais rico (embora fosse razoável esperar que Bill Gates pagasse uma ou duas rodadas). Se eu fosse descrever os frequentadores desse bar como tendo uma renda média anual de US\$91 milhões, a afirmação seria ao mesmo tempo estatisticamente correta e grosseiramente enganosa. Esse não é um bar de badalação de multimilionários; é um bar onde um bando de caras com renda relativamente baixa estão por acaso sentados ao lado de Bill Gates e seu papagaio falante. A sensibilidade da média a valores atípicos é o motivo pelo qual não devemos calibrar a saúde econômica da classe média americana observando a renda per capita. Por ter havido crescimento explosivo em rendas no topo da distribuição – CEOs, administradores de fundos hedge e atletas como Derek Jeter –, a renda média nos Estados Unidos poderia ser fortemente distorcida pelos megarricos, como no exemplo das banquetas de bar com Bill Gates numa das pontas.

Por essa razão, temos outra estatística que também sinaliza o “meio” de uma distribuição, só que de maneira diferente: a mediana. A mediana é o ponto que divide uma distribuição ao meio, significando que metade das observações jaz acima da mediana e metade jaz abaixo. (Se o número de observações é par, a mediana está no ponto médio entre as duas observações do meio.) Se voltarmos ao exemplo das banquetas no bar, a renda mediana anual para os dez sujeitos ali sentados é de US\$35 mil. Quando Bill Gates entra com seu papagaio e se encarrapita num banco, a renda mediana anual para os onze ainda é de US\$35 mil. Se você literalmente visualizar os frequentadores do bar alinhados nas banquetas em ordem crescente de suas rendas, a renda do sujeito sentado no sexto banco representa a renda mediana do grupo. Se Warren Buffett entrar e se sentar no 12^o banco ao lado de Bill Gates, a mediana ainda não se altera.^b

Para distribuições sem valores atípicos sérios, a mediana e a média serão semelhantes. Incluí um sumário hipotético dos dados de qualidade para as impressoras da concorrente. Em particular, apresentei os dados naquilo que é conhecido como distribuição de frequência. A quantidade de problemas de qualidade por impressora está disposta ao longo da base; a altura de cada barra representa a porcentagem de impressoras vendidas com aquela quantidade de problemas. Por exemplo, 36% das impressoras da empresa concorrente tiveram dois defeitos de qualidade durante o período de garantia. Como a distribuição inclui todos os resultados de qualidade possíveis, inclusive zero defeito, as proporções precisam somar 1 (ou 100%).

Distribuição de frequência de reclamações de qualidade para as impressoras da concorrente




Como a distribuição é quase simétrica, a média e a mediana estão relativamente próximas entre si. A distribuição é ligeiramente puxada para a direita pelo pequeno número de impressoras com muitos defeitos de qualidade reportados. Esses valores atípicos movem a média ligeiramente para a direita, mas não têm impacto na mediana. Suponha que pouco antes de mandar o relatório de qualidade para o seu chefe, você resolve calcular o número *mediano* de problemas de qualidade das impressoras da sua firma e da concorrência. Ao apertar apenas algumas teclas, você obtém o resultado. O número mediano de queixas de qualidade para as impressoras da concorrente é 2; o número mediano de queixas de qualidade para as impressoras

da sua companhia é 1.

Hein? O número mediano de reclamações de qualidade por impressora da sua empresa é na verdade *mais baixo* que o da sua concorrente. Como o relato sobre o casamento de Kim Kardashian está ficando monótono, e como está intrigado por essa descoberta, você imprime uma distribuição de frequência para os seus próprios problemas de qualidade.

O que fica claro é que a sua firma não tem um problema de qualidade uniforme; você tem um problema “de limões”;^c um pequeno número de impressoras tem uma quantidade enorme de reclamações de qualidade. Esses valores extremos inflam a média, mas não a mediana. Mais importante do ponto de vista da produção, você não precisa reequipar todo o processo de fabricação; precisa apenas descobrir de onde estão vindo as impressoras de egrégia baixa qualidade e consertar isso.^d

Distribuição de frequência de reclamações de qualidade da sua companhia



Problemas de qualidade por impressora

Nem a mediana nem a média são difíceis de calcular; a chave é determinar que medida do “meio” é mais acurada numa situação particular (um fenômeno que é explorado com facilidade). Ao mesmo tempo, a mediana tem alguns correspondentes úteis. Como já discutimos, a mediana divide a distribuição pela metade. A distribuição pode ser ainda mais dividida em quartos, ou quartis. O primeiro quartil consiste nos 25% inferiores das observações; o segundo quartil consiste nos 25% seguintes das observações; e assim por diante. Ou a distribuição pode ser dividida em decis, cada um com 10% das observações. (Se a sua renda está no decil superior da distribuição de renda americana, você estaria ganhando mais que 90% que seus colegas trabalhadores.) Podemos ir ainda além e dividir a distribuição em centésimos, ou percentis. Cada percentil representa 1% da distribuição, de modo que o primeiro percentil representa a base da distribuição e o 99^o percentil representa o 1% superior da distribuição.

A vantagem desses tipos de estatística descritiva é que eles descrevem onde uma observação

particular se encontra em comparação a todo o restante. Se eu lhe disser que seu filho está no terceiro percentil em compreensão de leitura, você deverá saber imediatamente que a família precisa passar mais tempo na biblioteca. Você não precisa saber nada sobre o teste em si, ou o número de questões que o seu filho acertou. A contagem do percentil fornece o ranking do seu filho em relação a todas as outras crianças que fizeram o teste. Se o teste foi fácil, então a maioria das crianças teve um número alto de respostas corretas, mas seu filho teve menos que a maioria delas. Se foi um teste extremamente difícil, então todas as crianças tiveram um número baixo de respostas corretas, mas a contagem do seu filho ainda será baixa.

Aqui é um bom momento para introduzir alguma terminologia útil. Uma contagem, um resultado, número ou valor “absoluto” possui algum significado intrínseco. Se precisei de 83 tacadas para dezoito buracos no golfe, esse é um placar absoluto. Eu posso ter feito isso num dia com temperatura de 14° C, o que também é um valor absoluto. Valores absolutos geralmente podem ser interpretados sem qualquer contexto ou informação adicional. Quando digo que dei 83 tacadas, você não precisa saber o placar dos outros jogadores naquele dia para avaliar a minha performance. (A exceção poderia ser se as condições forem particularmente adversas, ou o campo especialmente difícil ou fácil.) Se eu fico em nono lugar num torneio de golfe, essa é uma estatística relativa. Um valor ou número “relativo” só tem significado em comparação com alguma outra coisa, ou num contexto mais amplo, tal como a comparação com os oito golfistas que tiveram resultado melhor que o meu. A maioria dos testes padronizados gera resultados que têm significado apenas como estatística relativa. Se eu lhe digo que um aluno do terceiro ano de uma escola fundamental em Illinois acertou 43 questões em sessenta na seção de matemática do Teste Estadual de Aproveitamento Escolar, esse placar absoluto não tem muito significado. Mas quando o converto num percentil – significando que ponho o resultado bruto numa distribuição com os placares de matemática de todos os outros alunos de terceiro ano de Illinois –, então obtenho uma boa dose de significado. Se 43 respostas corretas cai no 83.^o percentil, então esse aluno está se saindo melhor que a maioria dos seus colegas por todo o estado. Se ele está no oitavo percentil, então está de fato se debatendo com a matemática. Nesse caso, o percentil (placar relativo) é mais significativo do que o número de respostas corretas (placar absoluto).

Outra estatística que pode nos ajudar a descrever o que de outro modo poderia ser apenas um ajuntamento de números é o desvio padrão, que é uma medida de como os dados se dispersam em relação à média. Em outras palavras, o quanto essas observações estão espalhadas? Suponha que eu coletasse dados sobre o peso de 250 pessoas num avião com destino a Boston e também levantasse o peso de uma amostra de 250 qualificados para a Maratona de Boston. Agora, suponha que o peso médio para ambos os grupos seja aproximadamente o mesmo, digamos setenta quilos. Qualquer pessoa que já tenha ficado espremida na fileira do meio num voo lotado, lutando pelo encosto de braço, sabe que muita gente num voo comercial típico pesa mais que 70 quilos. Mas você pode se recordar que nesses mesmos voos desagradáveis, superlotados, havia um monte de bebês chorando e crianças malcomportadas, todos com uma enorme capacidade pulmonar, mas não muita massa. Quando se trata de calcular o peso médio no voo, o bloco de 150 quilos dos jogadores de futebol americano de cada lado da sua poltrona do meio tende a ser compensado pelo minúsculo bebê chorando na outra fila e pelo garoto de seis anos chutando as costas do seu assento na fila de trás.

Com base nas ferramentas descritivas introduzidas até aqui, os pesos dos passageiros do avião e dos maratonistas são quase idênticos. *Mas não são*. Sim, os pesos dos dois grupos têm aproximadamente o mesmo “meio”, mas os passageiros do avião têm uma dispersão muito maior em torno do ponto médio, o que quer dizer que seus pesos estão espalhados para mais longe desse ponto médio. Meu filho de oito anos poderia ressaltar que os maratonistas todos parecem pesar a mesma coisa, enquanto que entre os passageiros do voo há algumas pessoas minúsculas e algumas pessoas bizarramente grandes. Os pesos dos passageiros estão “mais espalhados”, o que é um atributo importante quando se trata de descrever os pesos dos dois grupos. O desvio padrão é a estatística descritiva que nos permite atribuir um número único a essa dispersão em torno da média. As fórmulas para calcular o desvio padrão e a variância (outra medida comum de dispersão, da qual deriva o desvio padrão) estão incluídas no apêndice ao final do capítulo. Por enquanto, pensemos em por que a medida da dispersão tem importância.

Suponha que você entre no consultório da sua médica. Você tem se sentido fatigado desde a sua promoção a chefe do controle de qualidade de impressoras norte-americanas. Sua médica tira sangue, e alguns dias depois sua assistente deixa um recado na sua secretária eletrônica para informá-lo de que a sua contagem de HCB2 (um componente químico fictício do sangue) é 134. Você corre para a internet e descobre que o HCB2 médio para uma pessoa da sua idade é 122 (e a mediana é mais ou menos a mesma). Caramba! Se você for como eu, finalmente redigiria um testamento. Escreveria cartas chorosas para seus pais, esposa, filhos e amigos próximos. Poderia querer saltar de paraquedas ou tentar escrever um romance depressa. Mandaria ao seu chefe um e-mail composto às pressas comparando-o com certas partes da anatomia humana – TUDO EM MAIÚSCULAS.

Talvez nada disso seja necessário (e o envio daquele e-mail para o seu chefe poderia acabar muito mal). Quando você telefona de volta para o consultório da médica a fim de acertar as providências para seus cuidados hospitalares, a assistente lhe informa que a sua contagem está dentro da faixa normal. Mas como pode ser? “Minha contagem está doze pontos acima da média!”, você grita repetidamente ao aparelho.

“O desvio padrão para a contagem de HCB2 é 18”, a técnica lhe informa.

Que raios isso quer dizer?

Existe uma variação natural na contagem de HCB2, como ocorre com a maioria dos fenômenos biológicos (por exemplo, altura). Embora o valor médio do fictício componente químico seja 122, há uma profusão de gente saudável cuja contagem é superior ou inferior. O perigo só surge quando a contagem de HCB2 fica excessivamente alta ou baixa. Então, como descobrimos o que quer dizer “excessivamente” nesse contexto? Como já observamos, o desvio padrão é uma medida de dispersão, o que significa que reflete o quanto as observações se aglutinam em torno da média. Para muitas distribuições de dados típicas, uma elevada proporção das observações jaz dentro de um desvio padrão da média (o que significa que estão dentro da faixa que vai de um desvio padrão abaixo da média a um desvio padrão acima da média). Para ilustrar com um exemplo simples, a altura média de um homem americano adulto é de 1,75 metro. O desvio padrão é aproximadamente de oito centímetros. Uma alta proporção de homens adultos tem altura entre 1,67 metro e 1,83 metro.

Ou, colocando de forma ligeiramente distinta, qualquer homem dentro dessa faixa não seria considerado exageradamente baixo ou alto. O que nos traz de volta para os seus preocupantes

resultados de HCb2. Sim, sua contagem está doze acima da média, mas isso é menos que um desvio padrão, que é o equivalente químico sanguíneo de ter cerca de 1,80 metro – não particularmente incomum. É claro que muito menos observações se encontram a dois desvios padrões da média, e menos ainda a três ou quatro desvios padrões. (No caso da altura, um homem americano cuja altura esteja a três desvios padrões acima da média teria cerca de dois metros ou mais.)


Algumas distribuições são mais dispersas que outras. Daí, o desvio padrão dos pesos dos 250 passageiros da linha aérea ser mais alto que o desvio padrão dos pesos dos 250 maratonistas. Uma distribuição de frequência com os pesos dos 250 passageiros do voo seria literalmente mais “gorda” (mais espalhada) do que uma distribuição de frequência dos pesos dos maratonistas. Uma vez que conheçamos a média e o desvio padrão para qualquer conjunto de dados, teremos em mãos algum resultado intelectual sério. Por exemplo, suponha que eu diga que o escore médio do Teste de Raciocínio SAT de matemática seja quinhentos com um desvio padrão de cem. Como acontece com a altura, o grosso dos alunos que fazem o teste estará dentro de um desvio padrão da média, isto é, entre quatrocentos e seiscentos. Quantos alunos você acha que fazem 720 ou mais? Provavelmente não muitos, já que esse resultado está a mais de dois desvios padrões acima da média.

Na verdade, podemos fazer ainda melhor do que dizer “não muitos”. Este é um bom momento para introduzir uma das mais importantes, úteis e comuns distribuições em estatística: a distribuição normal. Dados distribuídos normalmente são simétricos em torno de sua média, num formato de sino que lhe parecerá familiar.

A distribuição normal descreve muitos fenômenos comuns. Imagine uma distribuição de frequência que descreve pipocas estourando numa panela. Alguns caroços começam a estourar logo, talvez um ou dois por segundo. Depois de dez ou quinze segundos, os caroços estão estourando freneticamente. Aí, aos poucos, a quantidade de caroços estourando por segundo diminui mais ou menos na mesma proporção de quando começaram a estourar. As alturas dos homens americanos têm uma distribuição mais ou menos normal, o que significa que são aproximadamente simétricas em torno da média de 1,75 metro. Cada teste SAT é especificamente projetado para produzir uma distribuição normal de escores com média quinhentos e desvio padrão de cem. Segundo o *Wall Street Journal*, os americanos até tendem a estacionar em shopping centers numa distribuição normal: a maioria dos carros é estacionada diretamente em frente à entrada do shopping – o “pico” da curva normal – com “traseiras” de carros saindo para a direita e a esquerda da entrada.

A beleza da distribuição normal – que remete ao poder, à sutileza e à elegância de Michael Jordan – provém do fato de que conhecemos por definição exatamente que proporção das observações numa distribuição normal cai dentro de um desvio padrão da média (68,2%), dentro de dois desvios padrões da média (95,4%), dentro de três desvios padrões (99,7%), e assim por diante. Isto pode soar trivial. Na verdade, é o alicerce sobre o qual se fundamenta grande parte da estatística. Voltaremos a este ponto com mais profundidade adiante no livro.

A distribuição normal



A média é a linha do meio, frequentemente representada pela letra grega μ . O desvio padrão é frequentemente representado pela letra grega σ . Cada faixa representa um desvio padrão.

A ESTATÍSTICA DESCRITIVA é muitas vezes usada para comparar dois valores ou quantidades. Eu sou dois centímetros mais alto que meu irmão; a temperatura de hoje está cinco graus acima da média histórica para esta data; e assim por diante. Essas comparações fazem sentido porque a maioria de nós reconhece a escala de unidades envolvida. Dois centímetros não são muita coisa quando se trata da altura de uma pessoa, então você pode inferir que meu irmão e eu temos aproximadamente a mesma altura. Por outro lado, cinco graus é um desvio de temperatura significativo em qualquer clima em qualquer época do ano, então cinco graus acima da média fazem com que o dia seja muito mais quente do que o habitual. Mas suponha que eu lhe dissesse que a barra de cereal de granola A contém 31 miligramas de sódio a mais que a barra de cereal de granola B. A menos que você seja um superentendido em sódio (e saiba muito sobre as porções de consumo para o cereal de granola), essa afirmação não será particularmente informativa. E se eu lhe dissesse que meu primo Al ganhou US\$53 mil menos este ano do que no ano passado? Será que devemos nos preocupar com o Al? Ou será que ele é um gerente de fundos de hedge para quem essa quantia é apenas um erro de arredondamento em seu balanço anual?

Tanto no exemplo do sódio quanto no da renda do Al, nos falta o contexto. O jeito mais fácil de dar sentido a essas comparações relativas é usar porcentagens. *Significaria* algo se eu lhe dissesse que a Barra de Granola A tem 50% mais sódio que a barra de cereal de granola B, ou que a renda do primo Al caiu 47% no ano passado. Medir alterações como porcentagem nos dá

algum senso de escala.

Você provavelmente aprendeu a calcular porcentagens no quarto ano e ficará tentado a pular os próximos parágrafos. Muito justo. Mas antes faça um exercício simples. Imagine que uma loja de departamento esteja vendendo um vestido por US\$100 e o subgerente remarca toda a mercadoria em 25% menos. Após encher a cara num bar com Bill Gates, ele é despedido^c e o novo subgerente sobe todos os preços em 25%. Qual é o preço final do vestido? Se você respondeu (ou pensou) US\$100, então é melhor não pular nenhum parágrafo.

O preço final do vestido é na realidade US\$93,75. Não se trata de um mero truque, que lhe renderá aplausos e adulação em festas e coquetéis. Porcentagens são úteis – mas também potencialmente capazes de confundir e até de iludir. A fórmula para calcular uma diferença (ou mudança) percentual é a seguinte: (valor novo – valor original)/valor original. O numerador (a parte de cima da fração) nos dá o tamanho da mudança em termos absolutos; o denominador (a parte de baixo da fração) é o que coloca essa mudança em contexto, comparando-a com o ponto de partida. De início, isso parece simples e direto, como quando o subgerente da loja corta o preço de US\$100 do vestido em 25%. Vinte e cinco por cento do preço original, US\$100, são US\$25; esse é o desconto, que reduz o preço para US\$75. Você pode colocar os números na fórmula acima e fazer uma manipulação simples para chegar ao mesmo lugar:

$$(100 - 75) / 100 = 0,25, \text{ ou } 25\%.$$

O vestido está sendo vendido por US\$75 quando o novo subgerente exige que o preço seja aumentado em 25%. É aí que muita gente que está lendo este parágrafo provavelmente cometeu um erro. A remarcação de 25% de aumento é calculada como porcentagem do novo preço reduzido do vestido, que é US\$75. O aumento será $0,25 \times 75$, ou US\$18,75, e é assim que o preço final do vestido acaba sendo US\$93,75 (e não US\$100). O ponto é que uma mudança percentual sempre dá o valor de algo *em relação a outra coisa*. Portanto, é melhor entendermos o que é essa outra coisa.

Certa vez investi algum dinheiro numa empresa que meu colega de quarto criou. Como se tratava de um empreendimento privado, não havia exigências quanto às informações a serem fornecidas aos sócios. Passaram-se alguns anos sem nenhuma informação sobre o destino do meu investimento; meu ex-colega de quarto era bem reticente sobre o assunto. Por fim, recebi uma carta pelo correio informando-me que os lucros da firma estavam 46% mais altos que no ano anterior. Não havia informação sobre o valor desses lucros em termos absolutos, o que significava que eu ainda não tinha absolutamente nenhuma ideia do desempenho do meu investimento. Suponha que no ano anterior a firma tenha ganhado US\$0,27 – essencialmente nada. Este ano a firma ganhou US\$0,39 – também essencialmente nada. Contudo, os lucros da empresa aumentaram de US\$0,27 para US\$0,39, que é tecnicamente um aumento de 46%. Obviamente a carta ao sócio teria sido decepcionante se dissesse que os lucros acumulados da firma em dois anos eram menos do que o custo de um copo de café na Starbucks.

Para ser justo com o meu colega de quarto, ele acabou vendendo a companhia por centenas de milhões de dólares, gerando um retorno de 100% sobre o meu investimento. (Como você não tem ideia de quanto eu investi, também não tem ideia de quanto dinheiro eu ganhei – o que vem reforçar lindamente o meu ponto!)

Deixe-me fazer uma distinção adicional. Mudança percentual não deve ser confundida com

uma mudança em pontos percentuais. Índices, taxas e alíquotas são geralmente expressos em porcentagens. O índice de imposto sobre vendas em Illinois é 6,75%. Eu pago ao meu agente 15% dos royalties do meu livro. Esses índices são atribuídos a alguma quantidade, tal como a renda no caso da alíquota do imposto de renda. Obviamente os índices podem subir ou descer; menos intuitivamente, as *mudanças* nos índices podem ser descritas de formas amplamente diversificadas. O melhor exemplo disso foi uma mudança recente no imposto de renda pessoal em Illinois, que subiu de 3 para 5%.^f Há duas maneiras de exprimir essa mudança de imposto, ambas tecnicamente acuradas. Os democratas, que engendraram esse aumento, assinalavam (corretamente) que a *alíquota* do imposto de renda estadual foi aumentada em *dois pontos percentuais* (de 3 para 5%). Os republicanos ressaltavam (também corretamente) que o imposto de renda estadual fora aumentado em 67%. [Este é um teste adequado para a fórmula de alguns parágrafos atrás: $(5-3)/3 = 2/3$, que, arredondando, dá 0,67, ou 67%.]

Os democratas focalizavam a mudança absoluta na alíquota do imposto. Os republicanos focalizavam a mudança percentual na carta tributária. Conforme observado, ambas as descrições são tecnicamente corretas, embora eu argumentaria que a descrição republicana transmite com mais precisão o impacto da mudança no imposto, já que o que eu vou pagar ao governo – a quantia que me importa, e não a forma como é calculada – realmente subiu 67%.

MUITOS FENÔMENOS desafiam uma descrição perfeita com uma estatística única. Suponha que o *quarterback* Aaron Rodgers lance 365 jardas, mas sem nenhum *touchdown*. Ao mesmo tempo, Peyton Manning lança magras 127 jardas, mas com três *touchdowns*. Manning gerou mais pontos, mas presumivelmente Rodgers preparou *touchdowns* marchando com seu time através do campo e mantendo o ataque da outra equipe fora de campo. Quem jogou melhor? No Capítulo 1, discuti o índice de passes da NFL, que é uma tentativa razoável da liga de lidar com esse desafio estatístico. O índice de passes é um exemplo de índice, que é uma estatística descritiva composta de outras estatísticas descritivas. Uma vez consolidadas essas diferentes medidas de desempenho num único número, essa estatística pode ser usada para fazer comparações, tais como um ranking de *quarterbacks* num dia específico, ou mesmo ao longo de toda uma carreira. Se o beisebol tivesse um índice semelhante, então a questão do melhor jogador de todos os tempos estaria resolvida. Estaria mesmo?

A vantagem de qualquer índice é que ele consolida um monte de informações complexas num único número. Podemos então ranquear coisas que de outra forma desafiam uma simples comparação – qualquer coisa, desde *quarterbacks* até faculdades e concorrentes em concursos de beleza. No concurso de Miss Estados Unidos, a vencedora geral é uma combinação de cinco competições separadas: entrevista pessoal, traje de banho, traje de noite, talento e pergunta no palco. (Miss Simpatia é votada separadamente pelas próprias competidoras.)

Mas, puxa vida, a desvantagem de qualquer índice é que ele consolida um monte de informações complexas num único número. Há incontáveis maneiras de fazer isso; cada uma tem o potencial de produzir um resultado diferente. Malcolm Gladwell mostra isso de forma brilhante numa matéria da *New Yorker* criticando a nossa compulsiva necessidade de ranquear as coisas.² (Ele é particularmente duro com o ranking de faculdades.) Gladwell oferece o exemplo de ranking da revista automobilística *Car and Driver* de três carros esportivos: o Porsche

Cayman, o Chevrolet Corvette e o Lotus Evora. Usando uma fórmula que inclui 21 variáveis, a *Car and Driver* ranqueou o Porsche em primeiro lugar. Mas Gladwell ressalta que “o design exterior” conta apenas 4% do escore total na fórmula da *Car and Driver*, o que parece ridiculamente pouco para um carro esportivo. Se o design tivesse um peso maior na contagem geral (25%), então o Lotus ficaria em primeiro.

Mas espere aí. Gladwell também assinala que o preço de tabela do carro tem um peso relativamente pequeno na fórmula da *Car and Driver*. Se o preço tivesse um peso maior (de modo que o ranking se baseasse igualmente no preço, no design exterior e nas características do veículo), o Chevy Corvette ficaria ranqueado como número um.

Qualquer índice é altamente sensível às estatísticas descritivas que são agrupadas para constituí-lo, assim como ao peso dado a cada um desses componentes. Como resultado, os índices variam de ferramentas úteis, mas imperfeitas, até completas charadas. Um exemplo do primeiro caso é o Índice de Desenvolvimento Humano das Nações Unidas, ou IDH. O IDH foi criado como uma medida de bem-estar econômico mais amplo que simplesmente a renda. O IDH utiliza a renda como um de seus componentes, mas também inclui medidas de expectativa de vida e realizações educacionais. Os Estados Unidos estão ranqueados em 11.^o lugar no mundo em termos de produção econômica per capita (atrás de vários países ricos em petróleo como o Qatar, Brunei e Kuwait), mas em quarto lugar em desenvolvimento humano.³ É verdade que os rankings de IDH mudariam ligeiramente se as partes componentes do índice fossem reconfiguradas, mas não haveria mudança razoável que fizesse o Zimbábue escalar o ranking de modo a ultrapassar a Noruega. O IDH fornece uma fotografia instantânea conveniente e razoavelmente acurada dos padrões de vida ao redor do globo.

ESTATÍSTICAS DESCRITIVAS nos dão a percepção de fenômenos que nos importam. Nesse espírito, podemos retornar às perguntas feitas no começo do capítulo. Quem é o melhor jogador de beisebol de todos os tempos? Mais importante para os propósitos deste capítulo, que estatística descritiva seria mais proveitosa para responder a essa pergunta? Segundo Steve Moyer, presidente da Baseball Info Solutions, as três estatísticas mais valiosas (além da idade) para avaliar qualquer jogador que não seja o arremessador seriam as seguintes:

1. Porcentagem na base (OBP – *on-base percentage*), às vezes chamada média na base (OBA – *on-base average*): mede a proporção do tempo que um jogador tem êxito em alcançar uma base, inclusive *walks* [caminhadas] (que não são contadas na média de rebatidas) – quando o rebatedor “caminha” para a primeira base mesmo não tendo rebatido.
2. *Slugging percentage* (SLG), que pode ser traduzido livremente como “matar a pau”: mede o poder de rebater calculando o total de bases alcançadas por rebatida. Uma base isolada vale um, base dupla vale dois, tripla, três, e um *home run* [“corrida até em casa” – a volta toda] vale quatro. Assim, um rebatedor que faz uma isolada e uma tripla em cinco posses do taco tem uma SLG de $(1+3)/5 = 0,800$.
3. *At bats* (AB) – posses do taco: contextualiza o índice acima. Qualquer palerma pode ter estatísticas impressionantes para um ou dois jogos. Um superastro compila “números”


impressionantes em milhares de aparições para rebater.

Na opinião de Moyer (sem hesitações, devo acrescentar), o melhor jogador de beisebol de todos os tempos foi Babe Ruth por causa da sua habilidade especial de rebater e arremessar. Babe Ruth ainda detém o recorde de carreira da Major League para SLG, a porcentagem de “matar a pau”, de 0,690.⁴

E quanto à saúde econômica da classe média americana? Mais uma vez, recorro aos especialistas. Mandeí um e-mail para Jeff Grogger (um colega meu na Universidade de Chicago) e Alan Krueger (o mesmo economista de Princeton que estudou terroristas e agora é chefe do Conselho de Assessores Econômicos do presidente Obama). Ambos deram variações da mesma resposta básica. Para avaliar a saúde econômica da “classe média” americana, devemos examinar as mudanças no salário mediano (corrigido pela inflação) durante as últimas décadas. Eles também recomendaram examinar mudanças nos salários no 25.^o e 75.^o percentis (o que pode ser razoavelmente interpretado como os limites inferior e superior para a classe média).

Mais uma distinção se faz necessária. Ao avaliar a saúde econômica, podemos examinar renda ou salários. Não são a mesma coisa. Um salário é aquilo que nos é pago por uma quantidade fixa de trabalho, tal como um salário por hora ou semanal. Renda é a soma de todos os pagamentos de diferentes fontes. Se um trabalhador pega um segundo emprego ou trabalha mais horas, sua renda pode aumentar sem mudança de salário. (Sob esse aspecto, a renda pode aumentar mesmo com o salário caindo, contanto que o trabalhador fique horas suficientes no emprego.) No entanto, se os indivíduos precisam trabalhar mais para ganhar mais, é difícil avaliar o efeito geral sobre seu bem-estar. O salário é uma medida menos ambígua de como os americanos estão sendo compensados pelo trabalho que fazem; quanto mais alto o salário, mais o trabalhador leva para casa por cada hora de serviço.

Dito isso tudo, eis um gráfico dos salários americanos nas últimas três décadas. Também acrescentei o nonagésimo percentil para ilustrar mudanças nos salários dos trabalhadores de classe média em comparação, nesse intervalo de tempo, com os trabalhadores do topo da distribuição.



Salários semanais em percentis escolhidos

Fonte: “Changes in the Distribution of Workers’ Hourly Wages between 1979 and 2009”, Congressional Budget Office, 16 de fevereiro de 2011. Os dados do gráfico podem ser encontrados em: <http://www.cbo.gov/sites/default/files/cbofiles/ftpdocs/120xx/doc12051/02-16-wagedispersion.pdf>.

Uma variedade de conclusões pode ser tirada desses dados. Eles não apresentam uma única resposta “certa” em relação às fortunas econômicas da classe média. Eles nos dizem sim que o trabalhador típico, um trabalhador americano ganhando salário mediano, tem “corrido sem sair do lugar” por quase trinta anos. Trabalhadores no nonagésimo percentil se saíram muito, muito melhor. As estatísticas descritivas nos ajudam a enquadrar a questão. O que fazer em relação a elas, se é que há algo a fazer, é uma questão política e ideológica.

APÊNDICE AO CAPÍTULO 2

Dados para o gráfico de defeitos de impressoras

	Zero	Um	Dois	Três	Quatro	Cinco	Seis	Sete	Oito	Nove	Dez ou mais
Frequência de defeitos da empresa concorrente	12	14	36	13	8	6	5	3	0	2	1

	Zero	Um	Dois	Três	Quatro	Cinco	Seis	Sete	Oito	Nove	Dez ou mais
Frequência dos seus defeitos	25	31	9	4	3	0	0	1	1	0	26

Fórmula para a variância e o desvio padrão

Variância e desvio padrão são os mecanismos estatísticos mais comuns para medir e descrever a dispersão de uma distribuição. A variância, frequentemente representada pelo símbolo s^2 , é calculada determinando-se o quão distante as observações dentro de uma distribuição se encontram da média. No entanto, o detalhe é que a diferença entre cada observação e a média é elevada ao quadrado; a soma de todos esses termos quadrados é então dividida pelo número de observações.

Especificamente:

Para qualquer conjunto de n observações $x_1, x_2, x_3 \dots x_n$ com média μ ,

$$\text{variância} = \sigma^2 = \frac{[(x_1 - \mu)^2 + (x_2 - \mu)^2 + (x_3 - \mu)^2 + \dots + (x_n - \mu)^2]}{n}$$

Como a diferença entre cada termo e a média é elevada ao quadrado, a fórmula para calcular a variância põe um peso particular em observações que se acham longe da média, ou

valores atípicos ou extremos (“*outliers*”), como ilustra a seguinte tabela de alturas de estudantes.

Grupo 1	Altura ($\mu = 175$ cm)	Média = Valor absoluto de $(x_n - \mu)^*$	$(x_n - \mu)^2$
Nick	185	10	100
Elana	165	10	100
Dinah	170	5	25
Rebecca	173	2	4
Ben	183	8	64
Charu	175	0	0
		Total = 35	Total = 293
			Variancia = $293/6 = 48,83$
			Desvio padrão = $\sqrt{48,83} = 6,988 = 7$
Grupo 2	Altura ($\mu = 175$ cm)	Média = Valor absoluto de $(x_n - \mu)^*$	$(x_n - \mu)^2$
Sahar	163	12	144
Maggie	170,5	4,5	20,25
Faisal	174	1	1
Ted	175	0	0
Jeff	180,5	5,5	30,25
Narciso	187	12	144
		Total = 35	Total = 339,5
			Variancia = $339,5/6 = 56,583$
			Desvio padrão = $\sqrt{56,583} = 7,522 = 7,5$

* Valor absoluto é a distância entre dois valores, independente do sentido, de modo que é sempre positiva. Neste caso, representa o número de centímetros entre a altura do indivíduo e a média.

Ambos os grupos de estudantes têm uma altura média de 175 centímetros. As alturas dos estudantes em ambos os grupos também diferem da média pela mesma quantidade total de centímetros, 35. Segundo essa medida de dispersão, as duas distribuições são idênticas. Todavia, a variância do Grupo 2 é mais elevada devido ao peso dado na fórmula de variância para valores que estão particularmente distantes da média – Sahar e Narciso, neste caso.

A variância é raramente usada como estatística descritiva por si só. Em vez disso, ela é mais útil como passo para calcular o desvio padrão de uma distribuição, que é uma ferramenta mais intuitiva como estatística descritiva.

O desvio padrão para um conjunto de observações é a raiz quadrada da variância:

Para qualquer conjunto de n observações $x_1, x_2, x_3 \dots x_n$ com média μ , o desvio padrão $= \sigma =$
raiz quadrada de todo esse valor =

$$\sqrt{\frac{[(x_1 - \mu)^2 + (x_2 - \mu)^2 + (x_3 - \mu)^2 + \dots + (x_n - \mu)^2]}{n}}$$

^a O termo original para esses “valores atípicos” é “*outlier*” – aquilo que “está fora”. Esse termo costuma ser usado também em textos em português. (N.T.)

^b Com doze frequentadores do bar, a mediana seria o ponto médio entre a renda do sujeito sentado no sexto banco e a renda do sujeito sentado no sétimo banco. Como ambos ganham US\$35 mil, a mediana é US\$35 mil. Se um ganhasse US\$35 mil e outro US\$36 mil, a mediana para o grupo todo seria US\$35,5 mil.

^c Termo popularizado pelo economista George Akerlof, num estudo de 1970. O termo se refere ao que ocorreu com o mercado de carros usados, que por um tempo ficou entregue a negociantes sem escrúpulos que vendiam apenas carros usados problemáticos, conhecidos como “limões”, na gíria local. Esse seria um bom exemplo para ilustrar o conceito de informação assimétrica. (N.T.)

^d Informação atualizada da produção: descobriu-se que quase todas as impressoras defeituosas estavam sendo fabricadas numa unidade em Kentucky, onde os operários haviam retirado partes da linha de montagem para construir uma destilaria de bourbon. Pelo visto, a qualidade das impressoras ali produzidas estava sendo comprometida tanto pelo baixo desempenho dos empregados perpetuamente bêbados quanto pelas peças faltantes ao acaso na linha de montagem.

^e É incrível: esse sujeito era um dos dez com renda anual de US\$35 mil que estavam sentados nas banquetas do bar quando Bill Gates entrou com seu papagaio. Vai entender!

^f Lembramos que nos Estados Unidos parte da renda pessoal é tributada pelos estados. (N.T.)