

Introdução à Ciência dos Dados

Aula 03 – Teorema Central do Limite

Sumário

- Revisão de probabilidade
- Histograma
- Funções de distribuição
- População x Amostra
- Teorema Central do Limite

Revisão: Probabilidade

- Variável aleatória
- Análise Frequentista
- Histograma / PDF
- CDF / CCDF

Revisão: Probabilidade

- Variável aleatória (exemplos de V.A. discretas)
 - Número de bits com erro transmitidos em um canal de comunicação
 - Número de acessos por segundo a um servidor
 - Atraso médio de um pacote de rede
 - Quantidade de usuários assistindo *Black Mirror* simultaneamente em Florestal
 - Quantidade de buscas por “ciência de dados” no Google por minuto
 - Número de curtidas por dia no *Instagram* para um usuário qualquer
 - Número de clientes por dia que compraram fralda e cerveja em um supermercado durante um ano
 - Número de novos casos de COVID-19 confirmados no Brasil por dia

Revisão: Probabilidade

- Variável aleatória (exemplos de V.A. discretas {espaço amostral})
 - Número de bits com erro transmitidos em um canal de comunicação {0,1,2,3,4,5,6,7,8,...}
 - Número de acessos por segundo a um servidor {0,1,2,3,4,...}
 - Atraso médio de um pacote de rede {0ms,1ms,2ms,3ms,4ms,...}
 - Quantidade de usuários assistindo *Black Mirror* simultaneamente em Florestal {0,1,2,3,4,...,5.000}
 - Quantidade de buscas por “ciência de dados” no Google por minuto {0,1,2,3,4,...}
 - Número de curtidas por dia no *Instagram* para um usuário qualquer {0,1,2,3,4,...}
 - Número de clientes por dia que compraram fralda e cerveja em um supermercado durante um ano {0,1,2,3,4,...}
 - Número de novos casos de COVID-19 confirmados no Brasil por dia {0,1,2,3,....}

Revisão: Probabilidade

- Variável aleatória
 - Pode assumir valores do seu espaço amostral com uma probabilidade de assumir cada valor
 - Probabilidade é um valor numérico que indica a chance/eventualidade/possibilidade de um evento acontecer

Mas quais probabilidades são atribuídas a cada elemento do espaço amostral??

Revisão: Probabilidade

- Variável aleatória

Mas quais probabilidades são atribuídas a cada elemento do espaço amostral??

- **Clássica**: conhecimento prévio, eventos igualmente prováveis
- **Subjetiva**: intuição ou palpite pessoal
- **Frequentista**: dados históricos, experimentos repetidos, frequência relativa

Revisão: Probabilidade

- Variável aleatória

Mas quais probabilidades são atribuídas a cada elemento do espaço amostral??


- **Clássica:** conhecimento prévio, eventos igualmente prováveis
- **Subjetiva:** intuição ou palpite pessoal
- **Frequentista:** dados históricos, experimentos repetidos, frequência relativa

Revisão: Probabilidade

- Histograma (PDF)
 - Representação gráfica da distribuição de frequências de um conjunto de dados
 - Pode ser por valores absolutos ou frequências relativas
 - Pode separar os valores possíveis em classes para dados contínuos ou discretos
 - **Observação:** existem diferenças em conceitos e nomenclatura se V.A. é discreta ou contínua. Porém, isso é irrelevante para o conteúdo da disciplina. O importante é saber interpretar um histograma ou função de densidade

Revisão: Probabilidade

- Histograma





Revisão: Probabilidade

- Função de Distribuição Acumulada (CDF)
 - Mapeia o valor ao seu ranking de percentil
 - X é um valor possível da V.A.
 - $CDF(X)$ indica a fração de valores menores ou iguais a X


Revisão: Probabilidade

- Função de Distribuição Acumulada (CDF)




Revisão: Probabilidade

- Função de Distribuição Acumulada (CDF)




Revisão: Probabilidade

- Função de Distribuição Acumulada Complementar (CCDF)
 - Às vezes, é mais importante saber a probabilidade de uma V.A. ser **maior que** algum valor
 - Ex. Número de likes, Taxa de Acerto, Número de usuários simultâneos
 - CCDF é $(1 - \text{CDF})$



Revisão: Probabilidade


- PDF x CDF x CCDF



PDF, CDF, and CCDF for the standard normal distribution.

Revisão: Probabilidade

- População x Amostra



Teorema Central do Limite

- Conclusões abrangentes e poderosas com base em dados relativamente escassos
 - Eleições, defeitos em um lote de fabricação de um produto, eficiência de remédios, alimentos contaminados,....
- De onde vem esse extraordinário poder de generalização?

Teorema Central do Limite

- Exemplo (Maratona)
 - Maratona na sua cidade, com corredores de todo o mundo
 - Corredores fazem *check-in* e são distribuídos **aleatoriamente** em vários ônibus com capacidade para 60 pessoas para irem ao ponto de partida
 - Infelizmente, um desses ônibus se perde no caminho
 - Você se voluntaria para ajudar a encontrar o ônibus

Teorema Central do Limite

- Exemplo (Maratona)
 - Ao sair de casa, você se depara com um ônibus estragado e pensa: “Serei o herói da cidade”

Teorema Central do Limite

- Exemplo (Maratona)
 - Ao sair de casa, você se depara com um ônibus estragado e pensa: “Serei o herói da cidade”
 - Porém, ao observar os passageiros, você fica com dúvida

Teorema Central do Limite

- Exemplo (Maratona)
 - Ao sair de casa, você se depara com um ônibus estragado e pensa: “Serei o herói da cidade”
 - Porém, ao observar os passageiros, você fica com dúvida
 - Os passageiros estão acima do peso, e você estima uma média de 100Kg entre eles
 - Pergunta: esse ônibus é o de corredores que ficou perdido??

Teorema Central do Limite

- Exemplo (Maratona)
 - Ao sair de casa, você se depara com um ônibus estragado e pensa: “Serei o herói da cidade”
 - Porém, ao observar os passageiros, você fica com dúvida
 - Os passageiros estão acima do peso, e você estima uma média de 100Kg entre eles
 - Pergunta: esse ônibus é o de corredores que ficou perdido??
 - Praticamente certeza que não!! Dificilmente um grupo aleatório de corredores de maratona será totalmente constituído de corredores tão pesados

Teorema Central do Limite

- Princípio do teorema central do limite
 - **Uma amostra grande, adequadamente escolhida, remeterá à população da qual foi retirada**
 - **Haverá variação de uma amostra para outra, mas a probabilidade de que qualquer amostra se desvie enormemente da população é muito baixa**

Teorema Central do Limite

- Princípio do teorema central do limite
 - Exemplo (Maratona): várias pessoas acima de 100Kg correm maratonas. Porém, a grande maioria são de pessoas mais magras. Portanto, a chance de que aleatoriamente um ônibus tenha sido preenchido com várias pessoas acima do peso é muito, mas muito reduzida.
 - Mais adiante iremos quantificar a probabilidade de estarmos certos ou errados

Teorema Central do Limite

1. Se tivermos informações detalhadas sobre alguma população, podemos fazer inferências sobre qualquer amostra adequadamente extraída
 - Ex. Diretor (todos os alunos) x MEC (amostra)
2. Se tivermos informações detalhadas sobre uma amostra extraída adequadamente, podemos fazer inferências sobre a população da qual a amostra foi retirada
 - Ex. MEC (amostra)

Observação: se (1) é verdadeiro, (2) também precisa ser. Se uma amostra se parece com uma população da qual é extraída, também deve ser verdade que a população se pareça com a amostra.

Teorema Central do Limite

3. Se tivermos dados que descrevem uma amostra, e dados sobre uma população, podemos inferir se a amostra pode ou não ter sido tirada da população
 - Ex. Ônibus da maratona
4. Se tivermos informações detalhadas sobre duas amostras, podemos inferir se ambas foram provavelmente tiradas ou não da mesma população
 - Ex. Ônibus da maratona x Ônibus de competição de pizza

Teorema Central do Limite

- Ok, entendemos o conceito intuitivo
- Mas qual o grau de confiança que temos em fazer tais inferências sobre alguma amostra?

Teorema Central do Limite

- Ok, entendemos o conceito intuitivo
- Mas qual o grau de confiança que temos em fazer tais inferências sobre alguma amostra?

Vamos responder a essa pergunta nos próximos slides

Teorema Central do Limite

- População (maratonistas)
- Amostras (ônibus de maratonistas)
- Cada amostra (ônibus possui uma média)
- Várias amostras (vários ônibus de maratonistas): uma lista de médias das amostras
- A maioria das médias das amostras estará muito próxima da média da população
 - Algumas mais altas, outras mais baixas, e poucas significativamente mais altas ou mais baixas

Teorema Central do Limite


- População (maratonistas)
- Amostras (ônibus de maratonistas)
- Cada amostra (ônibus possui uma média)
- Várias amostras (vários ônibus de maratonistas): uma lista de médias das amostras
- A maioria das médias das amostras estará muito próxima da média da população
 - Algumas mais altas, outras mais baixas, e poucas significativamente mais altas ou mais baixas

O teorema central do limite nos diz que as médias das amostras estarão distribuídas em torno da média da população aproximadamente numa distribuição Normal.

Isso é verdadeiro independente da distribuição da população


Teorema Central do Limite

- Exemplo: renda familiar nos EUA




Teorema Central do Limite

- Exemplo: renda familiar nos EUA




Teorema Central do Limite

- Exemplo: renda familiar nos EUA




Teorema Central do Limite

- Exemplo: renda familiar nos EUA



Teorema Central do Limite

- Exemplo: renda familiar nos EUA



Teorema Central do Limite

- Exemplo: renda familiar nos EUA
 - Suponha que peguemos **uma** amostra aleatória de 1000 famílias

Teorema Central do Limite

- Exemplo: renda familiar nos EUA
 - Suponha que peguemos **uma** amostra aleatória de 1000 famílias
 - Se a amostra for representativa, se parecerá muito com a população inteira
 - Teremos na amostra famílias de todas as rendas, na mesma proporção da população
 - A média da amostra não será exatamente a média da população, mas não deve ser exageradamente diferente
 - Porém, para termos mais assertividade acerca da população, é mais apropriado pegar várias amostras

Teorema Central do Limite

- Exemplo: renda familiar nos EUA
 - Suponha que peguemos **várias** amostras aleatórias de 1000 famílias

Teorema Central do Limite

- Exemplo: renda familiar nos EUA
 - Suponha que peguemos **várias** amostras aleatórias de 1000 famílias
 - As médias das amostras vão se aglomerar em torno da média da população de US\$70,9K
 - Algumas médias de amostras serão mais altas, outras mais baixas
 - Podemos ter amostras com médias muito altas ou muito baixas, mas essas amostras serão raras

Teorema Central do Limite

- Exemplo: renda familiar nos EUA
 - Suponha que peguemos **várias** amostras aleatórias de 1000 famílias
 - As médias das amostras vão se aglomerar em torno da média da população de US\$70,9K
 - Algumas médias de amostras serão mais altas, outras mais baixas
 - Podemos ter amostras com médias muito altas ou muito baixas, mas essas amostras serão raras
 - **As médias das amostras formarão uma distribuição Normal em torno da média da população**
 - Quanto maior a quantidade de amostras, mais próxima a distribuição das médias estará da distribuição Normal
 - Quanto maior o tamanho de cada amostra, mais compacta estará a distribuição das médias (Pelo menos 30 pela lei dos grandes números)


Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Distribuição desviada para a direita (mais fácil ter excesso que falta de peso)
 - Média da população: 162 libras

Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Distribuição desviada para a direita (mais fácil ter excesso que falta de peso)
 - Média da população: 162 libras


100 médias de amostras, $n = 100$



Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Distribuição desviada para a direita (mais fácil ter excesso que falta de peso)
 - Média da população: 162 libras

100 médias de amostras, $n = 100$



Teorema Central do Limite

- Para podermos quantificar uma inferência, precisamos de mais um conceito: **Erro Padrão**
 - Mede a dispersão das médias das amostras
 - O erro padrão é o desvio padrão das médias de amostras
 - Não confunda com o desvio padrão da população subjacente
 - Um erro padrão grande significa que as médias das amostras estão esparsamente espalhadas em torno da média da população
 - Um erro padrão pequeno significa que as médias das amostras estão relativamente aglomeradas em torno da média


Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Média da população: 162 libras




Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Média da população: 162 libras



Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Média da população: 162 libras



Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Média da população: 162 libras




Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Média da população: 162 libras



Teorema Central do Limite

- Exemplo: pesos de milhares de adultos
 - Média da população: 162 libras



Teorema Central do Limite

- Propriedades do erro padrão
 - Médias de amostras terão uma aglomeração mais “compacta” (menos dispersa) em torno da média da população à medida que o tamanho da amostra fica maior
 - $n=100$ x $n=20$
 - Médias de amostras se aglomeram menos (mais dispersas) em torno da média da população quando a população adjacente é mais dispersa
 - Mulheres x Toda a população

Teorema Central do Limite

- Propriedades do erro padrão

- Erro padrão =

$$\frac{s}{\sqrt{n}}$$

- onde **s** é o desvio padrão da população e **n** é o tamanho da amostra
 - o erro padrão será grande quando o desvio padrão da população adjacente for grande (numerador)
 - o erro padrão diminui à medida que o tamanho da amostra aumenta (denominador)
 - para amostras grandes onde não se conhece o desvio padrão da população, pode-se assumir que o desvio padrão da amostra está razoavelmente próximo do desvio padrão da população

Teorema Central do Limite

- O que fazemos com isso tudo?




Teorema Central do Limite

- Médias das amostras distribuídas Normalmente
 - **68%** das médias das amostras se situam dentro de **um** erro padrão em relação à média da população
 - **95%** das médias das amostras se situam dentro de **dois** erros padrões em relação à média da população
 - **99,7%** das médias das amostras se situam dentro de **três** erros padrões em relação à média da população

Teorema Central do Limite

- Médias das amostras distribuídas Normalmente



Teorema Central do Limite

- Exemplo: ônibus de maratonistas
 - População: média 74 Kg e desvio padrão 16
 - Um ônibus se perde, e a média de peso de seus 62 passageiros é de 88 Kg
 - **Erro padrão:** $16/\sqrt{62} = 16/7,9 = 2,02$
 - Diferença entre a média da amostra (88Kg) e a média da população (74Kg) é 14 Kg
 - $14/2,02 = 6,9 > 3$ erros padrões ($3 \times 2,02 = 6,06$)
 - Sabemos pelo teorema central do limite que 99,7% de todas as médias de amostras se situam dentro de três erros padrões da média da população

Teorema Central do Limite

- Exemplo: ônibus de maratonistas
 - População: média 74 Kg e desvio padrão 16
 - Um ônibus se perde, e a média de peso de seus 62 passageiros é de 88 Kg
 - **Erro padrão:** $16/\sqrt{62} = 16/7,9 = 2,02$
 - Diferença entre a média da amostra (88Kg) e a média da população (74Kg) é 14 Kg
 - $14/2,02 = 6,9 > 3$ erros padrões ($3 \times 2,02 = 6,06$)
 - Sabemos pelo teorema central do limite que 99,7% de todas as médias de amostras se situam dentro de três erros padrões da média da população

É extremamente improvável que esse ônibus
seja de maratonistas

Teorema Central do Limite

1) Se você obteve amostras grandes e representativas de qualquer população, as médias dessas amostras serão distribuídas normalmente em torno da média da população (independente da distribuição da população adjacente)

Teorema Central do Limite

2) A maioria das médias de amostras estará razoavelmente perto da média da população. O erro padrão é que define “razoavelmente perto”

Teorema Central do Limite

3) O teorema central do limite nos diz a probabilidade de que a média de uma amostra se situe dentro de certa distância da média da população. É relativamente improvável que uma média de amostras se situe a mais de dois erros padrões em relação à média da população, e bastante improvável que se situe a três ou mais erros padrões

Teorema Central do Limite

4) Quanto menos provável for um resultado observado ao acaso, mais confiantes podemos estar em presumir que haja outro fator em jogo

Teorema Central do Limite

CASO REAL – Instalação de Apps

Apps instalados de 87.904 usuários


Qual o percentual de usuários que possui Instagram?

Teorema Central do Limite

CASO REAL – Instalação de Apps


Apps instalados de 87.904 usuários

Percentual de usuários com Instagram?



10 amostras de tamanho 10

--- Real
--- Amostral




100 amostras de tamanho 30

Teorema Central do Limite

CASO REAL – Instalação de Apps


Apps instalados de 87.904 usuários

Percentual de usuários com WhatsApp?



10 amostras de tamanho 10

--- Real
--- Amostral




100 amostras de tamanho 30

Teorema Central do Limite

CASO REAL – Instalação de Apps


Apps instalados de 87.904 usuários

Percentual de usuários com Zoom?



10 amostras de tamanho 10

--- Real
--- Amostral




100 amostras de tamanho 30

Teorema Central do Limite

CASO REAL – Instalação de Apps


Apps instalados de 87.904 usuários

Percentual de usuários com Netflix?



10 amostras de tamanho 10

--- Real
--- Amostral



100 amostras de tamanho 30

Sugestão de Estudo

- Capítulo 8 (Estatística, Charles Wheelan)
- Teorema do Limite Central: Minions
- Exemplos