

8. O teorema do limite central

O “LeBron James” da estatística

ÀS VEZES, a estatística parece quase mágica. Somos capazes de tirar conclusões abrangentes e poderosas de dados relativamente escassos. De algum modo podemos adquirir uma percepção significativa de uma eleição presidencial meramente falando ao telefone com mil eleitores americanos. Podemos testar cem peitos de frango em busca de salmonela numa fábrica de processamento de aves e concluir com base apenas nessa amostra que a fábrica inteira é segura ou insegura. *De onde vem esse extraordinário poder de generalização?*

Grande parte dele vem do teorema do limite central, que é o LeBron James^a da estatística – se LeBron também fosse um supermodelo, um professor de Harvard e o ganhador do Prêmio Nobel da Paz. O teorema do limite central é a “fonte de poder” para muitas das atividades estatísticas que envolvem o uso de uma amostra para fazer inferências acerca de uma população grande (como uma pesquisa de intenção de voto ou teste de salmonela). Esses tipos de inferência podem parecer místicos; na verdade, são apenas uma combinação de duas ferramentas que já exploramos: probabilidade e amostragem adequada. Antes de mergulhar na mecânica do teorema do limite central (que não é absolutamente complicada), eis um exemplo para lhe dar a intuição geral.

Suponha que você more numa cidade onde esteja havendo uma maratona. Corredores de todo o mundo estarão competindo, o que significa que muitos deles não falam inglês. A logística requer que os corredores se apresentem na manhã do dia da corrida, após o que são aleatoriamente colocados em ônibus que os levam até a linha de largada. Infelizmente, um desses ônibus se perde a caminho da corrida. (Tudo bem, você vai ter que imaginar que ninguém tem telefone celular e que o motorista não tem um GPS no veículo; a menos que você queira fazer um montão de matemática neste momento, apenas aceite isso.) Como um líder comunitário da cidade, você se junta à equipe de busca.

Por puro acaso, você dá de cara com um ônibus enguiçado perto da sua casa com um grupo enorme de passageiros internacionais infelizes, nenhum dos quais fala inglês. Deve ser o ônibus perdido! Você será um herói! Só que uma dúvida paira no ar... os passageiros desse ônibus são, bem, muito grandes. Com base numa rápida olhada, você estima que o peso médio desse grupo de passageiros deve ser mais de cem quilos. Não há como um grupo aleatório de corredores de maratona ser totalmente constituído de corredores tão pesados. Você manda uma mensagem para o quartel-general da busca: “Acho que é o ônibus errado. Continuem procurando.”

Uma análise adicional confirma a sua impressão inicial. Quando chega um tradutor, você descobre que esse ônibus quebrado dirigia-se ao Festival Internacional da Salsicha, que também está acontecendo na sua cidade no mesmo fim de semana. (Em nome da verossimilitude, é inteiramente possível que os participantes de um festival da salsicha também estejam vestindo

calças de moletom.)

Parabéns. Se você consegue entender como alguém que dê uma rápida olhada nos pesos dos passageiros num ônibus pode inferir que provavelmente não estão a caminho da linha de largada de uma maratona, então você agora entende a ideia básica do teorema do limite central. O resto é apenas destrinchar os detalhes. E se você entende o teorema do limite central, a maioria das formas de inferência estatística parecerá relativamente intuitiva.

O princípio essencial subjacente ao teorema do limite central é que uma amostra grande, adequadamente escolhida, remeterá à população da qual foi retirada. É claro que haverá variação de uma amostra para outra (por exemplo, cada ônibus que se dirige à linha de largada da maratona terá uma mistura de passageiros ligeiramente diferente), mas a probabilidade de que qualquer amostra se desvie enormemente da população subjacente é muito baixa. Essa lógica é o que possibilitou seu julgamento instantâneo quando você subiu no ônibus enguiçado e viu a média da barriga dos passageiros a bordo. Um monte de pessoas gordas corre maratonas, provavelmente há centenas de pessoas que pesam mais de cem quilos em qualquer corrida. Mas a maioria dos corredores de maratona é relativamente magra. Logo, a probabilidade de que tantos dos corredores mais pesados estejam aleatoriamente num mesmo ônibus é muito, muito reduzida. Você pôde concluir, com um grau razoável de confiança, que esse não era o ônibus perdido da maratona. Sim, você podia estar errado, mas a probabilidade nos diz que a maioria das vezes você teria estado certo.

Essa é a intuição básica por trás do teorema do limite central. Quando adicionamos alguma parafernália estatística, podemos quantificar a probabilidade de você estar certo ou errado. Por exemplo, poderíamos calcular que, num campo de 10 mil maratonistas com peso médio de setenta quilos, há menos de uma chance em cem de que uma amostra aleatória de sessenta desses corredores (nosso ônibus perdido) tenha um peso médio de cem quilos ou mais. Por enquanto, vamos nos ater à intuição; haverá tempo de sobra para cálculos mais adiante. O teorema do limite central nos possibilita fazer as seguintes inferências, todas elas a serem exploradas em maior profundidade no próximo capítulo:

1. Se tivermos informações detalhadas sobre alguma população, então podemos fazer inferências poderosas sobre qualquer amostra adequadamente extraída dessa população. Por exemplo, imagine que o diretor de um colégio tenha informações detalhadas sobre os resultados de testes padronizados para todos os alunos desse colégio (média, desvio padrão etc.). Essa é a população relevante. Agora imagine que um burocrata do distrito escolar chegue na próxima semana para passar um teste padronizado similar para cem alunos escolhidos ao acaso. O desempenho desses cem alunos, a amostra, será usada para avaliar a performance do colégio como um todo.

Quanta confiança o diretor pode ter de que o desempenho dos cem alunos escolhidos de maneira aleatória irá refletir acuradamente como todo o corpo discente tem se saído em testes padronizados similares? Bastante. Segundo o teorema do limite central, o resultado médio do teste para uma amostra aleatória de cem alunos em geral não se desviará acentuadamente do resultado médio dos testes para a escola toda.

2. Se tivermos informações detalhadas sobre uma amostra extraída de modo adequado (média e desvio padrão), podemos fazer inferências surpreendentemente acuradas sobre a população

da qual a amostra foi retirada. Isso é essencialmente trabalhar no sentido inverso do exemplo acima, colocando-nos no lugar do burocrata do distrito escolar que está avaliando várias escolas no distrito. Ao contrário do diretor do colégio, esse burocrata não tem os (ou não confia nos) dados dos resultados de testes padronizados que o diretor tem para todos os alunos de um colégio específico, que é a população relevante. Em vez disso, ele administrará um teste similar próprio para uma amostra aleatória de cem alunos em cada escola.

Será que esse administrador pode estar razoavelmente seguro de que o desempenho de qualquer escola como um todo possa ser avaliada justamente com base em resultados de testes de uma amostra de apenas cem alunos desse colégio? Sim. O teorema do limite central nos diz que uma amostra grande em geral não se desviará acentuadamente da população subjacente – o que quer dizer que os resultados da amostra (as notas dos cem alunos escolhidos ao acaso) representam bem os resultados da população total (o corpo de alunos de uma escola específica). É claro que é assim que as pesquisas de opinião funcionam. Uma pesquisa metodologicamente sólida de 1.200 americanos pode nos dizer muita coisa sobre como o país todo está pensando.

Pense nisso: se a afirmação n.1 acima é verdadeira, a n.2 também precisa ser – e vice-versa. Se uma amostra geralmente se parece com a população da qual é extraída, também deve ser verdade que a população normalmente será parecida com uma amostra tirada dessa população. (Se as crianças em geral se parecem com os pais, os pais geralmente também se parecem com os filhos.)

3. Se tivermos dados que descrevem uma amostra particular, e dados sobre uma população particular, podemos inferir se a amostra é consistente ou não com uma amostra com probabilidade de ter sido tirada dessa população. Esse é o exemplo do ônibus perdido descrito no começo do capítulo. Sabemos o peso médio (mais ou menos) dos participantes de uma maratona. E sabemos o peso médio (mais ou menos) dos passageiros do ônibus quebrado. O teorema do limite central nos possibilita calcular a probabilidade de que uma amostra específica (as pessoas rotundas no ônibus) tenha sido tirada de uma dada população (os maratonistas). Se essa probabilidade é baixa, então podemos concluir com alto grau de confiança que a amostra não foi tirada da população em questão (por exemplo, as pessoas nesse ônibus não se parecem com um grupo de corredores de maratona indo para a linha de largada).
4. Por fim, se soubermos as características subjacentes de duas amostras, podemos inferir se ambas foram provavelmente tiradas ou não da mesma população. Voltemos ao nosso exemplo (cada vez mais absurdo) do ônibus. Sabemos agora que há uma maratona acontecendo na cidade, bem como um Festival Internacional da Salsicha. Imagine que ambos os grupos tenham milhares de participantes e que ambos os grupos estejam em ônibus, todos carregados com amostras aleatórias, seja de maratonistas ou de amantes de salsicha. Imagine também que dois ônibus sofram uma colisão. (Já reconheci que o exemplo é absurdo, portanto, simplesmente continue lendo.) Na sua função de líder comunitário, você chega à cena e recebe a incumbência de determinar se os dois ônibus iam ou não para o mesmo evento (festival de salsicha ou maratona). Milagrosamente, ninguém em nenhum dos ônibus fala inglês, mas os paramédicos lhe fornecem informações detalhadas sobre os pesos

dos passageiros em cada ônibus.

A partir disso, você pode inferir se os dois ônibus iam provavelmente para o mesmo evento ou para dois eventos distintos. Mais uma vez, pense nisso de maneira intuitiva. Suponha que o peso médio dos passageiros de um dos ônibus seja 72 quilos, com um desvio padrão de cinco quilos (o que significa que uma alta proporção dos passageiros pesa entre 67 e 77 quilos). Agora suponha que os passageiros no segundo ônibus tenham um peso médio de 95 quilos com um desvio padrão de dez quilos (o que quer dizer que uma alta proporção dos passageiros pesa entre 85 e 105 quilos). Esqueça fórmulas estatísticas por um instante e apenas use a lógica: parece provável que os passageiros desses dois ônibus tenham sido retirados aleatoriamente da mesma população?

Não. Parece muito mais provável que um ônibus esteja cheio de maratonistas e o outro cheio de amantes de salsicha. Além da diferença na média de peso dos dois ônibus, você pode ver também que a variação de pesos *entre* os dois ônibus é muito grande em comparação com a variação de pesos *dentro* de cada ônibus. Os sujeitos que pesam um desvio padrão acima da média no ônibus “magro” têm 77 quilos, que é menos do que pesam os sujeitos com um desvio padrão abaixo da média no “outro” ônibus (85 quilos). Esse é um sinal revelador (tanto estatística como logicamente) de que as duas amostras provavelmente vieram de populações distintas.

Se tudo isso faz sentido intuitivo, então você percorreu 93,2% do caminho para entender o teorema do limite central.^b Precisamos ir um passo adiante para conferir uma solidez técnica à intuição. Obviamente, quando você meteu a cabeça dentro do ônibus quebrado e viu um grupo de gente gorda de moletom, teve um “palpite” de que não eram maratonistas. O teorema do limite central nos permite ir além desse palpite e atribuir um grau de confiança à sua conclusão.

Por exemplo, alguns cálculos básicos me possibilitam concluir que 99 vezes em cem o peso médio de qualquer ônibus de maratonistas aleatoriamente escolhido estará dentro de quatro quilos do peso médio de todo o campo de maratonistas. É isso que dá solidez estatística para o meu palpite quando me deparo com o ônibus quebrado. Esses passageiros têm um peso médio que é dez quilos maior que o peso médio dos maratonistas, algo que só deveria ocorrer por acaso em menos de uma vez em cem. Como resultado, posso rejeitar a hipótese de que esse seja o ônibus da maratona perdido com 99% de confiança – o que significa que devo esperar que minha inferência esteja correta 99 vezes em cem.

E, sim, a probabilidade sugere que em média estarei *errado* uma vez em cem.

Esse tipo de análise provém inteiramente do teorema do limite central, que, do ponto de vista estatístico, tem poder e elegância semelhantes a LeBron James. De acordo com o teorema do limite central, as médias das amostras para qualquer população estarão distribuídas aproximadamente como uma distribuição normal em torno da média da população. Aguarde um momento enquanto deslindamos essa afirmação.


1. Suponha que tenhamos uma população, como nosso campo de maratonistas, e estejamos interessados nos pesos de seus membros. Qualquer amostra de corredores, tal como um ônibus de sessenta participantes, terá uma média.

- Se pegarmos repetidamente diversas amostras, por exemplo, grupos aleatórios de sessenta
2. corredores, então cada uma dessas amostras terá seu próprio peso médio. Essas são as médias das amostras.
 3. A maioria das médias das amostras estará muito próxima da média da população. Algumas serão um pouco mais altas. Outras serão um pouco mais baixas. Por simples questão de acaso, muito poucas serão significativamente mais altas que a média da população, e muitas poucas serão significativamente mais baixas.

Coloque uma música como trilha sonora, porque é aqui que tudo se junta num poderoso crescendo...

4. O teorema do limite central nos diz que as médias das amostras estarão distribuídas em torno da média da população aproximadamente numa distribuição normal. A distribuição normal, como você deve se lembrar do Capítulo 2, é a distribuição em forma de sino (por exemplo, alturas de homens adultos) na qual 68% das observações jazem dentro de um desvio padrão da média, 95% jazem dentro de dois desvios padrões, e assim por diante.
5. Tudo isso será verdadeiro independentemente do aspecto da distribuição da população subjacente. A população da qual as amostras estão sendo tiradas não precisa necessariamente ter uma distribuição normal para que as médias das amostras estejam distribuídas normalmente.

Pensemos em alguns dados reais, digamos, a distribuição de renda familiar nos Estados Unidos. A renda familiar não é distribuída normalmente no país; ao contrário, tende a sofrer desvio para a direita. Nenhuma família pode ter renda inferior a US\$0 num dado ano, de modo que esse é o limite inferior para a distribuição. Ao mesmo tempo, um pequeno grupo de famílias pode ter rendas anuais estarrecedoramente altas – centenas de milhões ou mesmo bilhões de dólares em alguns casos. Como resultado, seria de esperar que a distribuição de rendas familiares tenha uma longa cauda para a direita – algo mais ou menos assim:



A mediana da renda familiar nos Estados Unidos é aproximadamente US\$51,9 mil; a média da renda familiar é de US\$70,9 mil.¹ (Pessoas como Bill Gates puxam a renda familiar média para a direita, exatamente como aconteceu quando ele entrou no bar no Capítulo 2.) Agora suponha que peguemos uma amostra aleatória de mil famílias americanas e colhamos informações sobre suas rendas anuais. Com base na informação acima, e no teorema do limite central, o que podemos inferir dessa amostra?

Muita coisa, como se verá. Primeiro de tudo, nosso melhor palpite sobre qual será a média de qualquer amostra é a média da população da qual ela é tirada. A principal ideia de uma amostra representativa é que ela tenha a aparência da população subjacente. Uma amostra extraída adequadamente se parecerá, em média, com os Estados Unidos. Haverá administradores de fundos hedge, gente sem teto, policiais e todo tipo de pessoas – tudo aproximadamente na proporção da sua frequência na população. Portanto, devemos esperar que a renda familiar média para uma amostra representativa de mil famílias americanas seja em torno de US\$70,9 mil. Será exatamente isso? Não. Tampouco deve ser exageradamente diferente.

Se pegássemos múltiplas amostras de mil famílias, seria de esperar que as diferentes médias das amostras se aglomerassem em torno da média da população, US\$70,9 mil. Esperaríamos que algumas médias fossem mais altas, outras mais baixas. Poderíamos ter uma amostra de mil famílias com uma renda familiar média de US\$427 mil? Com certeza, isso é possível – mas bastante improvável. (Lembre-se, nossa metodologia de amostragem é sólida, não estamos conduzindo uma pesquisa no estacionamento do Greenwich Country Club.) Também é muito improvável que uma amostra adequada de mil famílias americanas tenha uma renda média de US\$8 mil.

Tudo isso é lógica básica. O teorema do limite central nos possibilita ir um passo além descrevendo a distribuição esperada dessas diversas médias de amostras conforme elas se aglutinam em torno da média da população. Especificamente, as médias das amostras formarão

uma distribuição normal em volta da média da população, que no caso é de US\$70,9 mil. Lembre-se, o formato da distribuição da população subjacente não importa. A distribuição de renda familiar nos Estados Unidos é bastante desviada, *mas a distribuição das médias das amostras não terá desvios*. Se pegarmos cem amostras diferentes, cada uma de mil famílias, e pusermos nossos resultados num gráfico, esperamos que as médias dessas amostras formem a familiar distribuição “em forma de sino” ao redor de US\$70,9 mil.

Quanto maior a quantidade de amostras, mais próxima a distribuição de suas médias estará da distribuição normal. E quanto maior o tamanho de cada amostra, mais compacta será essa distribuição. Para testar esse resultado, façamos um experimento divertido com dados reais dos pesos de americanos reais. A Universidade de Michigan conduz um estudo longitudinal chamado Americans’ Changing Lives, que consiste em observações detalhadas sobre milhares de adultos americanos, inclusive seus pesos. A distribuição dos pesos é ligeiramente desviada para a direita, porque é biologicamente mais fácil ter cinquenta quilos de excesso de peso do que cinquenta quilos de falta de peso. O peso médio para todos os adultos do estudo é de 74 quilos.

Usando um programa básico de estatística, podemos mandar o computador pegar uma amostra aleatória de cem indivíduos dos dados do Changing Lives. Na verdade, podemos fazer isso repetidas vezes para ver como os resultados se encaixam na previsão do teorema do limite central. Eis um gráfico da distribuição das médias de cem amostras (arredondadas para o quilo mais próximo) geradas aleatoriamente a partir dos dados do Changing Lives.



Quanto maior o tamanho da amostra e mais amostras forem tiradas, mais a distribuição das médias das amostras se aproximará da curva normal. (Como regra prática, o tamanho da amostra precisa ser de pelo menos trinta para validar o teorema do limite central.) Isso faz sentido. Uma amostra maior tem menos probabilidade de ser afetada por uma variação aleatória. Uma amostra de duas pessoas pode ser bastante distorcida se uma delas for particularmente grande ou pequena. Em contraste, uma amostra de quinhentas não será afetada indevidamente por algumas pessoas particularmente grandes ou pequenas.

Estamos agora bem próximos de tornar realidade todos os nossos sonhos estatísticos. As médias das amostras estão distribuídas aproximadamente como uma curva normal, conforme descrito antes. O poder de uma distribuição normal deriva do fato de sabermos aproximadamente que proporção de observações estará dentro de um desvio padrão acima ou abaixo da média (68%); que proporção das observações estará dentro de dois desvios padrões acima ou abaixo da média (95%); e assim por diante. Isso é algo muito poderoso.


Anteriormente neste capítulo, ressalttei que podíamos inferir de modo intuitivo que um ônibus carregado de passageiros com um peso médio de onze quilos a mais que o peso médio de todos os maratonistas provavelmente não seria o ônibus de corredores perdido. Para quantificar essa intuição – ser capaz de dizer que a inferência estará correta em 95% das vezes, ou 99%, ou 99,9% –, precisamos apenas de mais um conceito técnico: o erro padrão.

O erro padrão mede a dispersão das médias das amostras. Quão próximas esperamos que as médias de amostras estejam da média da população? Aqui existe um potencial para confusão, pois agora introduzimos duas medidas diferentes de dispersão: o desvio padrão e o erro padrão. Eis o que você precisa lembrar para manter cada uma no seu lugar:


1. O desvio padrão mede a dispersão da população subjacente. Neste caso, poderia medir a dispersão dos pesos de todos os participantes no Estudo Cardíaco de Framingham, ou a dispersão em torno da média de todo o campo de maratonistas.
2. O erro padrão mede a dispersão das *médias das amostras*. Se tomarmos repetidas amostras de cem participantes do Estudo Cardíaco de Framingham, qual será o aspecto da dispersão dessas médias de amostras?
3. Eis aqui o que liga os dois conceitos: o erro padrão é o desvio padrão das médias de amostras! Não é bacana?

Um erro padrão grande significa que as médias das amostras estão esparsamente espalhadas em torno da média da população; um erro padrão pequeno significa que estão relativamente bem aglomeradas. Eis três exemplos reais dos dados do Changing Lives.


100 médias de amostras, $n = 20$



100 médias de amostras, $n = 100$



Apenas população feminina/100 médias de amostras, $n = 100$



A segunda distribuição, que tem um tamanho de amostra maior, tem uma aglomeração mais “compacta” em torno da média do que a primeira distribuição. O tamanho maior da amostra torna menos provável que sua média se desvie acentuadamente da média da população. O conjunto final de médias de amostras é tirado apenas de um subconjunto da população, as mulheres no estudo. Como os pesos das mulheres no conjunto de dados são menos difusos do que os pesos de todas as pessoas na população, é razoável que os pesos de amostras tiradas apenas entre as mulheres estejam menos dispersos que as amostras tiradas de toda a população do Changing Lives. (Essas amostras também estão aglomeradas em torno de uma média da população ligeiramente distinta, uma vez que o peso médio de todas as mulheres no estudo Changing Lives é diferente do peso médio da população total do estudo.)

O padrão que você viu acima vale para todos os casos em geral. Médias de amostras terão uma aglomeração mais “compacta” em torno da média da população à medida que o tamanho de cada amostra fica maior (por exemplo, as nossas médias de amostras estavam mais aglomeradas quando pegamos amostras de cem em vez de amostras de vinte). E as médias de amostras se aglomeram *menos* em torno da média da população quando a população subjacente é mais dispersa (por exemplo, as nossas médias de amostras para toda a população do Changing Lives estavam mais dispersas do que as médias de amostras apenas para as mulheres no estudo).

Se você acompanhou a lógica até aqui, então a fórmula para o erro padrão fluirá naturalmente.

$EP = \frac{s}{\sqrt{n}}$, onde s é o desvio padrão da população da qual é tirada a amostra e n é o tamanho da amostra. Mantenha a calma! Não deixe o surgimento de letras atrapalhar a sua intuição básica. O erro padrão será grande quando o desvio padrão da distribuição subjacente for grande. Uma amostra grande tirada de uma população muito dispersa também tem propensão a ser bastante dispersa; uma amostra grande de uma população fortemente aglomerada em torno da média também terá propensão a se aglomerar fortemente em torno da média. Se ainda estivermos examinando pesos, seria de esperar que o erro padrão para uma amostra tirada de toda a população do Changing Lives fosse maior que o erro padrão para uma amostra tirada apenas de homens na casa dos vinte anos. *É por isso que o desvio padrão (s) está no numerador.*

De maneira similar, seria de esperar que o erro padrão diminuísse à medida que o tamanho da amostra aumentasse, uma vez que amostras grandes são menos propensas à distorção por valores extremos. É por isso que o tamanho da amostra (n) está no denominador. (O motivo de pegarmos a raiz quadrada de n será deixado para um texto mais avançado; o importante aqui é a relação básica.)


No caso dos dados do Changing Lives, na realidade sabemos o desvio padrão da população; o que muitas vezes não é o caso. Para amostras grandes, podemos pressupor que o desvio padrão da amostra está razoavelmente próximo do desvio padrão da população.^c

Por fim, teremos a recompensa por tudo isso. Como as médias das amostras estão distribuídas normalmente (graças ao teorema do limite central), podemos mobilizar o poder da curva normal. Esperamos que aproximadamente 68% de todas as médias de amostras se situem dentro de um erro padrão em relação à média da população; 95% das médias de amostras se situarão dentro de dois erros padrões em relação à média da população; e 99,7% das médias de amostras

se situarão dentro de três erros padrões em relação à média da população.

Então retornemos a uma variação do nosso exemplo do ônibus perdido, só que agora podemos substituir a intuição por números. (O exemplo em si continuará sendo absurdo; o próximo capítulo terá uma porção de exemplos menos absurdos, do mundo real.) Suponha que o estudo Changing Lives tenha convidado todos os participantes a se reunir em Boston para um fim de semana de coleta de dados e folguedos. Os participantes são colocados ao acaso em ônibus e transportados entre os edifícios nas instalações de testes onde são pesados, medidos, cutucados, espetados, e assim por diante. Por incrível que pareça, um ônibus se perde, fato que é transmitido pelos noticiários locais. Mais ou menos nessa hora, você está voltando de carro do Festival da Salsicha quando vê um ônibus acidentado ao lado da estrada. Aparentemente, o ônibus se desviou para não atingir uma raposa selvagem atravessando a estrada, e todos os passageiros estão inconscientes, mas não seriamente feridos. (Preciso que eles não possam se comunicar para que o exemplo funcione, mas não quero que os ferimentos sejam muito perturbadores.) Os paramédicos na cena lhe informam que o peso médio dos 62 passageiros no ônibus é 88 quilos. Além disso, a raposa da qual o ônibus se desviou foi atingida de raspão e parece que teve apenas uma pata traseira quebrada.

Distribuição de frequência das médias de amostras



Felizmente, você conhece o peso médio e o desvio padrão para toda a população do Changing Lives, assim como você tem um conhecimento instrumental do teorema do limite central e sabe como prestar primeiros socorros a uma raposa selvagem. O peso médio para os participantes do Changing Lives é 74; o desvio padrão é dezesseis. A partir dessa informação, podemos calcular o erro padrão para uma amostra de 62 pessoas (o número de passageiros inconscientes no ônibus): $\frac{16}{\sqrt{62}} = \frac{16}{4}$, ou 4.

A diferença entre a média da amostra (74 quilos) e a média da população (88 quilos) é de catorze quilos, ou bem mais que três erros padrões. Sabemos pelo teorema do limite central que 99,7% de todas as médias de amostras se situam dentro de três erros padrões da média da população. Isso faz com que seja extremamente improvável que esse ônibus represente um grupo aleatório de participantes do Changing Lives. O seu dever como líder comunitário é ligar para os funcionários do estudo e avisar que aquele provavelmente não é o seu ônibus perdido, só

que agora você pode fornecer evidência estatística, e não só “um palpite”. Você informa aos caras do Changing Lives que rejeita a possibilidade de que aquele seja o ônibus perdido com um nível de confiança de 99,7%. E, já que está falando com pesquisadores, eles realmente entenderão a que você se refere.

A sua análise é posteriormente confirmada quando os paramédicos fazem exames de sangue com os passageiros do ônibus e descobrem que o nível de colesterol médio do grupo é cinco erros padrões acima do nível de colesterol médio dos participantes do estudo Changing Lives. Isso sugere, corretamente, como se verificará, que os passageiros inconscientes estão envolvidos com o Festival da Salsicha.

[Há um final feliz. Quando os passageiros do ônibus recuperam a consciência, os funcionários do estudo Changing Lives lhes oferecem aconselhamento sobre os perigos de uma dieta rica em gorduras saturadas, fazendo com que muitos deles adotem hábitos alimentares mais saudáveis para o coração. Entrementes, a raposa recuperou sua saúde numa reserva local de preservação da vida selvagem e depois foi solta de volta na natureza.]^d

Tentei me ater ao básico neste capítulo. Você deve observar que para que o teorema do limite central se aplique, os tamanhos das amostras precisam ser relativamente grandes (mais de trinta, como regra prática). Também necessitamos de uma amostra relativamente grande se vamos pressupor que o desvio padrão da amostra é aproximadamente o mesmo que o desvio padrão da população da qual é retirada. Há uma profusão de recursos estatísticos que podem ser aplicados quando tais condições não são atendidas – mas são todos meras cerejas do bolo (e talvez até mesmo apenas enfeites na cobertura do bolo). O “quadro principal” aqui é simples e poderosíssimo:

1. Se você obteve amostras grandes, aleatórias, de qualquer população, as médias dessas amostras serão distribuídas normalmente em torno da média da população (independentemente do aspecto da distribuição da população subjacente).
2. A maioria das médias de amostras estará razoavelmente perto da média da população; o erro padrão é o que define “razoavelmente perto”.
3. O teorema do limite central nos diz a probabilidade de que a média de uma amostra se situe dentro de certa distância da média da população. É relativamente improvável que uma média de amostra se situe a mais de dois erros padrões em relação à média da população, e bastante improvável que se situe a três ou mais erros padrões em relação à média da população.
4. Quanto menos provável for um resultado observado ao acaso, mais confiantes podemos estar em presumir que haja algum outro fator em jogo.

É basicamente isso que constitui a inferência estatística. O teorema do limite central é o que torna a maior parte possível. E até LeBron James ganhar tantos campeonatos da NBA quanto Michael Jordan (seis), o teorema do limite central será muito mais impressionante que ele.

^a Craque do basquete profissional norte-americano. (N.T.)

^b Perceba aqui o uso astuto da falsa precisão.

^c Quando o desvio padrão para a população é calculado a partir de uma amostra menor, a fórmula é ligeiramente alterada: $EP = s/\sqrt{n-1}$. Isso ajuda a levar em conta o fato de que a dispersão numa amostra pequena pode subestimar a dispersão de toda a população. Não se trata de algo altamente relevante para as questões maiores que estamos abordando neste capítulo.

^d Meu colega da Universidade de Chicago Jim Sallee faz uma crítica muito contundente aos exemplos de ônibus perdidos. Ele ressalta que muito poucos ônibus costumam se perder. Então, se por acaso estamos procurando um ônibus perdido, qualquer ônibus perdido ou acidentado que encontrarmos será provavelmente o que estamos procurando, *independentemente do peso dos passageiros no ônibus*. Ele tem razão. (Pense nisso: se você perde seu filho num supermercado e o gerente da loja lhe diz que por acaso há uma criança perdida parada perto do caixa seis, você concluiria na mesma hora que provavelmente é o seu filho.) Portanto, teremos de adicionar mais um elemento absurdo a esses exemplos e fingir que há ônibus se perdendo o tempo todo.