

Introdução à Ciência dos Dados

Aula 06 – Inferência Estatística

Sumário

- Introdução
- Teste de hipótese
- Intervalo de confiança
- valor-p

Inferência Estatística

- Imagine um estudante que tirou as seguintes notas nas provas de Programação:
30%; 23%; 40%; 30%; 98%
- O que podemos **concluir**?

Inferência Estatística

- Imagine um estudante que tirou as seguintes notas nas provas de Programação:
30%; 23%; 40%; 30%; 98%
- O que podemos **concluir**?
 - *Nada. A estatística não pode provar nada com certeza.*
- Mas podemos usar inferência para tentar determinar a explicação mais provável para algum resultado

Inferência Estatística

- Imagine um estudante que tirou as seguintes notas nas provas de Programação:
30%; 23%; 40%; 30%; 98%
- O que podemos **inferir**?

Inferência Estatística

- Imagine um estudante que tirou as seguintes notas nas provas de Programação:
30%; 23%; 40%; 30%; 98%
- O que podemos **inferir**?
 - Com base em anos lecionando a disciplina de Programação, o professor tem dados suficientes para inferir que este estudante provavelmente colou na última prova.
 - O professor pode ter certeza disso? **Não**. Mas ele tem uma boa chance de estar certo....

Inferência Estatística

- Imagine que um estranho chegue em sua cidade e te ofereça a seguinte aposta:
 - Ele ganha R\$1.000 se tirar 6 em um lance de um dado
 - Você ganha R\$500 se der qualquer outro número

Inferência Estatística

- Imagine que um estranho chegue em sua cidade e te ofereça a seguinte aposta:
 - Ele ganha R\$1.000 se tirar 6 em um lance de um dado
 - Você ganha R\$500 se der qualquer outro número
- Ele então joga e tira dez vezes seguidas o 6, levando R\$10.000

Inferência Estatística

- Imagine que um estranho chegue em sua cidade e te ofereça a seguinte aposta:
 - Ele ganha R\$1.000 se tirar 6 em um lance de um dado
 - Você ganha R\$500 se der qualquer outro número
- Ele então joga e tira dez vezes seguidas o 6, levando R\$10.000
 - Uma explicação **possível** é que ele teve muita sorte
 - Uma explicação **alternativa** é que o dado é viciado, pois a probabilidade de tirar o 6 dez vezes seguidas é de uma em 60 milhões
- Você não pode **provar** que ele trapaceou, mas no mínimo deve ficar desconfiado

Inferência Estatística

- Quando um evento muito raro acontece, podemos desconfiar
- Mas cuidado: coisas extremamente raras acontecem
 - Linda Cooper foi atingida 4 vezes por raios
 - O estudante que tirou 98% na última prova pode ter resolvido se dedicar à Programação depois que já sabia que havia sido reprovado em Cálculo
- Mas um padrão improvável deve ser investigado
 - É assim que Comissão de Valores Imobiliários pega operações com informação privilegiada

Inferência Estatística

- Será que um novo remédio é efetivo no tratamento de doenças cardíacas?
- Será que celulares provocam câncer?
- Será que o meu protocolo é mais eficiente que o já existente?
- Será que a prefeitura da minha cidade está gastando o dinheiro honestamente?
- Será que o remédio Paracetamol cura COVID-19?

Inferência Estatística

- Será que um novo remédio é efetivo no tratamento de doenças cardíacas?
- Será que celulares provocam câncer?
- Será que o meu protocolo é mais eficiente que o já existente?
- Será que a prefeitura da minha cidade está gastando o dinheiro honestamente?
- Será que o remédio Paracetamol cura COVID-19?

A inferência não responde a essas perguntas, mas nos diz o que é provável e o que é improvável.

Inferência Estatística

- Suponha que 91 em cada 100 pacientes recebendo uma nova medicação mostrem uma melhora acentuada, em comparação com 49 em 100 do grupo de controle.
 - Ainda é possível que esse resultado impressionante não esteja relacionado com a nova droga. Mas essa explicação é bem menos provável....

Inferência Estatística

- Suponha que 91 em cada 100 pacientes recebendo uma nova medicação mostrem uma melhora acentuada, em comparação com 49 em 100 do grupo de controle.
 - 1) se o medicamento não tem efeito, raramente veríamos uma variação de resultados dessa dimensão entre os que receberam e os que não receberam o tratamento
 - 2) portanto, é muito improvável que o medicamento não tenha efeito positivo
 - 3) a explicação alternativa, e mais provável, é que o medicamento tenha efeito positivo

Inferência Estatística

- Inferência estatística é o processo pelo qual os dados falam conosco, possibilitando-nos tirar conclusões significativas
 - Dados e probabilidade, com ajuda do teorema central do limite
 - Aceitar ou rejeitar explicações/hipóteses com base na sua relativa probabilidade

Inferência Estatística

- Teste de hipóteses
 - *Hipótese Nula* implícita ou explícita
 - Premissa de partida, que será rejeitada ou não
 - Se rejeitada, aceitamos alguma hipótese alternativa que seja mais consistente com os dados observados
 - Não será provada verdadeira; apenas pode-se falhar em rejeitá-la
 - *Hipótese Alternativa*
 - Conclusão que precisa ser verdadeira se é para rejeitar a hipótese nula

Inferência Estatística

Exemplo: Droga para prevenir malária

- *Hipótese Nula*: nova droga não é mais efetiva em prevenir a malária do que um placebo
- *Hipótese Alternativa*: nova droga pode ajudar a prevenir a malária
- *Dados*: um grupo aleatório recebe a nova droga e um grupo de controle recebe placebo
- *Resultado*: grupo que recebe a droga tem muito menos casos de malária que o grupo de controle

Inferência Estatística

Exemplo: Droga para prevenir malária

- *Hipótese Nula*: nova droga não é mais efetiva em prevenir a malária do que um placebo
- *Hipótese Alternativa*: nova droga pode ajudar a prevenir a malária
- *Dados*: um grupo aleatório recebe a nova droga e um grupo de controle recebe placebo
- *Resultado*: grupo que recebe a droga tem muito menos casos de malária que o grupo de controle

Resultado extremamente improvável se a droga não tivesse impacto medicinal. Por isso, rejeitamos a hipótese nula e aceitamos a alternativa. Ou seja, essa nova droga pode ajudar a prevenir malária.

Inferência Estatística

Exemplo: Reincidência em crimes

- *Hipótese Nula*: tratamento para abuso de substâncias químicas para detentos não reduz sua taxa de reincidência
- *Hipótese Alternativa*: tratamento para abuso de substâncias químicas para detentos reduzirá a probabilidade de reincidência
- *Dados*: um grupo aleatório de detentos recebe tratamento para abuso de substâncias e o grupo de controle não recebe
- *Resultado*: Após 5 anos, ambos os grupos têm índices similares de reincidência

Inferência Estatística

Exemplo: Reincidência em crimes

- *Hipótese Nula*: tratamento para abuso de substâncias químicas para detentos não reduz sua taxa de reincidência
- *Hipótese Alternativa*: tratamento para abuso de substâncias químicas para detentos reduzirá a probabilidade de reincidência
- *Dados*: um grupo aleatório de detentos recebe tratamento para abuso de substâncias e o grupo de controle não recebe
- *Resultado*: Após 5 anos, ambos os grupos têm índices similares de reincidência

Não podemos rejeitar a hipótese nula. Os dados não nos deram razão para descartar nossa premissa inicial de que o tratamento para abuso de substâncias químicas não é uma ferramenta efetiva para diminuir a reincidência.

Inferência Estatística

- Muitas vezes, a hipótese nula é criada com a esperança de que seja rejeitada. Nesses exemplos, o “sucesso” da pesquisa envolvia rejeitar a hipótese nula.
- A pergunta a ser respondida quantitativamente:
 - Se a hipótese nula for **verdadeira**, qual é a probabilidade de observar esse padrão de dados por puro acaso?

Inferência Estatística

- Mas o quanto a hipótese nula deve ser implausível para podermos rejeitá-la e recorrer a alguma explicação alternativa?
 - 5% (0,05) é um dos limiares mais comuns
 - Chamado de nível de significância
 - Limite superior para a probabilidade de observação de algum padrão de dados se a hipótese nula fosse verdadeira
 - Podemos rejeitar a hipótese nula no nível 0,05 se a chance de obter um resultado no mínimo tão extremo quanto o que observamos se a hipótese nula for verdadeira for **menor que 5%**

Inferência Estatística


- Exemplo do ônibus perdido
 - Pessoas no ônibus (amostra): 60
 - Peso médio da população: 74 KG
 - Desvio padrão da população: 16 KG
 - Erro padrão: $16/\sqrt{60} = 2,1$

Inferência Estatística

- Exemplo do ônibus perdido
 - Pessoas no ônibus (amostra): 60
 - Peso médio da população: 74 KG
 - Desvio padrão da população: 16 KG
 - Erro padrão: $16/\sqrt{60} = 2,1$

Espera-se que 95% de todas as amostras de 60 pessoas tenham peso médio dentro de dois erros padrões em relação à média da população, ou aproximadamente entre 70 e 78 quilos.

Inversamente, apenas 5 vezes em 100 uma amostra de 60 pessoas teria um peso médio menor que 70 ou maior que 78 quilos.




Inferência Estatística

- Exemplo do ônibus perdido
 - Pessoas no ônibus (amostra): 60
 - Peso médio da população: 74 KG
 - Desvio padrão da população: 16 KG
 - Erro padrão: $16/\sqrt{60} = 2,1$
 - **Média de peso no ônibus: 86 KG**

Espera-se que 95% de todas as amostras de 60 pessoas tenham peso médio dentro de dois erros padrões em relação à média da população, ou aproximadamente entre 70 e 78 quilos.

Inversamente, apenas 5 vezes em 100 uma amostra de 60 pessoas teria um peso médio menor que 70 ou maior que 78 quilos.



Inferência Estatística

- Exemplo do ônibus perdido
 - Pessoas no ônibus (amostra): 60
 - Peso médio da população: 74 KG
 - Desvio padrão da população: 16 KG
 - Erro padrão: $16/\sqrt{60} = 2,1$
 - **Média de peso no ônibus: 86 KG**

Como 86 KG é mais de 2 erros padrões acima da média, podemos rejeitar a hipótese nula de que o ônibus contém integrantes da população em análise. Ou seja:

- 1) o peso médio da amostra cai em uma faixa que deveria ocorrer somente 5 em cada 100 vezes, se a amostra viesse da população em análise;
- 2) podemos rejeitar a hipótese com um nível de significância 0,05;
- 3) em média, 95 vezes em 100 teremos rejeitado corretamente a hipótese nula, e apenas 5 vezes em 100 estaremos errados.

Inferência Estatística

- Mas qual a probabilidade específica de obter um resultado no mínimo tão extremo quanto o que você observou se a hipótese nula for verdadeira?
 - **valor-p** ou ***p-value***
 - No exemplo anterior, 86 KG corresponde a 5,7 erros padrões acima da média
 - A probabilidade da amostra ser da população em análise é de apenas **valor-p=0,0001**

Inferência Estatística

“Descoberta relação entre condição neurológica e tamanho do cérebro”

- Exames de imagem em 59 crianças com a *condição neurológica* e 38 crianças sem
- Resultados: crianças com a *condição neurológica* têm cérebros que são até 10% maiores que das crianças da mesma idade sem a condição

Inferência Estatística

- *“Descoberta relação entre condição neurológica e tamanho do cérebro”*
- Pergunta: essa descoberta pode ser válida, considerando que os estudos foram baseados em apenas 97 crianças ao todo?

Inferência Estatística

- *“Descoberta relação entre condição neurológica e tamanho do cérebro”*
- Pergunta: essa descoberta pode ser válida, considerando que os estudos foram baseados em apenas 97 crianças ao todo?
 - Sim, pelo teorema central do limite
- A probabilidade de observar as diferenças seria de 2 em 1000 ($p = 0,002$), se de fato não houvesse diferença real entre os grupos

Inferência Estatística

- “*Descoberta relação entre condição neurológica e tamanho do cérebro*”
- Hipótese nula: não há diferença nos cérebros de crianças com a *condição neurológica* e sem a condição
- Hipótese alternativa: cérebros de crianças com a *condição neurológica* são fundamentalmente diferentes

Inferência Estatística

- “*Descoberta relação entre condição neurológica e tamanho do cérebro*”
- Hipótese nula: não há diferença nos cérebros de crianças com *condição neurológica* e sem
- Hipótese alternativa: cérebros de crianças com *condição neurológica* são fundamentalmente diferentes
- Crianças com *condição neurológica*: **média = 1310,4 cm³**

Crianças sem a condição: **média = 1238,8 cm³**

Diferença: 71,6 cm³

Qual a chance de termos diferença, caso a hipótese nula seja verdadeira?

Inferência Estatística

- “*Descoberta relação entre condição neurológica e tamanho do cérebro*”
- Crianças **com** *condição neurológica*: **média = 1310,4 cm³ / EP = 13 cm³**
- Crianças **sem** *condição neurológica*: **média = 1238,8 cm³ / EP = 18 cm³**
- 95 vezes em 100 (95% de confiança), o intervalo de 1310,4 +/- 26 conterá o valor médio para todas as crianças com *condição neurológica*
- 95 vezes em 100 (95% de confiança), o intervalo de 1238,8 +/- 36 incluirá o valor médio para crianças na população sem *condição*

Inferência Estatística

- “*Descoberta relação entre condição neurológica e tamanho do cérebro*”
- Crianças com *condição neurológica*: **média = 1310,4 cm³ / EP = 13 cm³**
Crianças sem condição: **média = 1238,8 cm³ / EP = 18 cm³**
- 95 vezes em 100 (95% de confiança), o intervalo de 1310,4 +/- 26 conterà o valor médio para todas as crianças com *condição neurológica*
- 95 vezes em 100 (95% de confiança), o intervalo de 1238,8 +/- 36 incluirá o valor médio para crianças na população sem condição



Inferência Estatística

- “*Descoberta relação entre condição neurológica e tamanho do cérebro*”

Ok, os intervalos de confiança não se sobrepõem. Mas qual a probabilidade de observarmos esses valores se realmente não houver diferença no tamanho dos cérebros entre os dois grupos?

- Podemos calcular o **valor-p**



Inferência Estatística

- *“Descoberta relação entre condição neurológica e tamanho do cérebro”*

Como calcular o valor-p?

- Se pegarmos duas amostras grandes da mesma população, seria de esperar que tenham médias bastante similares, ou idênticas.
- Ou seja, a diferença entre as médias deve ser próxima de zero
- O teorema central do limite nos diz que a diferença entre duas médias estará distribuída aproximadamente como uma distribuição Normal
- Se duas amostras provêm da mesma população, então, em cerca de 68 casos em 100, a diferença entre as médias estará dentro de um erro padrão de zero. E cerca de 95 casos em 100, a diferença estará dentro de dois erros padrões. E em 99,7 casos em 100, a diferença estará dentro de três erros padrões....

Inferência Estatística

“Descoberta relação entre condição neurológica e tamanho do cérebro”

- **Como calcular o valor-p?**
- Se pegarmos duas amostras grandes da mesma população, seria de esperar que tenham médias bastante similares, ou idênticas.
- Ou seja, a diferença entre as médias deve ser próxima de zero
- O teorema central do limite nos diz que a diferença entre duas médias estará distribuída aproximadamente como uma distribuição Normal
- Se duas amostras provêm da mesma população, então, em cerca de 68 casos em 100, a diferença entre as médias estará dentro de um erro padrão de zero. E cerca de 95 casos em 100, a diferença estará dentro de dois erros padrões. E em 99,7 casos em 100, a diferença estará dentro de três erros padrões....

Erro padrão da diferença: 22,7 (Veja como calcular no próximo slide)

Diferença entre médias: 71,6 → Mais que 3 erros padrões

Valor-p = 0,002

Inferência Estatística

Cálculo do erro padrão para uma diferença de médias

Fórmula para comparar duas médias:

$$\frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}}}$$

→ o numerador fornece o valor da diferença entre as médias

→ o denominador fornece o erro padrão para uma diferença entre as médias das duas amostras

onde:

$\bar{x}$ = média da amostra x

$\bar{y}$ = média da amostra y

s_x = desvio padrão para a amostra x

s_y = desvio padrão para a amostra y

n_x = número de observações na amostra x

n_y = número de observações na amostra y

Inferência Estatística

$$X' = 1310,4$$

$$Y' = 1238,8$$

$$N_x = 59$$

$$N_y = 38$$

$$S_x = EP_x * \text{sqrt}(N_x) = 13 * 7,68 = 99,84$$

$$S_y = EP_y * \text{sqrt}(N_y) = 18 * 6,16 = 110,95$$

Erro padrão da diferença: 22,7

$$X' - Y' = 1310,4 - 1238,8 = 71,6$$

$$\text{Razão: } 71,6 / 22,7 = 3,15$$

Diferença entre as médias está 3,15 EPs do zero

Cálculo do erro padrão para uma diferença de médias

Fórmula para comparar duas médias:

$$\frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}}} \longrightarrow \begin{array}{l} \text{o numerador fornece o valor da diferença entre as médias} \\ \text{o denominador fornece o erro padrão para uma diferença} \\ \text{entre as médias das duas amostras} \end{array}$$

onde:

$\bar{x}$ = média da amostra x

$\bar{y}$ = média da amostra y

s_x = desvio padrão para a amostra x


s_y = desvio padrão para a amostra y

n_x = número de observações na amostra x

n_y = número de observações na amostra y

Inferência Estatística

Diferença entre médias de amostras



Inferência Estatística

- Hipótese nula é rejeitada se probabilidade de encontrarmos os dados observados for menor que um limiar/nível de significância
- Qual o melhor limiar para rejeitar uma hipótese nula?
 - Depende das circunstâncias de cada caso
- Quanto menor o nível de significância, menos provável que a rejeição ocorra, e mais peso estatístico a rejeição tem
- Quanto maior o nível de significância, mais provável de rejeitar a hipótese nula

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?
 - **Erro Tipo I:** rejeitar equivocadamente uma hipótese nula (Falso Positivo)
 - Quanto maior o limiar, maiores as chances
 - Ex. Inocentes presos, drogas que não funcionam no mercado
 - **Erro Tipo II:** não rejeitar uma hipótese nula que deveria ser rejeitada (Falso Negativo)
 - Quanto menor o limiar, maiores as chances
 - Ex. Culpados soltos, drogas que funcionam fora do mercado
- Qual tipo de erro é pior?

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?
 - **Erro Tipo I:** rejeitar equivocadamente uma hipótese nula (Falso Positivo)
 - Quanto maior o limiar, maiores as chances
 - Ex. Inocentes presos, drogas que não funcionam no mercado
 - **Erro Tipo II:** não rejeitar uma hipótese nula que deveria ser rejeitada (Falso Negativo)
 - Quanto menor o limiar, maiores as chances
 - Ex. Culpados soltos, drogas que funcionam fora do mercado
- Qual tipo de erro é pior?
 - **Depende das circunstâncias**

Inferência Estatística

		Situação real	
		H_0 é verdadeira	H_0 é falsa
Nossa Decisão	Rejeitar H_0	<i>Erro Tipo I</i> (Rejeitar H_0 , quando H_0 é verdadeira)	Decisão correta
	Não Rejeitar H_0	Decisão correta	<i>Erro Tipo II</i> (Não Rejeitar H_0 , quando H_0 é falsa)

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?
 - 1) Filtro de spam:
 - Hipótese nula: a mensagem **não** é spam

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?

1) Filtro de spam:

- Hipótese nula: a mensagem **não** é spam
- Erro Tipo I: mensagem que não é spam excluída
- Erro Tipo II: spam continuar na caixa de entrada

Erro Tipo II é mais aceitável. Quanto menor o limiar, menores as chances de Erro Tipo I.

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?

2) Diagnóstico de Câncer:

- Hipótese nula: a pessoa **não** possui câncer

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?
- 2) Diagnóstico de Câncer:
- Hipótese nula: a pessoa **não** possui câncer
 - Erro Tipo I: pessoa **sem** câncer é diagnosticada (falso positivo)
 - Erro Tipo II: pessoa **com** câncer não é diagnosticada (falso negativo)
- Erro Tipo I é mais aceitável. Quanto maior o limiar, menores as chances de Erro Tipo II.

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?

3) Captura de terroristas:

- Hipótese nula: a pessoa **não** é terrorista

Inferência Estatística

- Qual o melhor limiar para rejeitar uma hipótese nula?


3) Captura de terroristas:

- Hipótese nula: a pessoa **não** é terrorista
- Erro Tipo I: **não** terrorista preso e enviado para Guantánamo (falso positivo)
- Erro Tipo II: terrorista liberado (falso negativo)

Nenhum erro é aceitável. Porém, um único terrorista solto pode ser catastrófico. Decisão complicada.

Inferência Estatística

- Exemplos




30 simulações, comparação entre soluções com base nessa amostra de tamanho 30. Essa é uma estimativa da população.



Análise com 2000 usuários

Análise da Google com muitos milhares de usuários

State of Rio de Janeiro



Inferência Estatística

- Exemplos

Table 1. Baseline Characteristics of Patients Infected With 2019-nCoV

	No. (%)			P Value ^a
	Total (N = 138)	ICU (n = 36)	Non-ICU (n = 102)	
Signs and symptoms				
Fever	136 (98.6)	36 (100)	100 (98.0)	>.99
Fatigue	96 (69.6)	29 (80.6)	67 (65.7)	.10
Dry cough	82 (59.4)	21 (58.3)	61 (59.8)	.88
Anorexia	55 (39.9)	24 (66.7)	31 (30.4)	<.001
Myalgia	48 (34.8)	12 (33.3)	36 (35.3)	.83
Dyspnea	43 (31.2)	23 (63.9)	20 (19.6)	<.001
Expectoration	37 (26.8)	8 (22.2)	29 (28.4)	.35
Pharyngalgia	24 (17.4)	12 (33.3)	12 (11.8)	.003
Diarrhea	14 (10.1)	6 (16.7)	8 (7.8)	.20
Nausea	14 (10.1)	4 (11.1)	10 (9.8)	>.99
Dizziness	13 (9.4)	8 (22.2)	5 (4.9)	.007
Headache	9 (6.5)	3 (8.3)	6 (5.9)	.70
Vomiting	5 (3.6)	3 (8.3)	2 (2.0)	.13
Abdominal pain	3 (2.2)	3 (8.3)	0 (0)	.02

ICU = UTI

Para anorexia: p-value < 0.001
A probabilidade da diferença entre 67% e 30% ser APENAS pela aleatoriedade da amostragem é menor que 0.001. Ou seja, muito improvável.

From one of the most cited COVID-19 papers

Clinical Characteristics of 138 Hospitalized Patients With 2019 Novel Coronavirus Infected Pneumonia in Wuhan, China

<https://towardsdatascience.com/how-to-interpret-p-value-with-covid-19-data-edc19e8483b>

Inferência Estatística

- A inferência estatística não é mágica nem infalível, mas uma ferramenta extraordinária para explicar várias situações do mundo
- Podemos adquirir grande percepção de muitos fenômenos da vida apenas determinando a explicação mais provável



Você acha que esse cidadão bebeu exageradamente ou foi envenenado por um agente secreto russo?

Sugestão de estudo

- Capítulo 9 (Estatística, Charles Wheelan)
- Inferência - Portal Action