

Introdução à Ciência dos Dados

Aula 10 – Aprendizado Não-Supervisionado

Sumário


- Aprendizado Não-Supervisionado
- Características de agrupamentos
- Métricas de qualidade
- Principais algoritmos

O que é Aprendizagem de Máquina?

- Dois tipos: supervisionado e não-supervisionado

O que é Aprendizagem de Máquina?

- Não-Supervisionado
 - Dados não possuem rótulos
 - Objetivo é separar os dados em grupos semelhantes
 - Ou seja, criar rótulos para os dados



Aprendizado Não-Supervisionado

- Segmentação: separar um grande conjunto de dados em sub-conjuntos com elementos similares
- Compreensão: gerar descrição mais compacta do conjunto de dados

Aprendizado Não-Supervisionado

- Aplicações
 - Segmentar grupos de clientes
 - Agrupar estudantes pelo perfil
 - Encontrar grupos de genes similares
 - Categorizar documentos
 - Detectar anomalias
 - Identificar pontos de interesse de usuários móveis

Aprendizado Não-Supervisionado


- Como definir os grupos?



Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBBD 2003, Manaus

Aprendizado Não-Supervisionado

- Como definir os grupos?




Família



Empregados da Escola



Mulheres




Homens

Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBB D 2003, Manaus


Aprendizado Não-Supervisionado

- Como definir os grupos?





Aprendizado Não-Supervisionado

- Como definir os grupos?
 - Quantidade de grupos




Aprendizado Não-Supervisionado

- Como definir os grupos?
 - Com ou sem sobreposição?




Aprendizado Não-Supervisionado

- Como definir os grupos?
 - Formas



Aprendizado Não-Supervisionado

- Como definir os grupos?
 - Hierárquico ou particional



Aprendizado Não-Supervisionado

Matriz de dados: N objetos com p atributos

$$X = \begin{bmatrix} x_{11} & x_{12} \cdots & x_{1p} \\ x_{21} & x_{22} \cdots & x_{2p} \\ \cdots & \cdots \cdots & \cdots \\ x_{N1} & x_{Np} \cdots & x_{Np} \end{bmatrix}$$

Cada objeto é um vetor de tamanho p

$$x_i = [x_{i1} \ x_{i2} \ \cdots \ x_{ip}]$$

Aprendizado Não-Supervisionado

Matriz de (dis)similaridade N x N

$$X = \begin{bmatrix} d(x_1, x_1) & d(x_1, x_2) & \dots & d(x_1, x_N) \\ d(x_2, x_1) & d(x_2, x_2) & \dots & d(x_2, x_N) \\ \dots & \dots & \dots & \dots \\ d(x_N, x_1) & d(x_N, x_2) & \dots & d(x_N, x_N) \end{bmatrix}$$

Simétrica em relação à diagonal principal

Aprendizado Não-Supervisionado

- Como separar os objetos em grupos?
 - Utilizar uma medida de similaridade, que calcula a distância entre dois objetos
 - Várias medidas de distâncias existentes
 - Euclidiana
 - Manhattan
 - Cosseno
 -

Aprendizado Não-Supervisionado

- Propriedades das medidas de similaridades entre objetos
 - $d(x,y) = d(y,x)$
 - $d(x,y) \geq 0$
 - $d(x,x) = 0$
 - $d(x,y) = 0$, se e somente se $x = y$
 - $d(x,y) \leq d(x,z) + d(z,y)$

Aprendizado Não-Supervisionado

- Distância Minkowski
 - Espaço euclidiano
 - Generalização para outras distâncias
 - Manhattan (r=1) e Euclidiana (r=2)

$$d(x, y) = \left(\sum_{k=1}^n |x_k - y_k|^r \right)^{\frac{1}{r}}$$

Aprendizado Não-Supervisionado

- Distância Euclidiana
 - Distância mais comum entre dois objetos x e y em um espaço n -dimensional


$$d(x, y) = \sqrt{\sum_{k=1}^n (x_k - y_k)^2}$$

- x_k e y_k são o k -ésimo atributo dos objetos x e y

Aprendizado Não-Supervisionado

- Distância de Manhattan (*city block*)
 - Somatória dos módulos das diferenças


$$d(X, Y) = \left(\sum_{i=1}^p |X_i - Y_i| \right)^1 =$$
$$|X_1 - Y_1| + |X_2 - Y_2| + \cdots + |X_p - Y_p|$$



Fonte: ALGORITMOS PARA O PROBLEMA DE LOCALIZAÇÃO DE UMA FACILIDADE COM DISTÂNCIAS LIMITADAS E RESTRIÇÕES DE ATENDIMENTO

Aprendizado Não-Supervisionado


- Euclidiana x Manhattan



$y = [1 \ 4]$

$x = [5 \ 2]$

$$d(x,y) = \sqrt{(1-5)^2 + (4-2)^2}$$
$$d(x,y) = \sqrt{4^2 + 2^2}$$
$$d(x,y) = \sqrt{16 + 4}$$
$$d(x,y) = \sqrt{20}$$
$$d(x,y) = 4,4721$$



$y = [1 \ 4]$

$x = [5 \ 2]$

$$d(x,y) = |1-5| + |4-2|$$
$$d(x,y) = 4 + 2$$
$$d(x,y) = 6$$

Aprendizado Não-Supervisionado

- Similaridade de Cossenos

- Medida do ângulo entre x e y . Se é 1, o ângulo entre x e y é 0° ; se a similaridade é 0, o ângulo é 90°

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \|y\|}$$


Produto Interno

$$x \cdot y = \sum_{k=1}^n x_k y_k$$

Norma

$$\|x\| = \sqrt{\sum_{k=1}^n x_k^2}$$

- Muito usado em mineração de texto



Aprendizado Não-Supervisionado

- Coeficiente de casamento simples
 - Vetores binários
 - Conta as presenças e ausências igualmente

$$SMC = \frac{f_{11} + f_{00}}{f_{01} + f_{10} + f_{00} + f_{11}}$$

- f_{00} = atributos com $x=0$ e $y=0$
- f_{01} = atributos com $x=0$ e $y=1$
- f_{10} = atributos com $x=1$ e $y=0$
- f_{11} = atributos com $x=1$ e $y=1$

Aprendizado Não-Supervisionado

- Coeficiente de Jaccard
 - Vetores binários
 - Considera apenas coincidências de 1's


$$J = \frac{f_{11}}{f_{01} + f_{10} + f_{11}}$$

- f_{00} = atributos com $x=0$ e $y=0$
- f_{01} = atributos com $x=0$ e $y=1$
- f_{10} = atributos com $x=1$ e $y=0$
- f_{11} = atributos com $x=1$ e $y=1$

Aprendizado Não-Supervisionado


- Objetos de um grupo devem ser mais relacionados entre si do que entre objetos de outros grupos
- Minimizar distância intra-cluster
 - Entre elementos de um mesmo grupo
- Maximizar distância inter-cluster
 - Entre elementos de grupos diferentes

Aprendizado Não-Supervisionado




Aprendizado Não-Supervisionado

- Como avaliar a qualidade dos agrupamentos
 - Distância mínima ou vizinho mais próximo
 - Distância entre dois grupos é dada pela menor distância entre dois objetos, um de cada grupo




Aprendizado Não-Supervisionado

- Como avaliar a qualidade dos agrupamentos
 - Distância máxima ou vizinho mais distante
 - Distância entre dois grupos é dada pela maior distância entre dois objetos, um de cada grupo




Aprendizado Não-Supervisionado

- Como avaliar a qualidade dos agrupamentos
 - Distância média
 - Distância entre dois grupos é dada pela média das distâncias entre cada par de objetos, um de cada grupo




Aprendizado Não-Supervisionado

- Como avaliar a qualidade dos agrupamentos
 - Distância entre centróides
 - Distância entre dois grupos é dada pela distância entre os centróides de cada grupo



Aprendizado Não-Supervisionado

- Como avaliar a qualidade dos agrupamentos
 - Largura da Silhueta
 - Cada grupo é representado por uma silhueta
 - Considera:
 - Distância entre objetos de um mesmo grupo
 - Distância entre objetos de um grupo aos objetos do grupo mais próximo



Aprendizado Não-Supervisionado

- Como avaliar a qualidade dos agrupamentos
 - Largura da Silhueta
 - Para cada objeto i
 - a_i : distância média do objeto i a todos os outros objetos do seu grupo
 - b_i : distância média do objeto i a todos os objetos do grupo vizinho mais próximo
 - $s(i)$: silhueta do objeto i

$$s(i) = \frac{b_i - a_i}{\max(a_i, b_i)}$$

Aprendizado Não-Supervisionado

- Como avaliar a qualidade dos agrupamentos
 - Largura da Silhueta
 - Coeficiente de silhueta: média de $s(i)$ para todo objeto i
 - Valor entre -1 e 1 (quanto mais próximo de 1, melhor)
 - Valores ideais:
 - a_i bem próximos de zero
 - Valores positivos, bem próximos de 1

Aprendizado Não-Supervisionado

Algoritmos

Aprendizado Não-Supervisionado

Algoritmos

- K-means
- GMM
- DBScan

Aprendizado Não-Supervisionado

K-Means


Aprendizado Não-Supervisionado

K-Means

- Baseado na distância Euclidiana
- Os centros dos clusters são calculados pela média aritmética de seus componentes
- Algoritmo guloso
 - Comece com centros de clusters arbitrários
 - Encontre o centro do cluster mais próximo para cada item, e atribua o item a esse cluster
 - Recalcule o centro dos clusters incluindo os novos membros

Aprendizado Não-Supervisionado


K-Means




(a) Initial dataset

Aprendizado Não-Supervisionado

K-Means




(a) Initial dataset




(b) Iteration: $t = 1$

Aprendizado Não-Supervisionado


K-Means



(a) Initial dataset




(b) Iteration: $t = 1$



(c) Iteration: $t = 2$


Aprendizado Não-Supervisionado

K-Means




Aprendizado Não-Supervisionado

K-Means



(d) Iteration: $t = 3$




(e) Iteration: $t = 4$

Aprendizado Não-Supervisionado


K-Means



(d) Iteration: $t = 3$



(e) Iteration: $t = 4$




(f) Iteration: $t = 5$ (converged)

Aprendizado Não-Supervisionado


K-Means

- Repete
 - por um número fixo de vezes, ou
 - até que não tenha mudança nos clusters, ou
 - até que mudanças sejam mínimas na qualidade



Aprendizado Não-Supervisionado


K-Means



(a) Random initialization: $t = 0$


Aprendizado Não-Supervisionado

K-Means



Aprendizado Não-Supervisionado

K-Means



(c) Iteration: $t = 8$ (converged)

Aprendizado Não-Supervisionado

K-Means

- Requer o número pré-definido de clusters
- Algoritmo guloso com pontos iniciais aleatórios
- Complexidade $O(NK)$ por iteração, onde N é o número de atributos e K o número de clusters
- Fronteiras lineares
- Muito simples
- Atributos numéricos




Figure 5-116. Failure of k-means with nonlinear boundaries


Aprendizado Não-Supervisionado

GMM

Aprendizado Não-Supervisionado

GMM



- K-Means forma grupos com base em formas esféricas
- Nem sempre os dados podem ser separados dessa forma



Aprendizado Não-Supervisionado

GMM


- GMM (Gaussian Mixture Model)
 - Encontra uma mistura de distribuições Normais que melhor representam os dados



Aprendizado Não-Supervisionado

GMM


- GMM (Gaussian Mixture Model)
 - Cada objeto tem uma probabilidade de pertencer a um grupo, e pode portanto não ser alocado a nenhum grupo



Aprendizado Não-Supervisionado

GMM

- GMM (Gaussian Mixture Model)
 - Cada objeto tem uma probabilidade de pertencer a um grupo, e pode portanto não ser alocado a nenhum grupo



Aprendizado Não-Supervisionado

DBScan


Aprendizado Não-Supervisionado

DBScan

- Baseado na densidade dos pontos
 - quantidade de pontos em uma área
- Dois parâmetros: *minPoints* e *epsilon* (EPS)
- Ponto núcleo: existe pelo menos um número específico de pontos (*minPoints*) próximos (distância menor que *EPS*)
- Ponto de fronteira: não é um núcleo, mas está na vizinhança algum núcleo
- Ponto de ruído: não é núcleo nem de fronteira


Aprendizado Não-Supervisionado

DBScan



Aprendizado Não-Supervisionado


DBScan




Aprendizado Não-Supervisionado

DBScan

DBSCAN



k-means



Fonte: <https://towardsdatascience.com/understanding-dbscan-algorithm-and-implementation-from-scratch-c256289479c5?gi=99618a1cbf7b>

Aprendizado Não-Supervisionado

DBScan

- Não requer como parâmetro o número de grupos
- Outliers não são atribuídos a nenhum grupo
- Dificuldade em identificar os grupos se as densidades variam muito entre eles
 - Distância mínima (EPS) não atenderá a todos

Sugestão de estudo

