

Introdução à Ciência dos Dados

Aula 09 – Aprendizado Supervisionado

Sumário

- Aprendizado de Máquina
- Supervisionado x Não-Supervisionado
- Validação cruzada
- Métricas de avaliação
- Principais algoritmos

O que é Aprendizado de Máquina?

- Sub-área da Inteligência Artificial
- Aprendendo com os dados
- Criar modelos para entender os dados
- Utilizar modelos para prever novos dados

O que é Aprendizado de Máquina?


- Mensagem de e-mail é spam?
- Transação de cartão de crédito é fraudulenta?
- Qual propaganda um comprador está mais propício a clicar?
- Qual time irá vencer o campeonato?
- Qual a expectativa de nota que um cliente dará a um restaurante?
- Essa imagem é de um cachorro?
- Qual o próximo local de visita de um usuário?

O que é Aprendizado de Máquina?

- Dois tipos: supervisionado e não-supervisionado


O que é Aprendizado de Máquina?

- Não-Supervisionado
 - Dados não possuem rótulos
 - Objetivo é separar os dados em grupos semelhantes
 - Ou seja, criar rótulos para os dados




O que é Aprendizado de Máquina?

- Supervisionado
 - Dados possuem rótulos/classes
 - Cria um modelo que relaciona as características (*features*) dos dados a um rótulo (*label*)
 - O modelo criado pode ser usado para rotular dados desconhecidos (não-rotulados)



O que é Aprendizado de Máquina?

- Supervisionado
 - **Regressão**: rótulos são quantidades contínuas
 - Atributo a ser analisado é numérico
 - Identifica uma curva para os dados
 - Usa a curva aprendida para prever saídas de dados desconhecidos



O que é Aprendizado de Máquina?

- Supervisionado
 - **Classificação:** rótulos são categorias discretas
 - Atributo a ser analisado é categórico
 - Entrada: vetor de características
 - Saída: único valor discreto (a “classe”)




Cão



Gato



???




O que é Aprendizado de Máquina?

- Supervisionado
 - **Classificação:** rótulos são categorias discretas

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes


outlook	temperature	humidity	windy	PLAY?
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild	high	false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
sunny	cool	normal	false	yes
rainy	mild	normal	false	yes
sunny	mild	normal	true	yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

O que é Aprendizado de Máquina?




O que é Aprendizagem de Máquina?

- Supervisionado
 - **Classificação:** rótulos são categorias discretas



Aprendizado Supervisionado



Aprendizado Supervisionado

- A meta é generalizar
 - Criar um modelo genérico que irá ser capaz de prever classes/rótulos de dados novos e desconhecidos
- 1. Separe um sub-conjunto dos dados para treinamento
- 2. Treine o modelo
- 3. Teste o modelo com os dados que sobraram



Atenção: nunca utilize para teste os mesmos dados usados para treinamento

Aprendizado Supervisionado

- Sub-conjunto de teste pode estar tendencioso
- **Solução:** Validação Cruzada
 - Separar os dados D em K sub-conjuntos com aproximadamente o mesmo tamanho
 - Para cada sub-conjunto D' , utilize os outros $D - D'$ para treinar o modelo e D' para validar
 - Faça a média dos K resultados
 - Quantos sub-conjuntos K ?
 - Usualmente, os dados são divididos em 10 sub-conjuntos:
10-fold-cross-validation

Aprendizado Supervisionado

- Validação Cruzada



Final Accuracy = Average(Round 1, Round 2, ...)

Aprendizado Supervisionado

- Existem diferentes algoritmos
 - Qual o melhor?
- Os dados conhecidos podem não ser completos
- Decisões da máquina podem afetar diferentes e importantes aspectos da empresa

Como avaliar se o modelo está bom?

Aprendizado Supervisionado

- Existem diferentes algoritmos
 - Qual o melhor?
- Os dados conhecidos podem não ser completos
- Decisões da máquina podem afetar diferentes e importantes aspectos da empresa

Como avaliar se o modelo está bom?

Matriz de confusão

Aprendizado Supervisionado

- Ao se gerar um modelo de classificação, espera-se que ele classifique corretamente as entradas desconhecidas
 - Porém, às vezes na prática o modelo pode classificar equivocadamente
- A **matriz de confusão** condensa os resultados para facilitar a validação do modelo

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

1. Mensagem é *Spam* e o modelo a classifica como *Spam*: **Verdadeiro Positivo (VP)**

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

1. Mensagem é *Spam* e o modelo a classifica como *Spam*: **Verdadeiro Positivo (VP)**
2. Mensagem *não é Spam* e o modelo a classifica como *não Spam*: **Verdadeiro Negativo (VN)**

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

1. Mensagem é *Spam* e o modelo a classifica como *Spam*: **Verdadeiro Positivo (VP)**
2. Mensagem *não é Spam* e o modelo a classifica como *não Spam*: **Verdadeiro Negativo (VN)**
3. Mensagem é *Spam* e o modelo a classifica como *não Spam*: **Falso Negativo (FN)**

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

1. Mensagem é *Spam* e o modelo a classifica como *Spam*: **Verdadeiro Positivo (VP)**
2. Mensagem *não é Spam* e o modelo a classifica como *não Spam*: **Verdadeiro Negativo (VN)**
3. Mensagem é *Spam* e o modelo a classifica como *não Spam*: **Falso Negativo (FN)**
4. Mensagem *não é Spam* e o modelo a classifica como *Spam*: **Falso Positivo (FP)**

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

		Classe dada pelo classificador	
		Spam	Não-Spam
Classe Real	Spam		
	Não-Spam		

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

		Classe dada pelo classificador	
		Spam	Não-Spam
Classe Real	Spam	Verdadeiro-Positivo (VP)	
	Não-Spam		

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

		Classe dada pelo classificador	
		Spam	Não-Spam
Classe Real	Spam	Verdadeiro-Positivo (VP)	
	Não-Spam		Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

		Classe dada pelo classificador	
		Spam	Não-Spam
Classe Real	Spam	Verdadeiro-Positivo (VP)	Falso-Negativo (FN)
	Não-Spam		Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

Exemplo: classificador de spam

Quatro possíveis resultados

		Classe dada pelo classificador	
		Spam	Não-Spam
Classe Real	Spam	Verdadeiro-Positivo (VP)	Falso-Negativo (FN)
	Não-Spam	Falso-Positivo (FP)	Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

Matriz de confusão geral

		Classe dada pelo classificador	
		Classe A	Classe B
Classe Real	Classe A	Verdadeiro-Positivo (VP)	Falso-Negativo (FN)
	Classe B	Falso-Positivo (FP)	Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?

- **Acurácia:**

Acertos / (Acertos + Erros)

$(VP + VN) / (VP + VN + FP + FN)$

		Classe dada pelo classificador	
		Classe A	Classe B
Classe Real	Classe A	Verdadeiro-Positivo (VP)	Falso-Negativo (FN)
	Classe B	Falso-Positivo (FP)	Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?
 - **Acurácia:**
$$\frac{\text{Acertos}}{\text{Acertos} + \text{Erros}}$$
$$\frac{VP + VN}{VP + VN + FP + FN}$$
 - Responde à pergunta: no geral, o quão frequente o classificador está correto?

Apenas acurácia é
suficiente??

		Classe dada pelo classificador	
		Classe A	Classe B
Classe Real	Classe A	Verdadeiro-Positivo (VP)	Falso-Negativo (FN)
	Classe B	Falso-Positivo (FP)	Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?
 - **Acurácia:** Acertos / (Acertos + Erros)

	Classificado como Spam	Classificado como normal
Spam	100	150
Normal	50	1000

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?
 - **Acurácia:** Acertos / (Acertos + Erros)

	Classificado como Spam	Classificado como normal
Spam	100	150
Normal	50	1000

$$\begin{aligned}\text{Acurácia} &= (100 + 1000) / (100 + 1000 + 150 + 50) \\ &= 1100 / 1300 \\ &= 84.6\%\end{aligned}$$

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?
 - **Acurácia:** Acertos / (Acertos + Erros)

	Classificado como Spam	Classificado como normal
Spam	100	150
Normal	50	1000

$$\begin{aligned}\text{Acurácia} &= (100 + 1000) / (100 + 1000 + 150 + 50) \\ &= 1100 / 1300 \\ &= 84.6\% \text{ (mas para Spam, é apenas 66\%)}\end{aligned}$$

Cuidado: em conjuntos de dados muito desbalanceados, apenas classificar como a classe mais frequente já leva a uma acurácia alta.

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?

- **Precisão:**

Acertos Positivos / (Acertos Positivos + Erros Positivos)

VP / (VP + FP)

Daqueles classificados como positivos, quantos realmente são positivos?

		Classe dada pelo classificador	
		Classe A	Classe B
Classe Real	Classe A	Verdadeiro-Positivo (VP)	Falso-Negativo (FN)
	Classe B	Falso-Positivo (FP)	Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?

- **Precisão:**

Acertos Positivos / (Acertos Positivos + Erros Positivos)

VP / (VP + FP)

	Classificado como Spam	Classificado como normal
Spam	100	150
Normal	50	1000

$$\begin{aligned}\text{Precisão} &= (100) / (100 + 50) \\ &= 100 / 150 \\ &= 66.6\%\end{aligned}$$

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?

- **Revocação (Recall) ou sensibilidade**

Acertos Positivos / (Acertos Positivos + Falsos Negativos)

$VP / (VP + FN)$

Das entradas de classe positiva, quantas foram classificadas realmente como positiva?

		Classe dada pelo classificador	
		Classe A	Classe B
Classe Real	Classe A	Verdadeiro-Positivo (VP)	Falso-Negativo (FN)
	Classe B	Falso-Positivo (FP)	Verdadeiro-Negativo (VN)

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?

- **Revocação (Recall) ou sensibilidade**

Acertos Positivos / (Acertos Positivos + Falsos Negativos)


$VP / (VP + FN)$

	Classificado como Spam	Classificado como normal
Spam	100	150
Normal	50	1000

$$\begin{aligned}\text{Revogação} &= (100) / (100 + 150) \\ &= 100 / 250 \\ &= 40\%\end{aligned}$$

Aprendizado Supervisionado

- Precisão x Revocação
 - Ideal ter 100% para ambos
 - Buscar equilíbrio: VP x FP
 - Aumentar a revocação tende a “relaxar” o algoritmo e diminuir a precisão
 - Aumentar a “rigidez” do algoritmo tende a aumentar a precisão e diminuir a revocação



$\text{Precisão} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos positivos}}$	$\text{Revocação} = \frac{\text{Verdadeiros positivos} + \text{Falsos positivos}}{\text{Verdadeiros positivos} + \text{Verdadeiros negativos}}$
"Quanto elementos selecionados são relevantes?"	"Quanto elementos relevantes foram selecionados?"

Aprendizado Supervisionado

- Como avaliar se o modelo está bom?
 - **f1-score**: média harmônica entre precisão e revocação

$$F1 = 2 \times (\text{precisão} \times \text{revocação}) / (\text{precisão} + \text{revocação})$$

Ajuda no balanceamento entre precisão e revocação com uma única métrica

Aprendizado Supervisionado

- Como comparar diferentes modelos?

Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - Com várias matrizes

Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - Com várias matrizes

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - Com várias matrizes

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN


Difícil de
comparar...

Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - Curva ROC (*Receiver Operating Characteristic*)
 - Taxa de Verdadeiro Positivo (sensibilidade/recall)
 - $VP / (VP + FN)$
 - Quanto maior, melhor
 - Taxa de Falso Positivo (1 - especificidade)
 - $FP / (FP + VN)$
 - Quanto menor, melhor


Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - Curva ROC (*Receiver Operating Characteristic*)



Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - Curva ROC (*Receiver Operating Characteristic*)




Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - Muitos algoritmos de classificação retornam as probabilidades de uma instância pertencer a uma classe
 - Um limiar é utilizado para que a classificação seja feita
 - Se $P(\text{Diabético} \mid \text{Glicemia}) > \text{Limiar}$, então classifica como diabético
 - Qual o melhor valor para o limiar?
 - Podemos testar vários valores diferentes e comparar

Aprendizado Supervisionado


- Como comparar diferentes modelos?



Aprendizado Supervisionado



- Como comparar diferentes modelos?

Todo não-diabético é não é diagnosticado corretamente, mas tem muito falso negativo.



Aprendizado Supervisionado


- Como comparar diferentes modelos?



Podemos variar os valores de limiar para verificar o comportamento na curva ROC.



Aprendizado Supervisionado

- Como comparar diferentes modelos?






Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - AUC (*Area Under Curve*): métrica para consolidar a curva ROC



Aprendizado Supervisionado

- Como comparar diferentes modelos?
 - AUC (*Area Under Curve*): métrica para consolidar a curva ROC
 - Quanto maior o valor de AUC, melhor o modelo é para distinguir entre as classes



Aprendizado Supervisionado

Algoritmos

Aprendizado Supervisionado

Algoritmos

- KNN (K vizinhos mais próximos)
- Naive Bayes
- Árvore de Decisão
- Support Vector Machine (SVM)

Aprendizado Supervisionado

KNN – K Vizinhos Mais Próximos

- Você deseja classificar uma pessoa para prever em quem ela irá votar para presidente
 - Você não sabe nada sobre essa pessoa, além do endereço
 - Pelos dados de treinamento, você sabe como outras pessoas ao longo do território nacional irão votar

Aprendizado Supervisionado

KNN – K Vizinhos Mais Próximos


- Você deseja classificar uma pessoa para prever em quem ela irá votar para presidente
 - Você não sabe nada sobre essa pessoa, além do endereço
 - Pelos dados de treinamento, você sabe como outras pessoas ao longo do território nacional irão votar

K-NN: verifique como os K vizinhos mais próximos da pessoa irão votar

Aprendizado Supervisionado

KNN – K Vizinhos Mais Próximos


- Se você sabe mais detalhes sobre as pessoas além do endereço (idade, sexo, renda, formação, etc), os K vizinhos são calculados com base em todas essas características



Aprendizado Supervisionado

KNN – K Vizinhos Mais Próximos


- Se anda como um pato e “fala” como um pato, provavelmente é um pato



Aprendizado Supervisionado

KNN – K Vizinhos Mais Próximos

- Requer três coisas:
 - conjunto de treinamento
 - métrica para distância
 - valor de K
- Para classificar um desconhecido
 - calcula a distância aos objetos de treinamento
 - identifica os K mais próximos
 - use a classe mais predominante dos K vizinhos



Aprendizado Supervisionado

KNN – K Vizinhos Mais Próximos

- Técnica Lazy: não cria modelo explícito
- Caro para classificar
- Valor do K pode influenciar resultado
- Importante escolher boa métrica de distância

Aprendizado Supervisionado

Naive Bayes

- Baseado no teorema de Bayes

Conditional Probability: $P(Y | X) = \frac{P(X, Y)}{P(X)}$

$$P(X | Y) = \frac{P(X, Y)}{P(Y)}$$

Bayes theorem:

$$P(Y | X) = \frac{P(X | Y)P(Y)}{P(X)}$$

Aprendizado Supervisionado

Naive Bayes

- Na classificação, calcula a probabilidade de um objeto ter determinado rótulo dadas algumas de suas características

$$P(L \mid \text{features}) = \frac{P(\text{features} \mid L)P(L)}{P(\text{features})}$$

- Precisamos estimar $P(\text{features} \mid L)$
 - “*Naive*” (ingênuo) pois assume premissas simples (ex. dados seguem distribuição Normal)

Aprendizado Supervisionado

Naive Bayes

- Rápido para treinar e classificar
- Poucos parâmetros para ajustar
- Fácil de interpretar os resultados
- Útil para começar, para verificar se serão necessários modelos mais complexos

Aprendizado Supervisionado

Naive Bayes

- Funciona muito bem quando
 - Dados são realmente representados pela premissa “Naive” (raro na prática)
 - Para categorias muito bem distintas
 - Para dimensões muito grandes dos dados, em que a complexidade do modelo não é relevante para a qualidade


Aprendizado Supervisionado

Árvores de Decisão

- A função de classificação aprendida é representada por uma árvore de decisão
 - Regras SE-ENTÃO
- Aplicações: diagnóstico médico, análise de risco de crédito, etc
- Cada nó especifica o teste de algum atributo da instância
- Cada ramo, partindo de um nó, corresponde a um dos valores possíveis dos atributos

Aprendizado Supervisionado


Árvores de Decisão



Aprendizado Supervisionado

Árvores de Decisão

Árvore de Decisão para Jogar Ténis



Aprendizado Supervisionado

Árvores de Decisão

- Algoritmo base: ID3 e seu sucessor C4.5
- Começa pela pergunta:
 - Qual atributo deve ser testado na raiz?
- Cada atributo é testado para avaliar o quanto bem classifica sozinho os exemplos de treinamento
- Processo se repete até que a árvore esteja completa
 - Abordagem gulosa


Aprendizado Supervisionado

Árvores de Decisão

- Simplicidade para compreensão e interpretação
- Não necessita normalização dos dados
- Atributos numéricos e categóricos
- Bom desempenho e robustez
- Solução ótima é NP-Completo
 - Heurísticas são utilizadas
- Pode necessitar de mecanismos de poda para generalizar melhor

Aprendizado Supervisionado


Support Vector Machine (SVM)



Encontre um hiperplano para separar o espaço em duas partes

Aprendizado Supervisionado


Support Vector Machine (SVM)




Possível solução

Aprendizado Supervisionado


Support Vector Machine (SVM)



Possível solução



Outra possível solução




Várias possibilidades...

Qual a melhor opção?
Como definir melhor?

Aprendizado Supervisionado

Support Vector Machine (SVM)




Qual a melhor opção?
Como definir melhor?

A que maximiza a margem: B_1 é melhor que B_2 neste exemplo

Aprendizado Supervisionado


Support Vector Machine (SVM)



Funciona para dados em várias dimensões

Aprendizado Supervisionado

Support Vector Machine (SVM)



Funciona para dados em com separações não-lineares

Aprendizado Supervisionado

Support Vector Machine (SVM)

- Existem algoritmos eficientes para calcular o melhor hiperplano
 - Requer que usuário decida sobre melhores funções e parâmetros
- Dificuldade em tratar valores vazios
- Robusto a ruído
- Alto custo computacional
- Resultados muito bons

Aprendizado Supervisionado

Algoritmos

- Existem vários outros algoritmos
- Cada um com suas características, vantagens e desvantagens
- Cada um com seus hyper-parâmetros
 - Importante conhecer e fazer ajustes
- Mais importante é fazer uma boa engenharia de atributos
 - Bons dados e atributos relevantes levam a modelos melhores

Sugestão de estudo

