

Introdução à Ciência dos Dados


Aula 05 – Os Dados

Sumário

- Tipos de atributos
- Tipos de conjuntos de dados
- Qualidade dos dados
- Pré-processamento
- Exploração dos dados

O que são dados?

- Coleção de **objetos** e seus **atributos**
- Um **atributo** é uma propriedade ou característica de um objeto
 - Ex. Cor do olho de uma pessoa, temperatura, estado civil, idade
 - Também conhecido como variável, campo, característica, dimensão, ou *feature*
- Uma coleção de atributos descreve um **objeto**
 - Também conhecido como registro, ponto, caso, entidade, observação ou instância




The diagram illustrates a data table with 5 columns and 10 rows. A bracket above the columns is labeled 'Attributes' in red. A bracket to the left of the rows is labeled 'Objects' in red. The table contains the following data:

<i>Tid</i>	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

O que são dados?

- Medidas ou observações coletadas de alguma fonte
 - pessoas no Brasil, clientes de uma empresa, produtos em um loja, imagens de algum tipo de animal,
- Fatos observados
- Principal componente da Ciência dos Dados



Valores de atributos

- Valores de atributos são números ou símbolos mapeados a um atributo de um objeto em particular
- Mesmo atributo pode ser mapeado para diferentes valores de atributos
 - Ex. Altura pode ser medida em metros ou centímetros
- Diferentes atributos podem ser mapeados para o mesmo conjunto de valores
 - Ex. Quantidade de curtidas e idade são inteiros
- Também chamado de Domínio

Tipos de Atributos

- **Categórico:** Domínio de algum conjunto
 - Nominal: CorCabelo={preto, branco, louro}
 - Ordinal: valores possuem uma ordem. Tamanho={pequeno, médio, grande}, Nota={A,B,C,D,E}, Satisfação={1,2,3,4,5}
- **Numérico:** Domínio dos números (R, N, Z)
 - Intervalo: somente adição e subtração fazem sentido
 - Razão: adição, subtração, multiplicação e divisão fazem sentido
- **Data***
- **Texto***
- **Localização***

Tipos de Atributos

- Operações possíveis em atributos
 - Distinção: $==$ $\neq$
 - Ordenação: $<$ $>$
 - Diferenças: $+$ $-$
 - Razão: $*$ $/$
- Atributo nominal: distinção
- Atributo ordinal: distinção, ordenação
- Atributo intervalo: distinção, ordenação e diferença
- Atributo razão: todas as operações

Tipos de Atributos

- Diferença em intervalo e razão
 - Tem sentido dizer que uma temperatura de 10°C é o dobro de uma temperatura de 5°C ?
 - Se João é 30cm mais alto que a média de alunos, e Pedro é 15cm mais alto que a média, podemos dizer que João é duas vezes mais alto que Pedro?
 - Se Carla pesa 40Kg e Tiago pesa 80Kg, é possível afirmar que Tiago pesa o dobro de Carla?
 - Se Antônio tem 80 anos e Gabriel tem 20 anos, podemos dizer que Antônio é 4 vezes mais velho que Gabriel?

Tipos de Atributos

- Diferença em intervalo e razão
 - Tem sentido dizer que uma temperatura de 10°C é o dobro de uma temperatura de 5°C ? Não, mas podemos dizer que a temperatura diminuiu 5°C (Intervalo)
 - Se João é 30cm mais alto que a média de alunos, e Pedro é 15cm mais alto que a média, podemos dizer que João é duas vezes mais alto que Pedro? Não, mas podemos dizer que João é 15cm mais alto que Pedro (Intervalo)
 - Se Carla pesa 40Kg e Tiago pesa 80Kg, é possível afirmar que Tiago pesa o dobro de Carla? Sim, e também podemos dizer que Tiago pesa 40Kg a mais que Carla (Razão)
 - Se Antônio tem 80 anos e Gabriel tem 20 anos, podemos dizer que Antônio é 4 vezes mais velho que Gabriel? Sim, e também podemos dizer que Antônio tem 60 anos a mais que Gabriel (Razão)

Nos atributos de Razão, existe um zero absoluto indicando a ausência de quantidade

Tipos de Atributos

Tipo do Atributo	Descrição	Exemplos
Nominal	Distinção (=, !=)	CEP, ID, cor de olhos, sexo {M,F}
Ordinal	Distinção e ordenação (=, !=, <, >)	Nota: {A,B,C,D}, Qualidade: {Bom, Ruim}
Intervalo	Distinção, ordenação, diferença (=, !=, <, >, +, -)	Temperatura, ano
Razão	Distinção, ordenação, diferença e razão (=, !=, <, >, +, -, *, /)	Quantidades monetárias, contagens, idade, peso, tamanho

Atributos Discretos e Contínuos

- Atributo Discreto
 - Conjunto de valores finito ou contável
 - Número de likes, contagem de palavras em um texto
 - Frequentemente representados como Inteiros
- Atributo Contínuo
 - Conjunto de valores dos números Reais
 - Temperatura, altura, peso
 - Frequentemente representados como variáveis de ponto flutuante

Características Importantes

- Dimensão (número de atributos)
 - Desafio em lidar com dimensões muito grandes
 - Redução de dimensão
- Tamanho (número de objetos)
 - Desafio em lidar com grandes volumes de dados (Big Data)
 - Amostragem

Conjuntos de Dados

- Registros
 - Matriz
 - Documento
 - Transação
- Grafo
 - WWW
 - Mapa viária

Registros


- Coleção de objetos, cada um composto de um conjunto fixo de atributos

<i>Tid</i>	<i>Refund</i>	<i>Marital Status</i>	<i>Taxable Income</i>	<i>Cheat</i>
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Matriz

- Se os objetos possuem o mesmo conjunto fixo de atributos **numéricos**, então podem ser vistos como pontos em um espaço multi-dimensional, em que cada dimensão representa um atributo distinto
 - Matriz $M \times N$, sendo M objetos e N atributos

	1º bimestre	2º bimestre	3º bimestre	4º bimestre
Matemática	5,9	6,2	4,5	5,5
Português	6,6	7,1	6,5	8,4
Geografia	8,6	6,8	7,8	9,0
História	6,2	5,6	5,9	7,7



Documento

- Cada documento texto vira um vetor de termos
 - Cada termo é um componente (atributo) do vetor
 - O valor de cada componente representa uma característica do termo no documento (ex. o número ocorrências, taxa de ocorrência, posições)

	team	coach	play	ball	score	game	win	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0



Transação

- Tipo especial de registro, em que:
 - Cada registro (transação) envolve um conjunto de itens
- Exemplo: uma transação representa uma compra em um supermercado

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Grafo

- Vértices e arestas



Benzene Molecule: C₆H₆

Useful Links:

- [Bibliography](#)
- Other Useful Web sites
 - [ACM SIGKDD](#)
 - [KDNuggets](#)
 - [The Data Mine](#)

Knowledge Discovery and Data Mining Bibliography

(Gets updated frequently, so visit often!)

- [Books](#)
- [General Data Mining](#)

Book References in Data Mining and Knowledge Discovery

Usama Fayyad, Gregory Piatetsky-Shapiro, Padhraic Smyth, and Ramasamy uthurasamy, "Advances in Knowledge Discovery and Data Mining", AAAI Press/the MIT Press, 1996.

J. Ross Quinlan, "C4.5: Programs for Machine Learning", Morgan Kaufmann Publishers, 1993.

Michael Berry and Gordon Linoff, "Data Mining Techniques (For Marketing, Sales, and Customer Support)", John Wiley & Sons, 1997.

General Data Mining

Usama Fayyad, "Mining Databases: Towards Algorithms for Knowledge Discovery", Bulletin of the IEEE Computer Society Technical Committee on data Engineering, vol. 21, no. 1, March 1998.

Christopher Matheus, Philip Chan, and Gregory Piatetsky-Shapiro, "Systems for knowledge Discovery in databases", IEEE Transactions on Knowledge and Data Engineering, 5(6):903-913, December 1993.

Qualidade dos Dados

“Entra lixo, sai lixo”

Qualidade dos Dados

- Não se faz uma receita excelente com ingredientes estragados
- O mesmo ocorre com a análise de dados:
 - Não há análise sofisticada o suficiente que possa compensar dados falhos

Qualidade dos Dados


- Exemplo: cálculo de risco de um empréstimo bancário
 - Negar empréstimo a bons pagadores
 - Aceitar empréstimo a maus pagadores

Qualidade dos Dados


- Problemas com a qualidade dos dados
 - Ruídos e valores extremos (*outliers*)
 - Valores ausentes
 - Dados duplicados
 - Dados errados
 - Dados tendenciosos/enviesados (*biased*)
 - Dados certos para o problema errado

Qualidade dos Dados

- Ruído
 - Em objetos: objeto estranho
 - Em atributos: modificação de valores originais
 - Distorção na voz e imagem, precisão de GPS




Two Sine Waves



Two Sine Waves + Noise

Qualidade dos Dados

- Outliers (Valores extremos): objetos com características diferentes da maioria dos outros
- Caso 1: Outliers são ruídos que interferem na análise
- Caso 2: Outliers são a meta a ser alcançada
 - Fraude em cartão de crédito
 - Detecção de intruso



Qualidade dos Dados

- Valores ausentes: algum atributo de algum objeto com valor vazio
- Razões
 - Informação não coletada (ex. pessoas não forneceram renda e idade, GPS desabilitado)
 - Atributos podem não ser aplicáveis a todos os casos (ex. renda não se aplica a crianças)
- O tratamento depende de cada situação
 - Eliminar objetos do conjunto de dados (ex. compra sem valor)
 - Estimar valores com base em outras informações (ex. Localização pela rede móvel)
 - Ignorar

Qualidade dos Dados

- Dados duplicados: mesmos objetos repetidos
 - Atenção ao agrupar dados de fontes diferentes
 - Ex. Mesma pessoa, mas e-mails diferentes
- Tratamento depende de cada situação
 - Identificar e descartar
 - Manter os duplicados
 - Ex. Acessos de usuário a algum aplicativo

Qualidade dos Dados

- Dados errados
 - Erros na coleta
 - Localização *Indoor* em dispositivos móveis
 - Falhas manuais na digitação
 - Falhas manuais na integração entre várias fontes
 - Importância de termos amostras grandes e significativas, para evitar que esses erros afetem os resultados

Qualidade dos Dados

- Dados com viés
 - Tendenciosos para alguma conclusão
 - Exemplos:
 - Média da renda de moradores de BH coletados no Shopping Diamond Mall
 - Previsão de votos coletados por telefone durante o dia
 - Trabalhadores não participarão da consulta, por exemplo
 - Expectativa de vida das pessoas coletada no encontro de 60 anos de formação da turma
 - Quem já morreu não irá participar (pelo menos fisicamente)

Qualidade dos Dados

- Dados certos para o problema errado
 - Dados foram coletados corretamente e estão completos, porém o conhecimento extraído é sem sentido do ponto de visto do negócio
 - Ex. Qualidade de experiência de uma navegação na Internet pela taxa de transmissão
 - Ex. Estudar em Harvard mudará a sua vida?

Qualidade dos Dados

- Estudar em Harvard mudará a sua vida?

Qualidade dos Dados

- Estudar em Harvard mudará a sua vida?
 - Se analisarmos os graduados em Harvard, observaremos uma correlação com altos salários (em média, ganham mais que graduados em outras universidades)

Qualidade dos Dados

- Estudar em Harvard mudará a sua vida?
 - Se analisarmos os graduados em Harvard, observaremos uma correlação com altos salários (em média, ganham mais que graduados em outras universidades)
 - Mas o que aconteceria com essas pessoas caso não fossem para Harvard?

Qualidade dos Dados

- Estudar em Harvard mudará a sua vida?
 - Se analisarmos os graduados em Harvard, observaremos uma correlação com altos salários (em média, ganham mais que graduados em outras universidades)
 - Mas o que aconteceria com essas pessoas caso não fossem para Harvard?
 - Ao olhar estudantes que foram aceitos em Harvard mas foram para outra universidade menos qualificada (por motivo de localização, situação financeira, etc), o mesmo padrão foi encontrado

Qualidade dos Dados

- Estudar em Harvard mudará a sua vida?
 - Se analisarmos os graduados em Harvard, observaremos uma correlação com altos salários (em média, ganham mais que graduados em outras universidades)
 - Mas o que aconteceria com essas pessoas caso não fossem para Harvard?
 - Ao olhar estudantes que foram aceitos em Harvard mas foram para outra universidade menos qualificada (por motivo de localização, financeira, etc), o mesmo padrão foi encontrado

Ou seja, se olharmos para dados corretos mas com falhas no entendimento dos mesmos, podemos chegar a conclusões incorretas.

Pré-processamento de dados

- Agregação
- Amostra
- Redução de dimensionalidade
- Seleção de atributos
- Criação de atributos
- Discretização
- Transformação de atributos

Pré-processamento de dados

- **Agregação**

- Combinar dois ou mais atributos (ou objetos) em um único atributo (ou objeto)

- **Objetivo**

- Reduzir número de objetos ou atributos
- Mudança de escala (cidades agregadas em regiões, estados, países)

Pré-processamento de dados

- **Amostragem**

- Redução de dados, tanto na investigação preliminar quanto na análise final
- Usualmente usada na coleta, pois obter o conjunto completo (população) é inviável em termos de tempo e custo
- Útil para reduzir o custo computacional para processamento

Pré-processamento de dados

- **Amostragem**

- Uma amostragem é similar a todo o conjunto, desde que seja representativa
- Uma amostragem é representativa se tem aproximadamente as mesmas propriedades dos dados originais

Pré-processamento de dados

- **Amostragem**

- Uma amostragem é similar a todo o conjunto, desde que seja representativa
- Uma amostragem é representativa se tem aproximadamente as mesmas propriedades dos dados originais



8000 points



2000 Points



500 Points

Pré-processamento de dados

- Tipos de Amostragem
 - Aleatória simples
 - Probabilidade igual de selecionar qualquer item
 - Sem repetição ou com repetição
 - Amostragem estratificada
 - Separação em partições (regiões, períodos de tempo,..)

Pré-processamento de dados

- **Redução de dimensionalidade**
 - Pode ajudar a eliminar atributos irrelevantes
 - Reduzir tempo de processamento e memória
 - Facilitar visualização
- **Técnicas**
 - Principal Component Analysis (PCA)
 - Singular Value Decomposition
 - Outras....

Pré-processamento de dados

- **Seleção de atributos**
 - Outra forma de reduzir dimensionalidade
- Atributos redundantes
 - Ex. preço unitário, quantidade e **preço total**
- Atributos irrelevantes
 - Não agrega valor no processo de análise de dados
 - Ex. matrícula de estudante é irrelevante para prever coeficiente

Pré-processamento de dados

- **Criação de Atributo**
 - Cria novos atributos que capturam informação mais relevante que os atributos originais
- Extração: brilhos de imagens
- Construção: dividir massa por volume para ter densidade

Pré-processamento de dados

- **Discretização**

- Converter atributos contínuos em discretos ou em categorias
- Mapear um conjunto potencial de valores em um conjunto pequeno de categorias e valores
- Comumente utilizada em classificação
- Exemplo: valores numéricos de renda em categorias Alta, Média, Baixa

Pré-processamento de dados

- **Transformação**

- Função que mapeia um conjunto inteiro de valores de um atributo em um novo conjunto de valores, de tal forma que cada um dos valores antigos possa ser identificado como um novo valor
 - Ex. X^k , $\log(x)$, e^x , $|x|$
- Normalização:
 - Várias técnicas para ajustar as diferenças entre atributos em termos de frequência de ocorrência, média, variância, etc.

Análise Exploratória

- Análise preliminar dos dados para entender melhor suas características
 - Identificar o que precisa ser feito no pré-processamento
 - Identificar melhores ferramentas para pré-processamento e análise
 - Aproveitar habilidades humanas para reconhecer padrões

Análise Exploratória

- Análise preliminar dos dados para entender melhor suas características
 - Identificar o que precisa ser feito no pré-processamento
 - Identificar melhores ferramentas para pré-processamento e análise
 - Aproveitar habilidades humanas para reconhecer padrões
- Em geral, foco está em:
 - Sumário estatístico
 - Visualização

Análise Exploratória

- Sumário estatístico (atributos categóricos)
 - Frequência de um atributo: número de vezes ou percentual em que aparece no conjunto de dados
 - Ex. 48% das observações são de homens
 - Moda de um atributo: valor mais frequente

Análise Exploratória

- Sumário estatístico (atributos numéricos)
 - Percentil: o p-ésimo percentil x_p indica que p% dos valores são menores que x_p
 - Ex. o 20º percentil indica que 20% dos valores estão abaixo dele, e 80% dos valores estão acima
 - Mediana: 50º percentil
 - Média:
 - medida mais comum, mas sensível a outliers

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

Análise Exploratória

- Sumário estatístico (atributos numéricos)
 - Faixa: diferença entre os valores mínimo e máximo
 - Variância/Desvio padrão:
 - medida de dispersão, ou seja, o quão próximos os valores estão entre si

Análise Exploratória

- Visualização dos dados
 - Converte dados em um formato visual para que as características e os relacionamentos entre os dados sejam explorados

Sugestão de Estudo

- Capítulo 7 (Estatística, Charles Wheelan)
- Capítulos 2 e 3 (Data Mining, Zaki e Meira)