

7. A importância dos dados

“Entra lixo, sai lixo”

Na PRIMAVERA DE 2012, pesquisadores publicaram uma descoberta espantosa na renomada revista *Science*. Segundo essa pesquisa de ponta, quando os machos das moscas-da-fruta são repetidamente rejeitados pelas fêmeas, eles afogam suas mágoas no álcool. O *New York Times* descreveu o estudo num artigo de primeira página:

Eram machos jovens dispostos a acasalar e abordaram não uma vez, nem duas, mas uma dúzia de vezes um grupo de atraentes fêmeas voejando nas redondezas. E então fizeram o que tantos homens fazem depois de serem repetidamente rejeitados: embebedaram-se, usando o álcool como um bálsamo para seu desejo insatisfeito.¹

Essa pesquisa amplia a nossa compreensão sobre o sistema de gratificação do cérebro, que por sua vez nos ajuda a encontrar novas estratégias para lidar com a dependência de drogas e álcool. Um especialista em abuso de substâncias químicas descreveu a leitura do estudo como “olhar para trás no tempo, para ver a própria origem do circuito de gratificação que guia comportamentos fundamentais como sexo, comer e dormir”.

Como não sou especialista nesse campo, tive duas reações ligeiramente diferentes ao ler sobre moscas-da-fruta rejeitadas. Primeiro, senti saudades da faculdade. Segundo, meu senso interior de pesquisador pôs-se a imaginar como moscas-da-fruta ficam bêbadas. Será que existe um bar em miniatura para moscas-da-fruta, com uma variedade de bebidas alcoólicas à base de frutas e um simpático barman-mosca? Será que há música country tocando ao fundo? Será que as moscas-da-fruta gostam de música country?

Acontece que o projeto do experimento era diabolicamente simples. Um grupo de machos ganhou a oportunidade de acasalar livremente com fêmeas virgens. Outro grupo de machos foi solto entre as fêmeas que já haviam acasalado e que, portanto, estavam indiferentes às suas investidas amorosas. Ambos os conjuntos de machos puderam então escolher entre duas alternativas de alimentação: ração habitual para moscas-da-fruta, consistindo em levedura e açúcar, ou a “ração barra pesada”: levedura, açúcar e 15% de álcool. Os machos que haviam passado o dia tentando se acasalar com fêmeas indiferentes foram significativamente mais propensos a escolher a biritá.

Deixando de lado as brincadeiras, esses resultados têm implicações importantes para os humanos. Sugerem uma conexão entre estresse, respostas químicas no cérebro e apetite pelo álcool. Não obstante, os resultados não são um triunfo da estatística. São um triunfo dos dados, que tornaram possível uma análise estatística relativamente básica. A genialidade desse estudo foi conceber um modo de criar um grupo de machos sexualmente saciados e um grupo de machos sexualmente frustrados – e então descobrir um meio de comparar seus hábitos de bebida. Uma

vez feito isso, o processamento dos números não foi mais complicado do que um projeto típico de feira de ciências no ensino médio.

Os dados são para a estatística o que uma boa linha ofensiva é para um *quarterback* de renome. À frente de todo *quarterback* famoso está um bom grupo de bloqueadores. Eles geralmente não recebem muito crédito. Mas sem eles jamais se veria um excelente *quarterback*. A maior parte dos livros de estatística presume que você esteja usando bons dados, da mesma maneira que um livro de cozinha presume que você não esteja comprando carne rançosa nem legumes e verduras podres. Afinal, mesmo a mais fina receita não salva uma refeição que começa com ingredientes estragados. O mesmo ocorre com a estatística: não há volume de análise sofisticada que possa compensar dados fundamentalmente falhos. Daí a expressão “entra lixo, sai lixo”. Os dados merecem respeito, exatamente como a linha ofensiva.

GERALMENTE PEDIMOS aos nossos dados que façam uma destas três coisas: primeiro, podemos requisitar uma amostra de dados que seja representativa de algum grupo ou população maior. Se estamos tentando avaliar as atitudes dos eleitores em relação a um candidato político particular, precisaremos entrevistar uma amostra de potenciais eleitores que seja representativa de todos os eleitores na jurisdição política relevante. (E, lembre-se, não queremos uma amostra que seja representativa de todo mundo *que vive* naquela jurisdição; queremos uma amostra daqueles *que estão propensos a votar*.^{a)} Uma das descobertas mais poderosas em estatística, que será explicada em maior profundidade nos próximos dois capítulos, é que inferências feitas a partir de amostras razoavelmente grandes, adequadamente escolhidas, podem ser tão acuradas quanto tentar extrair a mesma informação da população inteira.

O modo mais fácil de coletar uma amostra representativa de uma população maior é selecionar de modo aleatório algum subconjunto dessa população. (Estranhamente isso é conhecido como amostra aleatória simples.) A chave para essa metodologia é que cada observação na população relevante deve ter uma igual chance de ser incluída na amostra. Se você planeja fazer uma sondagem com cem adultos num bairro com 4.328 moradores adultos, a sua metodologia precisa assegurar que cada um desses 4.328 adultos tenha a mesma probabilidade de acabar como um dos cem adultos pesquisados. Os livros de estatística quase sempre ilustram esse ponto com a retirada de bolinhas coloridas de dentro de uma urna. (Na verdade, na língua inglesa, é praticamente o único lugar onde se vê a palavra “urna” usada com tamanha regularidade.^{b)} Se houver 60 mil bolinhas azuis e 40 mil vermelhas numa urna gigante, então a composição mais provável de uma amostra de cem bolinhas tiradas aleatoriamente da urna seria de sessenta azuis e quarenta vermelhas. Se fizéssemos isso mais de uma vez, obviamente haveria desvios de uma amostra para outra – algumas poderiam ter 62 azuis e 38 vermelhas, ou 58 azuis e 42 vermelhas. Mas as chances de tirar qualquer amostra que se desvie muito da composição de bolinhas na urna são muito, muito poucas.

Agora, reconhecidamente, aqui há alguns desafios práticos. A maioria das populações a que damos importância tende a ser mais complicada do que uma urna cheia de bolinhas. Como, exatamente, alguém selecionaria uma amostra aleatória da população adulta americana a ser incluída numa pesquisa por telefone? Mesmo uma solução aparentemente elegante como um discador telefônico aleatório tem falhas potenciais. Alguns indivíduos (particularmente pessoas de

baixa renda) podem não ter telefone. Outros (particularmente pessoas de alta renda) podem ter a tendência de selecionar chamadas e optar por não atender. O Capítulo 10 delineará algumas das estratégias que empresas de pesquisa usam para superar esse tipo de obstáculos de amostragem (a maioria dos quais ficou ainda mais complicada com o advento dos celulares). A ideia-chave é que uma amostra adequadamente coletada se pareça com a população da qual é retirada. Em termos de intuição, você pode visualizar o processo de coletar uma amostra de uma panela de sopa com uma única colherada. Se você mexer bem a sopa, uma única colherada pode lhe dizer o sabor da sopa toda.

Um texto sobre estatística incluirá muito mais detalhes sobre métodos de amostragem. Firms de pesquisa de opinião e companhias de pesquisa de mercado passam seus dias concebendo como obter bons dados representativos de várias populações da maneira mais efetiva em termos de custo. Por enquanto, você deve considerar diversas questões importantes: (1) uma amostra representativa é uma coisa fabulosamente importante, pois abre a porta para algumas das ferramentas mais poderosas que a estatística tem a oferecer. (2) Obter uma boa amostra é mais difícil do que parece. (3) Muitas das afirmativas estatísticas mais abomináveis são causadas por bons métodos estatísticos aplicados a amostras ruins, e não o contrário. (4) O tamanho importa, e quanto maior melhor. Os detalhes serão explicados nos próximos capítulos, mas deve ser intuitivo que uma amostra maior ajudará a aplainar qualquer variação muito maluca. (Uma tigela de sopa será um teste ainda melhor que uma colherada.) Uma ressalva crucial é que uma amostra maior não compensa erros em sua composição, ou um “viés”. Uma amostra ruim é uma amostra ruim. Nenhum supercomputador ou fórmula mágica vai salvar a validade da sua pesquisa presidencial *nacional* se os participantes foram tirados apenas de uma sondagem telefônica com residentes em Washington, D.C. Os residentes de Washington, D.C. não votam como o resto dos Estados Unidos; e pegar 100 mil residentes em Washington, D.C. em vez de mil não vai sanar o problema fundamental da sua pesquisa. Na verdade, uma amostra grande, enviesada, é indiscutivelmente pior do que uma amostra pequena enviesada, porque dará uma falsa sensação de confiança referente aos resultados.

A SEGUNDA COISA QUE frequentemente pedimos aos dados é que forneçam alguma fonte de comparação. Um novo medicamento é mais efetivo que o tratamento atual? Ex-presidiários que recebem treinamento profissional têm menor probabilidade de voltar à prisão do que ex-presidiários que não recebem esse tipo de treinamento? Estudantes que frequentam escolas particulares que recebem verbas públicas têm desempenho melhor que estudantes similares que frequentam escolas públicas?

Nesses casos, a meta é encontrar dois grupos de sujeitos que sejam basicamente semelhantes exceto na aplicação de qualquer que seja o “tratamento” que nos interesse. No contexto de ciências sociais, a palavra “tratamento” é ampla o suficiente para abarcar qualquer coisa, desde ser uma mosca-da-fruta sexualmente frustrada até receber um desconto no imposto de renda. Como em qualquer outra aplicação do método científico, estamos tentando isolar o impacto de *uma intervenção ou atributo específico*. Essa foi a genialidade do experimento com as moscas-da-fruta. Os pesquisadores conceberam um meio de criar um grupo de controle (os machos que se acasalaram) e um grupo de “tratamento” (os machos que foram rejeitados); a diferença subsequente em seus hábitos de bebida pôde então ser atribuída ao fato de terem sido rejeitados

sexualmente ou não.

Em ciências físicas e biológicas, criar grupos de tratamento e controle é algo relativamente simples e direto. Os químicos podem fazer pequenas variações de um tubo de ensaio para outro, para então estudar a diferença nos resultados. Biólogos podem fazer a mesma coisa com suas placas de Petri. Mesmo a maioria dos testes com animais é mais simples do que tentar fazer moscas-da-fruta beber álcool. Podemos ter um grupo de ratos exercitando-se regularmente numa esteira e aí comparar sua acuidade mental num labirinto com o desempenho de outro grupo de ratos que não se exercitou. Mas quando há envolvimento de seres humanos, as coisas se tornam mais complicadas. Análise estatística sólida muitas vezes requer um grupo de tratamento e um de controle, no entanto, não podemos forçar pessoas a fazer as coisas que obrigamos os ratos de laboratório a fazer. (E muita gente não gosta nem que obrigemos ratos de laboratório a fazer essas coisas.) Será que repetidas concussões causam problemas neurológicos sérios mais tarde na vida? Essa é uma pergunta realmente importante. O futuro do futebol americano (e talvez de outros esportes) depende da resposta. Todavia, é uma pergunta que não pode ser respondida com experimentos em humanos. Então, a não ser que e até que possamos ensinar moscas-da-fruta a usar capacetes e enfrentar a defesa adversária, temos que encontrar outros meios de estudar o impacto no longo prazo de traumas na cabeça.

Um desafio de pesquisa recorrente com sujeitos humanos é criar grupos de tratamento e controle cuja diferença seja *apenas* que um grupo está recebendo o tratamento e o outro não. Por esse motivo, o “padrão-ouro” da pesquisa é a aleatoriedade, um processo pelo qual sujeitos humanos (ou escolas, ou hospitais, ou o que quer que estejamos estudando) são designados aleatoriamente para o grupo de tratamento ou de controle. Nós não consideramos que todos os sujeitos experimentais sejam idênticos. Em vez disso, a probabilidade torna-se nossa amiga (mais uma vez), e pressupomos que a aleatoriedade dividirá equilibradamente entre os dois grupos todas as características relevantes – tanto as características que podemos observar, como raça ou renda, mas também características nebulosas que não podemos medir ou deixamos de considerar, como fé ou perseverança.

A TERCEIRA RAZÃO PARA coletarmos dados é, citando a minha filha adolescente: “Porque sim.” Às vezes não temos nada específico em mente sobre o que faremos com a informação – mas desconfiamos que ela nos será proveitosa em algum momento. Isso é semelhante a um detetive exigindo que sejam colhidas todas as evidências possíveis da cena de um crime de modo que possam ser aproveitadas mais tarde como pistas. Parte dessas evidências se revelará útil, parte não. Para começar, se soubéssemos exatamente o que seria útil, talvez não precisaríamos estar fazendo a investigação.

É provável que você saiba que fumo e obesidade são fatores de risco para doenças cardíacas. Provavelmente não sabe é que um estudo de longa duração com os moradores de Framingham, Massachusetts, ajudou a esclarecer essas relações. Framingham é uma cidade suburbana com cerca de 67 mil habitantes mais ou menos a trinta quilômetros de Boston. Para não pesquisadores, é mais conhecida como um subúrbio de Boston com moradia a preços razoáveis e um conveniente acesso ao impressionante e sofisticado Natick Mall. Para pesquisadores, a cidade é mais conhecida como sede do Estudo de Framingham, um dos estudos longitudinais mais bem-sucedidos e influentes na história da ciência moderna.

Um estudo longitudinal colhe informações sobre um grande número de sujeitos em muitos momentos diferentes, como uma vez a cada dois anos. Os mesmos participantes podem ser entrevistados periodicamente durante dez, vinte ou até cinquenta anos após entrarem no estudo, criando um núcleo de informação extraordinariamente rico. No caso do estudo de Framingham, os pesquisadores reuniram informações sobre 5.209 adultos ali residentes em 1948: altura, peso, pressão sanguínea, histórico educacional, estrutura familiar, alimentação, comportamento quanto ao fumo, uso de drogas, e assim por diante. E, mais importante, os pesquisadores têm juntado dados de acompanhamento *dos mesmos participantes* desde então (e também dados de seus descendentes, para examinar fatores genéticos relacionados com doenças do coração). Os dados de Framingham têm sido usados para gerar mais de 2 mil artigos acadêmicos desde 1950, inclusive cerca de mil entre os anos 2000 e 2009.

Esses estudos produziram achados cruciais para a nossa compreensão de enfermidades cardiovasculares, muitos dos quais agora consideramos banais: fumar cigarros aumenta o risco de doença cardíaca (1960); atividade física reduz o risco de doença cardíaca, enquanto a obesidade aumenta esse risco (1967); pressão sanguínea elevada aumenta o risco de infarto e derrame (1970); altos níveis de colesterol HDL (daí por diante conhecido como “colesterol bom”) reduzem o risco de morte (1988); indivíduos com pais e irmãos que tenham doenças cardiovasculares têm um risco significativamente mais alto de também tê-las (2004 e 2005).

Conjuntos de dados longitudinais são o equivalente a uma Ferrari no ramo da pesquisa. Os dados são particularmente valiosos quando se trata de explorar relações causais que podem levar anos ou décadas para se manifestar. Por exemplo, o Estudo Pré-Escolar Perry começou no fim dos anos 1960 com um grupo de 123 afro-americanos de três e quatro anos vindos de famílias pobres. As crianças participantes foram designadas aleatoriamente a um grupo que recebeu um programa pré-escolar intensivo e um grupo de comparação que não recebeu. Os pesquisadores mediram então vários resultados para ambos os grupos *durante os quarenta anos seguintes*. Esses resultados constituem um contundente argumento em favor dos benefícios da educação na primeira infância. Os alunos que receberam o programa pré-escolar intensivo tinham QI mais alto aos cinco anos. Eles também tinham maior probabilidade de se graduarem no ensino médio. Aos quarenta anos, tinham rendas mais altas. Em contraste, os participantes que não receberam o programa de pré-escola eram significativamente mais propensos a terem sido presos cinco ou mais vezes até chegarem aos quarenta anos.

Não é surpresa, porém, que não possamos contar sempre com uma Ferrari. A pesquisa equivalente a uma Toyota é um conjunto de dados transversais, que é uma coleção de dados reunidos num único instante no tempo. Por exemplo, se epidemiologistas estão buscando a causa de uma doença nova (ou um surto repentino de uma doença antiga), podem reunir dados de todos os que sofrem da doença na esperança de achar um padrão que conduza à sua origem. O que essas pessoas comeram? Para onde viajaram? O que mais elas têm em comum? Os pesquisadores também podem coletar dados de indivíduos não afligidos pela doença para identificar os contrastes entre os dois grupos.

Na verdade, todo esse empolgante papo sobre dados transversais me faz lembrar da semana antes do meu casamento, quando me tornei parte de um conjunto de dados. Estava trabalhando em Katmandu, no Nepal, quando testei positivo para uma doença estomacal pouco compreendida chamada “alga azul-verde”, que fora encontrada em apenas dois lugares do

mundo. Pesquisadores haviam isolado o patógeno que causava a doença, mas ainda não tinham certeza sobre o tipo de organismo que era, pois nunca fora identificado antes. Quando liguei para casa para comunicar minha noiva acerca do diagnóstico, informei que havia más notícias. A doença não tinha meio de transmissão conhecido, nem cura, e podia causar extrema fadiga e outros efeitos colaterais desagradáveis por um período que podia ir de poucos dias até meses.^c Com o casamento marcado daí a apenas uma semana, sim, podia ser um problema. Teria eu controle total do meu sistema digestivo ao percorrer o corredor central? Talvez.

Mas aí tentei realmente me focar nas notícias boas. Primeiro, a “alga azul-verde” era considerada não fatal. Segundo, especialistas em doenças tropicais de lugares tão distantes como Bangkok tinham se interessado pelo meu caso em particular. *Não era uma boa?* (Também fiz um serviço estupendo desviando repetidamente a conversa para os planos do casamento: “Chega de falar da minha doença incurável. Conte-me mais sobre as flores.”)

Passei minhas últimas horas em Katmandu preenchendo uma pesquisa de trinta páginas descrevendo cada aspecto da minha vida: onde comi? O que comi? Como cozinhei? Eu saí para nadar? Onde e com que frequência? Todo mundo que fora diagnosticado com a doença estava fazendo a mesma coisa. O patógeno acabou sendo identificado como uma forma aquática de cianobactéria. (Essas bactérias são azuis e são do único tipo de bactéria que extrai sua energia da fotossíntese; daí a descrição original da doença como “alga azul-verde”.) Descobriu-se que a moléstia respondia a tratamento com antibióticos tradicionais, mas, curiosamente, não a alguns dos antibióticos mais novos. Todas essas descobertas vieram tarde demais para me ajudar, mas, de qualquer maneira, tive bastante sorte de me recuperar depressa. Tive um controle quase perfeito do meu sistema digestivo no dia do casamento.

POR TRÁS DE TODO estudo importante há bons dados que possibilitam a análise. E por trás de todo estudo ruim... bem, continue lendo. As pessoas muitas vezes falam sobre “mentir com estatísticas”. Eu argumentaria que alguns dos erros estatísticos mais escandalosos envolvem *mentir com dados*; a análise estatística está em ordem, mas os dados sobre os quais os cálculos são realizados são espúrios ou inadequados. Eis alguns exemplos comuns de “entra lixo, sai lixo”.

Viés de seleção. Pauline Kael, a consagrada crítica de cinema da revista *New Yorker*, teria dito após a eleição de Richard Nixon para presidente: “Não é possível que Nixon tenha ganhado. Não conheço ninguém que votou nele.” A citação provavelmente é apócrifa, mas é um encantador exemplo de como uma amostra fajuta (o grupo de amigos liberais de uma pessoa) pode fornecer um retrato enganador de uma população maior (os eleitores por todos os Estados Unidos). E introduz a questão que sempre se deve perguntar: como foi que escolhemos a amostra ou amostras que estamos avaliando? Se cada membro da população relevante não tem chance igual de aparecer na amostra, vamos ter um problema com quaisquer que sejam os resultados que surjam a partir da amostra. Um dos rituais na campanha presidencial é a pesquisa de intenção em Iowa, na qual candidatos republicanos vão para Ames, Iowa, em agosto do ano anterior a uma eleição presidencial para cortejar os participantes, cada um dos quais paga US\$30 para depositar um voto na pesquisa. A pesquisa de intenção em Iowa não nos conta tanta coisa sobre o futuro dos candidatos republicanos. (A pesquisa predisse apenas três dos cinco últimos nomeados

pelo Partido Republicano.) Por quê? Porque aqueles cidadãos de Iowa que pagam US\$30 na pesquisa são diferentes de outros republicanos de Iowa, e os republicanos de Iowa são diferentes dos eleitores republicanos no resto do país.

O viés de seleção pode ser introduzido de muitas outras maneiras. Um levantamento de consumidores num aeroporto será viesado pelo simples fato de que pessoas que viajam de avião provavelmente são mais ricas que o público geral; uma pesquisa numa parada de ônibus na Interestadual 90 pode ter o problema oposto. Ambas as pesquisas têm probabilidade de serem viesadas porque pessoas dispostas a responder a uma pesquisa num espaço público são diferentes de pessoas que preferem não ser incomodadas. Se você pedir a cem pessoas num espaço público para responder a uma breve pesquisa e sessenta estão dispostas a responder ao questionário, *essas sessenta provavelmente são significativamente diferentes sob vários aspectos das quarenta que foram embora sem fazer qualquer contato visual.*

Uma das maiores mancadas estatísticas de todos os tempos, a notória pesquisa da *Literary Digest* de 1936, foi causada por uma amostra viesada. Naquele ano, o republicano Alf Landon, então governador do Kansas, estava concorrendo à presidência contra o presidente no poder, Franklin Roosevelt, democrata. A *Literary Digest*, uma revista noticiosa semanal influente na época, despachou por correio uma pesquisa aos seus assinantes e a proprietários de telefone e automóvel cujos endereços podiam ser colhidos a partir de registros públicos. Tudo definido, a *Literary Digest* incluiu 10 milhões de eleitores em potencial, uma amostra astronômica. À medida que pesquisas com boas amostras se tornam maiores, ficam também melhores, pois a margem de erros se reduz. À medida que pesquisas com más amostras se tornam maiores, o monte de lixo só aumenta e fede mais. A *Literary Digest* predisse que Landon venceria Roosevelt com 57% do voto popular. Na verdade, Roosevelt ganhou de lavada, com 60% do voto popular e 46 dos 48 estados no colégio eleitoral. A amostra da *Literary Digest* era “lixo entrando”: os assinantes da revista eram mais ricos que os americanos médios e, portanto, mais propensos a votar num republicano, da mesma maneira que famílias com carro e telefone em 1936.²

Podemos acabar com o mesmo problema básico quando comparamos resultados entre um grupo de tratamento e um grupo de controle se o mecanismo para a escolha dos indivíduos de um ou outro grupo não for aleatório. Consideremos uma descoberta recente na literatura médica sobre os efeitos colaterais de um tratamento para câncer de próstata. Há três tratamentos comuns para o câncer de próstata: remoção cirúrgica da próstata; radioterapia; ou braquiterapia (que envolve implantar “sementes” radioativas perto do câncer).³ Impotência é um efeito colateral comum no tratamento do câncer de próstata, então os pesquisadores têm documentado a função sexual de homens que recebem cada um dos três tratamentos. Um estudo com mil homens descobriu que, dois anos após o tratamento, 35% dos indivíduos do grupo de cirurgia eram capazes de ter uma relação sexual, em comparação com 37% do grupo de radioterapia e 43% do grupo de braquiterapia.

É possível olhar esses dados e presumir que a braquiterapia é a menos provável de prejudicar a função sexual do homem? Não, não, não. Os autores do estudo advertiram explicitamente que não podemos concluir que a braquiterapia seja melhor para preservar a função sexual, uma vez que os homens que recebem esse tratamento em geral são mais jovens e estão em melhor condição física do que os que recebem outro tratamento. O propósito do estudo foi meramente

documentar o grau de efeitos colaterais sexuais em todos os tipos de tratamento.

Uma fonte de viés correlata, conhecida como viés de autosseleção, surge sempre que indivíduos se apresentam como voluntários para um grupo de tratamento. Por exemplo, prisioneiros que se apresentam voluntariamente para um grupo de tratamento de drogas são diferentes de outros prisioneiros *porque se voluntariaram a participar de um programa de tratamento de drogas*. Se os participantes desse programa tiveram maior propensão a permanecer fora da prisão que os outros depois de soltos, isso é ótimo – mas não nos diz absolutamente nada sobre o valor do programa de tratamento de drogas. Esses ex-detentos podem ter mudado de vida porque o programa os ajudou a se livrar das drogas. Ou podem ter mudado de vida por causa de outros fatores que inclusive também interferiram para deixá-los mais propensos a se apresentarem como voluntários para um programa de tratamento (como ter um desejo realmente forte de não voltar para a cadeia). Não podemos separar o impacto causal de um elemento (o programa de tratamento de drogas) do outro (ser do tipo de pessoa que se apresenta como voluntária para um programa de tratamento de drogas).

Viés de publicação. Achados positivos têm maior probabilidade de serem publicados que negativos, o que pode tornar tendenciosos os resultados que vemos. Suponha que você tenha acabado de conduzir um rigoroso estudo longitudinal no qual descobre conclusivamente que jogar videogames *não previne* câncer de cólon. Você acompanhou uma amostra significativa de 100 mil americanos durante vinte anos; aqueles participantes que passam horas jogando videogames têm aproximadamente a mesma incidência de câncer de cólon que os participantes que não jogam absolutamente nada de videogames. Vamos presumir que a sua metodologia seja impecável. Que revista médica de prestígio vai publicar seus resultados?

Nenhuma, por dois motivos. Primeiro, não há nenhuma forte justificativa científica para acreditar que jogar videogames tenha qualquer impacto sobre o câncer de cólon, portanto, não fica óbvio por que você estava fazendo esse estudo. Segundo, e mais relevante aqui, o fato de que algo *não previne* o câncer não é um achado particularmente interessante. Afinal, a maioria das coisas *não previne* o câncer. Achados negativos não são especialmente sensuais, nem em medicina nem em nenhuma outra área.

O efeito líquido é distorcer a pesquisa que vemos, ou não vemos. Suponha que uma das suas colegas da universidade tenha conduzido um estudo longitudinal diferente. Ela descobre que pessoas que passam muito tempo jogando videogames *têm sim* uma incidência menor de câncer de cólon. *Agora isso é interessante!* É exatamente o tipo de achado que chamaria a atenção de uma revista médica, da imprensa popular, de blogueiros e fabricantes de videogames (que encheriam seus produtos de etiquetas exaltando os seus benefícios para a saúde). Não demoraria muito para que mães ultrarrígidas pelo país afora comesçassem a “proteger” seus filhos do câncer arrancando livros das suas mãos e forçando-os em vez disso a jogar videogames.

É claro que uma ideia recorrente importante em estatística é que coisas inusitadas acontecem vez ou outra, por simples questão de acaso. Se você conduzir cem estudos, um deles provavelmente virá com resultados que são puro absurdo – como uma associação estatística entre jogar videogames e menor incidência de câncer de cólon. Eis o problema: os 99 estudos que não encontram ligação entre videogames e câncer de cólon não serão publicados, porque

não são interessantes. O único estudo que encontra de fato um elo estatístico será impresso e receberá montes de atenção e acompanhamento. A fonte desse viés provém não dos estudos em si, mas da informação desvirtuada que efetivamente chega ao público. Alguém que leia a literatura científica sobre videogames e câncer encontraria um único estudo, e esse único estudo sugere que jogar videogames pode prevenir o câncer. Na verdade, 99 estudos em cem não teriam encontrado tal ligação.

Sim, meu exemplo é absurdo – mas o problema é real e sério. Eis a primeira sentença de um artigo do *New York Times* sobre o viés de publicação envolvendo drogas para tratamento de depressão: “Os fabricantes de antidepressivos como Prozac e Paxil nunca publicaram os resultados de cerca de 1/3 de testes com drogas que conduziram para ganhar aprovação do governo, induzindo a erro médicos e consumidores acerca da verdadeira efetividade das drogas.”⁴ Acontece que 94% dos estudos com achados positivos sobre a efetividade dessas drogas foram publicados, enquanto apenas 14% dos estudos com resultados não positivos foram publicados. Para pacientes que lidam com depressão, isso é bastante relevante. Quando se incluem todos os estudos, os antidepressivos são melhores que um placebo apenas por “uma modesta margem”.

Para combater esse problema, as revistas médicas agora normalmente requerem que qualquer estudo seja registrado no início do projeto se é para ser elegível para posterior publicação. Isto dá aos editores alguma evidência sobre a proporção entre descobertas positivas e não positivas. Se forem registrados cem estudos que se proponham a examinar o efeito da prática do skate sobre doenças cardíacas, e apenas um é, em última instância, submetido para publicação com achados positivos, os editores podem inferir que os outros estudos tiveram achados não positivos (ou podem ao menos investigar essa possibilidade).

Viés de memória. A memória é uma coisa fascinante – porém nem sempre uma grande fonte de bons dados. Temos um impulso humano natural de compreender o presente como consequência lógica de coisas que aconteceram no passado – causa e efeito. O problema é que as nossas memórias se revelam “sistematicamente frágeis” quando tentamos explicar alguns resultados particularmente bons ou ruins no presente. Considere um estudo analisando a relação entre dieta e câncer. Em 1993, um pesquisador de Harvard compilou um conjunto de dados abrangendo um grupo de mulheres com câncer de mama e um grupo de mulheres de idade correspondente que não haviam sido diagnosticadas com câncer. As mulheres de ambos os grupos foram indagadas a respeito de seus hábitos alimentares quando mais jovens. O estudo produziu resultados claros: as mulheres com câncer de mama tinham muito maior probabilidade de ter dietas com elevado teor de gordura quando mais novas.

Ah, mas esse não era na realidade um estudo de como a dieta afeta a probabilidade de ter câncer. *Era um estudo de como ter câncer afeta a memória da mulher acerca de sua dieta no passado.* Todas as mulheres no estudo tinham preenchido uma pesquisa sobre hábitos alimentares anos atrás, antes que qualquer uma delas tivesse sido diagnosticada com câncer. A descoberta surpreendente foi que mulheres com câncer de mama recordavam ter uma dieta com muito mais gordura do que haviam de fato consumido; isso não ocorreu com as mulheres sem câncer. A *New York Times Magazine* descreveu a natureza insidiosa desse viés de memória:

O diagnóstico de câncer de mama não só modificara o presente da mulher, e o seu futuro; havia alterado o seu passado. Mulheres com câncer de mama tinham (inconscientemente) decidido que uma dieta rica em gordura era uma predisposição provável para sua doença e (inconscientemente) recordavam-se de uma dieta de muita gordura. Era um padrão dolorosamente familiar a qualquer um que conheça a história dessa estigmatizada doença: essas mulheres, como milhares de outras antes delas, haviam vasculhado suas próprias memórias em busca de uma causa e então invocaram essa causa na memória.⁵

O viés de memória é um motivo para que se prefiram frequentemente estudos longitudinais em lugar de transversais. Num estudo longitudinal, os dados são coletados contemporaneamente. Aos cinco anos, um participante pode ser indagado sobre suas atitudes em relação à escola. Então, treze anos depois, podemos revisitar esse mesmo participante e verificar se ele abandonou o ensino médio. Num estudo transversal, no qual todos os dados são coletados num determinado instante no tempo, precisamos perguntar a um jovem de dezoito anos que abandonou o ensino médio como se sentia em relação à escola aos cinco anos, o que é inerentemente menos confiável.

Viés de sobrevivência. Suponha que o diretor de uma escola de ensino médio relate que os resultados de testes para um grupo particular de alunos melhoraram consistentemente por quatro anos. Os resultados do segundo ano para essa classe foram melhores que seus resultados como calouros. Os resultados do terceiro ano foram ainda melhores, e os resultados do último ano, os melhores de todos.^d Vamos estipular que não haja fraudes nem mesmo algum uso criativo de estatística descritiva. Todo ano esse grupo de alunos se saiu melhor que no ano anterior, por qualquer medida possível: média, mediana, porcentagem de alunos em nível de graduação, e assim por diante.

Você (a) indicaria o diretor dessa escola para “diretor do ano” ou (b) exigiria mais dados?

Eu digo “b”. Farejo viés de sobrevivência, que ocorre quando algumas ou muitas das observações caem fora da amostra, mudando a composição das observações que restam e, portanto, afetam os resultados de qualquer análise. Vamos supor que o nosso diretor seja verdadeiramente horrível. Os alunos nessa escola não estão aprendendo nada; a cada ano, metade deles cai fora. Bem, isso poderia gerar coisas muito boas para os resultados dos testes escolares – sem que nenhum aluno individual estivesse realmente se saindo melhor nos testes. Se partirmos da razoável premissa de que os piores alunos (com os piores resultados nos testes) sejam os mais prováveis de abandonar a escola, então a média dos resultados dos alunos que restam subirá uniformemente à medida que mais e mais alunos abandonem o curso. (Se em uma sala cheia de pessoas com alturas variadas as mais baixas forem obrigadas a sair, isso fará com que a altura média na sala aumente, mas ninguém fica mais alto.)

O ramo de fundos mútuos tem recorrido agressivamente (e insidiosamente) ao viés de sobrevivência para fazer seus retornos parecerem melhores para os investidores do que de fato são. Fundos mútuos normalmente avaliam seu desempenho em relação a um marco de referência para ações, o Standard & Poor's 500, que é um índice das quinhentas empresas públicas mais importantes nos Estados Unidos.^e Se o S&P 500 subiu 5,3% no ano, diz-se que o

fundo mútuo bateu o índice se o seu desempenho for melhor que esse, ou que perdeu para o índice se for pior. Uma opção barata e fácil para investidores que não querem pagar um administrador de fundo mútuo é comprar um S&P 500 Index Fund, que é um fundo mútuo que simplesmente compra ações em todas as quinhentas empresas do índice. Administradores de fundos mútuos gostam de acreditar que são investidores muito sábios, capazes de usar seu conhecimento para escolher ações que terão desempenho melhor do que um fundo mútuo simples. Na verdade, acaba sendo relativamente difícil bater o S&P 500 por qualquer período de tempo consistente. (O S&P 500 é uma média de todas as grandes ações negociadas, então, como simples questão de matemática, seria de esperar que metade dos fundos mútuos ativamente administrados superasse o S&P 500 em determinado ano e a outra metade tivesse desempenho inferior.) É claro que não parece muito bom perder para um índice irracional que simplesmente compra quinhentas ações e as retém. Nada de análise. Nada de rebuscadas macroprevisões. E, para grande deleite dos investidores, nada de taxas de administração.

O que uma companhia tradicional de fundo mútuo deve fazer? Adulterar os dados como salvação! Eis como podem “bater o mercado” sem bater o mercado. Uma grande companhia mútua abre muitos fundos novos ativamente administrados (o que significa que os peritos estão escolhendo as ações, muitas vezes com um foco ou estratégia particular). Como exemplo, vamos supor que uma companhia de fundos mútuos abra vinte fundos novos, cada um deles com aproximadamente 50% de chance de bater o S&P 500 em determinado ano. (Essa premissa é consistente com dados de longo prazo.) Agora, a probabilidade básica sugere que apenas dez dos novos fundos da firma irão bater o S&P 500 no primeiro ano; cinco fundos o baterão dois anos seguidos; e dois ou três outros o baterão três anos seguidos.

Agora entra em cena a esperteza. Nesse momento, os novos fundos mútuos com retornos inexpressivos em relação ao S&P 500 são discretamente fechados. (Seus ativos são incorporados em outros fundos existentes.) A companhia pode então anunciar intensamente os dois ou três fundos novos que têm “superado consistentemente o S&P 500” – mesmo que esse desempenho, em termos de compra de ações, seja o equivalente a tirar três caras seguidas num lançamento de moeda. O desempenho subsequente desses fundos provavelmente reverterá à média, só que depois de muitos investidores terem aderido. O número de gurus de fundos mútuos ou investimentos que têm batido consistentemente o S&P 500 durante um período longo é impressionantemente pequeno.^f

Viés do usuário saudável. Gente que toma vitaminas regularmente tem propensão a ser saudável – *porque são o tipo de gente que toma vitaminas regularmente!* Se as vitaminas têm qualquer impacto é uma questão totalmente à parte. Considere o seguinte experimento mental. Suponha que funcionários da saúde pública promulguem uma teoria de que todos os pais novos devem pôr seus filhos na cama apenas em pijamas roxos, porque essa cor ajuda a estimular o desenvolvimento do cérebro. Vinte anos depois, uma pesquisa longitudinal confirma que ter usado pijamas roxos quando criança tem uma associação extraordinariamente positiva com o sucesso na vida. Descobrimos, por exemplo, que 98% dos calouros que entraram em Harvard vestiram pijamas roxos quando crianças (e muitos ainda vestem) em comparação com apenas 3% dos detentos no sistema penitenciário estadual de Massachusetts.

É claro que pijamas roxos não têm importância, mas ter o tipo de pais que botam os filhos na cama em pijamas roxos *tem importância sim*. Mesmo quando tentamos controlar fatores como educação parental, ainda nos restarão diferenças não observáveis entre os pais que são obcecados em vestir pijamas roxos nos filhos e os que não são. Como explica o articulista de saúde do *New York Times*, Gary Taubes: “Na sua forma mais simples, o problema é que as pessoas que se engajam com fé em atividades que lhe são benéficas – por exemplo, tomar um remédio conforme a prescrição, ou comer o que acreditam ser uma dieta saudável – são fundamentalmente diferentes daquelas que não se engajam.”⁶ Esse efeito pode potencialmente confundir qualquer estudo que tente avaliar o efeito real de atividades percebidas como salutares, tais como exercitar-se com regularidade ou comer couve. Nós pensamos que estamos comparando os efeitos salutares de duas dietas: couve ou ausência de couve. Na verdade, se os grupos de tratamento e de controle não foram escolhidos de modo aleatório, estaremos comparando duas dietas que estão sendo mantidas por dois tipos diferentes de pessoa. Temos um grupo de tratamento que é diferente do grupo de controle em dois aspectos, e não apenas um.

SE A ESTATÍSTICA É trabalho de detetive, então os dados são as pistas. Minha esposa passou um ano como professora de ensino médio na região rural de New Hampshire. Um de seus alunos foi preso por arrombar uma loja de ferragens e roubar algumas ferramentas. A polícia foi capaz de solucionar o caso porque (1) tinha acabado de nevar e havia pegadas na neve levando da loja de ferragens para a casa do aluno e (2) as ferramentas roubadas foram encontradas lá dentro. Boas pistas ajudam.

Assim como bons dados. Mas primeiro você tem que ter bons dados, o que é bem mais difícil do que parece.

^a Lembrando que nos Estados Unidos o voto não é obrigatório. (N.T.)

^b Urna de votação em inglês é *ballot box*. (N.T.)

^c Na época, a doença tinha uma duração média de 43 dias, com um desvio padrão de 24 dias.

^d Lembrando que o ensino médio do sistema educacional americano tem quatro anos. (N.T.)

^e O S&P 500 é um belo exemplo do que um índice pode e deve fazer. O índice é composto dos preços das ações das quinhentas empresas líderes dos Estados Unidos, cada uma ponderada pelo seu valor de mercado (de modo que as empresas maiores tenham mais peso no índice do que as menores). O índice é uma avaliação simples e acurada do que está acontecendo com os preços das ações das maiores empresas americanas em dado momento.

^f Para uma excelente discussão sobre por que você deve provavelmente comprar fundos indexados em vez de tentar bater o mercado, leia *A Random Walk Down Wall Street*, de autoria do meu antigo professor Burton Malkiel.