

11. Análise de regressão

O elixir milagroso

SERÁ QUE ESTRESSE no emprego pode matar você? Sim. Há fortes evidências de que os rigores no trabalho podem levar a uma morte prematura, em especial de doença cardíaca. Mas não é o tipo de estresse que você talvez está imaginando. CEOs, que rotineiramente precisam tomar decisões de suma importância que determinam a sorte de suas empresas, correm um risco significativamente *menor* que suas secretárias, que obediamente atendem ao telefone e executam outras tarefas conforme são instruídas. Como isso pode fazer algum sentido? Acontece que o tipo de estresse mais perigoso está associado a ter “baixo controle” sobre as próprias responsabilidades. Diversos estudos envolvendo milhares de funcionários públicos britânicos (os estudos Whitehall) descobriram que trabalhadores que têm pouco controle sobre suas atribuições – o que significa que têm pouco a dizer sobre quais serviços executar ou como esses serviços são executados – têm uma taxa de mortalidade significativamente mais alta do que outros trabalhadores no funcionalismo público com maior autoridade na tomada de decisões. Segundo essa pesquisa, não é o estresse associado a responsabilidades importantes que vai matar você; é o estresse associado a lhe dizerem o que fazer enquanto você tem pouco a dizer sobre como e quando fazer.

Este não é um capítulo sobre estresse no emprego, doenças cardíacas ou funcionários públicos britânicos. A questão relevante concernente aos estudos Whitehall (e outros similares) é como os pesquisadores podem chegar a tal conclusão. Nitidamente, esse não é um experimento aleatório. Não podemos designar seres humanos arbitrariamente a diferentes empregos, forçá-los a trabalhar nesses empregos por muitos anos para então mensurar qual é a maior taxa de mortalidade. (Considerações éticas à parte, distribuir empregos de maneira aleatória acabaria gerando um caos no serviço civil britânico.) Em vez disso, os pesquisadores coletaram detalhados dados longitudinais de milhares de indivíduos nesse serviço; esses dados podem ser analisados para identificar associações significativas, tais como uma ligação entre empregos de “baixo controle” e doença cardíaca coronária.

Uma associação simples não é suficiente para concluir que certos tipos de emprego são ruins para a saúde. Se meramente observamos que trabalhadores de baixo escalão na hierarquia do serviço civil britânico têm maior taxa de doenças cardíacas, nossos resultados seriam confundidos por outros fatores. Por exemplo, é de esperar que trabalhadores de baixo escalão tenham menos educação do que funcionários que ocupam postos mais altos na burocracia da empresa. Eles podem ter mais propensão a fumar (talvez por causa de sua frustração no trabalho). Podem ter tido uma infância menos saudável, o que reduziu suas perspectivas de emprego. Ou seu salário mais baixo pode reduzir seu acesso a serviços de saúde. E assim por diante. O ponto é que qualquer estudo que simplesmente compare resultados em termos de saúde num grupo grande de trabalhadores britânicos – ou em qualquer outro grupo grande – não nos

dirá realmente muita coisa. Outras fontes de variação nos dados têm probabilidade de obscurecer a relação na qual estamos interessados. Será que “baixo controle no emprego” está realmente provocando doenças cardíacas? Ou será alguma combinação de outros fatores que casualmente são compartilhados pelas pessoas com baixo controle no emprego, e nesse caso podemos estar completamente enganados quanto à verdadeira ameaça à saúde pública.

A análise de regressão é a ferramenta estatística que nos ajuda a lidar com esse desafio. Especificamente, a análise de regressão nos permite quantificar a relação entre uma variável específica e um resultado que nos interessa enquanto *controlamos outros fatores*. Em outras palavras, podemos isolar o efeito de uma variável, como ter certo tipo de emprego, enquanto mantemos os efeitos das outras variáveis constantes. Os estudos Whitehall usaram análise de regressão para medir os impactos sobre a saúde que o baixo controle no emprego tem entre pessoas que são similares em outros aspectos, como fumar. (Trabalhadores de baixo escalão efetivamente fumam mais que seus superiores; isso explica uma quantidade relativamente pequena da variação em doenças cardíacas através da hierarquia do Whitehall.)

A maioria dos estudos sobre os quais você lê nos jornais é baseada em análise de regressão. Quando pesquisadores concluem que crianças que passam muito tempo em creches são mais propensas a problemas comportamentais no ensino fundamental que crianças que passam esse tempo em casa, o estudo não designou aleatoriamente milhares de crianças pequenas a creches ou a ficarem em casa com um dos pais. Nem simplesmente comparou o comportamento no ensino fundamental de crianças que tiveram experiências diferentes na primeira infância sem reconhecer que essas populações provavelmente também são diferentes em outros aspectos fundamentais. Diferentes famílias tomam decisões distintas em relação a como cuidar dos filhos *porque são diferentes*. Alguns lares têm os dois pais presentes; outros não têm. Alguns têm os dois pais trabalhando; outros não têm. Alguns lares são mais ricos e mais cultos que outros. Todas essas coisas afetam a decisão de como cuidar dos filhos *e afetam o desempenho das crianças dessas famílias no ensino fundamental*. Quando feita adequadamente, a análise de regressão pode ajudar-nos a estimar os efeitos das creches separadamente de outras coisas que afetam crianças pequenas: renda familiar, estrutura familiar, educação parental, e assim por diante.

Agora, há duas expressões essenciais na última sentença. A primeira é “quando feita adequadamente”. De posse dos dados adequados e com acesso a um computador pessoal, uma criança de seis anos pode usar um programa de estatística básica para gerar resultados de regressão. O computador pessoal tornou possível realizar a parte mecânica da análise de regressão quase sem nenhum esforço. O problema é que a mecânica da análise de regressão não é a parte difícil; a parte difícil é determinar quais variáveis devem ser consideradas na análise e como isso pode ser feito da melhor maneira. A análise de regressão é uma daquelas ferramentas de poder sofisticadas. É relativamente fácil de usar, mas difícil de usar bem – e potencialmente perigosa quando usada de forma inadequada.

A segunda expressão importante acima é “ajudar-nos a estimar”. Nosso estudo de creches infantis não nos dá a resposta “certa” para a relação entre creches e subsequente desempenho escolar. Em vez disso, quantifica a relação observada *para um grupo particular de crianças durante um particular período de tempo*. Podemos tirar conclusões que possam ser aplicadas a uma população mais ampla? Sim, mas confrontaremos as mesmas limitações e qualificações que temos com qualquer outro tipo de inferência. Primeiro, a nossa amostra tem que ser

representativa da população que nos interessa. Um estudo com 2 mil crianças pequenas na Suécia não nos dirá muita coisa sobre as melhores políticas para educação na primeira infância na área rural do México. Segundo, haverá variação de uma amostra para outra. Se fizermos múltiplos estudos sobre crianças e cuidados infantis, cada estudo produzirá achados ligeiramente distintos, mesmo se as metodologias forem todas sólidas e similares.

A análise de regressão é semelhante à pesquisa de opinião. A boa notícia é que, se temos uma grande amostra representativa e uma metodologia sólida, a relação que observamos para os nossos dados da amostra provavelmente não deve se desviar muito da verdadeira relação para a população como um todo. Se 10 mil pessoas que se exercitam três ou mais vezes por semana têm índices de doenças cardiovasculares acentuadamente mais baixos do que 10 mil pessoas que não se exercitam (mas são semelhantes em todos os outros aspectos importantes), então temos muito boas chances de verificar uma associação similar entre a prática de exercícios e saúde cardiovascular para uma população mais ampla. É por isso que fazemos esses estudos. (O objetivo ao final do estudo não é dizer àqueles que não se exercitam e estão doentes que eles deveriam ter se exercitado.)

A má notícia é que não estamos provando definitivamente que exercício previne doenças cardíacas. Em vez disso, estamos rejeitando a hipótese nula de que exercícios não têm ligação com doenças cardíacas, com base num limiar estatístico escolhido antes que o estudo tenha sido conduzido. Especificamente, os autores do estudo informariam que, se a prática de exercícios não tivesse relação com a saúde cardiovascular, então a probabilidade de observar uma diferença tão acentuada na incidência de doenças cardíacas entre os que se exercitam e os que não se exercitam nessa grande amostra seria menos de cinco em cem, ou abaixo de algum outro limiar de significância estatística.

Façamos uma breve pausa para emitir nosso primeiro grande sinal de alerta. Suponha que esse estudo particular tenha comparado um grupo grande de indivíduos que jogam squash regularmente com um grupo de igual tamanho de pessoas que não fazem exercício algum. Jogar squash constitui um bom exercício cardiovascular. No entanto, sabemos também que jogadores de squash tendem a ser suficientemente ricos para serem sócios de clubes com quadras de squash. Indivíduos ricos em geral têm maior acesso a atendimento de saúde, o que também pode contribuir para a saúde cardiovascular. Se a nossa análise for desleixada, podemos atribuir os benefícios de saúde a jogar squash quando na verdade o benefício real está associado a ser rico o bastante para jogar squash (e, nesse caso, jogar polo também estaria associado a uma saúde melhor, apesar de o cavalo fazer a maior parte do trabalho).

Ou talvez a causalidade opere no sentido oposto? Será que ter um coração saudável “causa” exercício? Sim. Indivíduos enfermos, particularmente os que têm alguma forma incipiente de doença cardíaca, acham muito mais difícil se exercitar. Sem dúvida terão menos propensão a jogar squash com regularidade. Mais uma vez, se a análise for desleixada ou supersimplificada, a alegação de que exercício é bom para a sua saúde pode simplesmente refletir o fato de que pessoas que já estão doentes acham difícil fazer exercícios. Nesse caso, jogar squash não deixa ninguém mais saudável; meramente separa os saudáveis dos não saudáveis.


Há tantas armadilhas potenciais na regressão que dediquei o próximo capítulo aos erros mais escandalosos. Por enquanto, vamos focar naquilo que pode dar certo. A análise de regressão tem a surpreendente capacidade de isolar uma relação estatística que nos interessa, tal como entre o

grau de controle no emprego e doenças cardíacas, ao mesmo tempo que leva em conta outros fatores que poderiam confundir essa relação.

Como é exatamente que isso funciona? Se sabemos que funcionários públicos britânicos de baixo escalão fumam mais que seus superiores, como podemos discernir que parte da sua pobre saúde cardiovascular deve-se aos empregos de baixo nível e que parte deve-se ao fumo? Esses dois fatores parecem inextricavelmente entrelaçados.

A análise de regressão (feita adequadamente) pode desentrelaçá-los. Para explicar a intuição, preciso começar com a ideia básica subjacente a todas as formas de análise de regressão – desde as relações estatísticas mais simples até os modelos complexos compilados por ganhadores do Prêmio Nobel. Em essência, a análise de regressão busca encontrar o “melhor encaixe” para uma relação linear entre duas variáveis. Um exemplo simples é a relação entre altura e peso. Pessoas mais altas tendem a pesar mais – embora obviamente esse não seja sempre o caso. Se pusermos num gráfico as alturas e pesos de um grupo de alunos de graduação, você pode se lembrar do que foi apresentado no Capítulo 4:

Gráfico de dispersão para altura e peso




Se lhe fosse pedido que descrevesse o padrão, você poderia dizer algo mais ou menos do tipo “O peso parece aumentar com a altura”. Essa não é uma afirmação terrivelmente sagaz ou específica. A análise de regressão nos dá a possibilidade de ir além e “encaixar uma reta” que melhor descreva uma relação linear entre as duas variáveis.

Muitas retas possíveis são amplamente consistentes com os dados de altura e peso. Mas como

sabemos qual é a *melhor* reta para esses dados? Na verdade, como exatamente definimos “melhor”? A análise de regressão usa tipicamente uma metodologia chamada mínimos quadrados ordinários, ou MQO. Os detalhes técnicos, inclusive por que o MQO produz o melhor encaixe, serão deixados para um livro mais avançado. O ponto-chave reside na parte dos “mínimos quadrados” do nome; o MQO encaixa a reta que minimiza a soma dos residuais elevados ao quadrado. Não é tão complicado quanto parece. Cada observação nos nossos dados de altura e peso tem um residual, que é a distância vertical a partir da reta de regressão, exceto para aquelas observações que se situam diretamente em cima da reta, para as quais o residual vale zero. (No diagrama abaixo, o residual é mostrado para uma pessoa hipotética A.) Deveria ser intuitivo que quanto maior a soma geral dos residuais, pior é o encaixe da reta. O único detalhe não intuitivo no MQO é que a fórmula pega o *quadrado* de cada residual antes de somar todos (o que aumenta o peso dado a observações particularmente distantes da reta de regressão, ou os “*outliers*” – os extremos).

Os mínimos quadrados ordinários “encaixam” a reta que minimiza a soma dos residuais ao quadrado, conforme ilustrado abaixo.

Reta de melhor encaixe para altura e peso



Se os detalhes técnicos lhe deram dor de cabeça, você estará desculpado se entender apenas o ponto principal, que é o seguinte: os mínimos quadrados ordinários nos dão a melhor descrição de uma relação linear entre duas variáveis. O resultado não é somente uma reta, mas, como e

você pode se recordar da geometria do ensino médio, uma equação que descreve essa reta. Esta é conhecida como equação de regressão e assume a seguinte forma: $y = a + bx$, onde y é o peso em quilos; a é a intersecção da reta com o eixo y (valor de y quando $x = 0$); b é a inclinação da reta; e x é a altura em centímetros. A inclinação da reta que encaixamos, b , descreve a “melhor” relação linear entre altura e peso para essa amostra, conforme definida pelos mínimos quadrados ordinários.

A reta de regressão com certeza não descreve perfeitamente toda observação nos dados. Mas é a melhor descrição que podemos obter para o que é claramente uma relação significativa entre altura e peso. Significa também que toda observação pode ser explicada como $\text{peso} = a + b(\text{ALTURA}) + e$, onde e é um “residual” que capta a variação no peso de cada indivíduo que não é explicada pela altura. Finalmente, significa que o nosso melhor palpite para o peso de qualquer pessoa no conjunto de dados seria $a + b(\text{ALTURA})$. Mesmo que a maioria das observações não se situe exatamente em cima da reta de regressão, o residual ainda tem um valor esperado de zero, uma vez que qualquer pessoa na amostra tem a mesma probabilidade de pesar mais ou de pesar menos do que prediz a equação de regressão.

Basta de jargão teórico! Vamos dar uma olhada em alguns dados reais de altura e peso provenientes do estudo Changing Lives, embora eu deva antes clarificar alguma terminologia básica. A variável que está sendo explicada – o peso, nesse caso – é conhecida como variável dependente (porque depende de outros fatores). As variáveis que estamos usando para explicar a nossa variável dependente são conhecidas como variáveis explicativas, pois explicam o resultado que nos interessa. (Só para dificultar mais as coisas, as variáveis explicativas às vezes também são chamadas de variáveis independentes ou variáveis de controle.) Começamos usando a altura para explicar o peso entre os participantes do Changing Lives; posteriormente adicionaremos outros fatores explicativos potenciais.^a Há 3.537 participantes adultos no estudo Changing Lives. Esse é o nosso número de observações, ou n . (Às vezes um artigo de pesquisa pode dizer que $n = 3.537$.) Quando traçamos uma regressão simples nos dados do Changing Lives com o peso como variável dependente e a altura como única variável explicativa, obtemos os seguintes resultados:

$$\text{peso} = -60 + (0,8) \times \text{altura em centímetros}$$

$a = -60$. Esta é a intersecção com o eixo y , que não tem significado particular em si. (Se você interpretar literalmente, uma pessoa que mede zero centímetro de altura pesaria sessenta quilos negativos; obviamente isso é absurdo em vários níveis.) Esse número também é conhecido como a constante, porque é o ponto de partida para calcular o peso para todas as observações no estudo.

$b = 0,8$. Nossa estimativa para $b = 0,8$ é conhecida como coeficiente de regressão, ou, em jargão estatístico, “o coeficiente sobre a altura”, porque nos dá a melhor estimativa para a relação entre altura e peso entre os participantes do Changing Lives. O coeficiente de regressão tem uma interpretação conveniente: um acréscimo de uma unidade na variável independente (altura) está associado a um acréscimo de 0,8 unidade na variável dependente (peso). Para a nossa amostra de dados, isso significa que um aumento de um centímetro na altura está associado a um aumento de 0,8 quilo no peso. Logo, se não tivéssemos nenhuma outra informação, nosso melhor palpite para o peso de uma pessoa que tem 1,75 metro (175 centímetros) no estudo

Changing Lives seria $-60 + 0,8 \times 175 = 80$ quilos.

Essa é a nossa recompensa, pois agora quantificamos o melhor encaixe para a relação linear entre altura e peso para os participantes do Changing Lives. As mesmas ferramentas básicas podem ser usadas para explorar relações mais complexas e questões socialmente mais significativas. Para qualquer coeficiente de regressão, você geralmente estará interessado em três coisas: sinal, tamanho e significância.

Sinal. O sinal (positivo ou negativo) do coeficiente para uma variável independente nos diz o sentido da associação com a variável dependente (o resultado que estamos tentando explicar). No caso simples acima, o coeficiente sobre a altura é positivo. Pessoas mais altas tendem a pesar mais. Algumas relações funcionam no sentido oposto. Eu esperaria que a associação entre exercício e peso fosse negativa. Se o estudo Changing Lives incluísse dados sobre algo como “quilômetros corridos por mês”, tenho praticamente certeza de que o coeficiente sobre “quilômetros corridos” seria negativo. Correr mais está associado a pesar menos.

Tamanho. Qual é o tamanho do efeito observado entre a variável independente e a variável dependente? É de uma magnitude relevante? Nesse caso, cada centímetro da altura está associado a 0,8 quilo, que é uma porcentagem considerável do peso corporal de uma pessoa típica. Numa explicação sobre por que algumas pessoas pesam mais que outras, a altura é nitidamente um fator importante. Em outros estudos, poderemos achar uma variável explicativa que tenha impacto estatisticamente significativo no nosso resultado de interesse – o que significa que o efeito observado provavelmente não é produto do acaso –, mas esse efeito poderá ser tão pequeno a ponto de ser considerado trivial ou *socialmente insignificante*. Por exemplo, suponha que estejamos examinando determinantes de renda. Por que algumas pessoas ganham mais dinheiro que outras? As variáveis explicativas são provavelmente coisas como educação, anos de experiência profissional, e assim por diante. Num grande conjunto de dados, os pesquisadores poderão também descobrir que pessoas com dentes mais brancos ganham US\$86 por ano a mais que outros trabalhadores, *ceteris paribus*. (“*Ceteris paribus*” é latim e significa “as outras coisas sendo iguais”.) O coeficiente positivo e estatisticamente significativo sobre a variável “dentes mais brancos” pressupõe que os indivíduos sendo comparados são similares em outros aspectos: mesma educação, mesma experiência profissional, e assim por diante. (Daqui a um instante explicarei como realizamos esse impressionante feito.) Nossa análise estatística demonstrou que dentes mais brancos estão associados a US\$86 de acréscimo na renda anual e que esse achado não parece ser mera coincidência. Isso significa que (1) rejeitamos a hipótese nula de que dentes brancos realmente não têm associação alguma com a renda, com alto grau de confiança; e (2) se analisarmos outras amostras de dados, provavelmente descobriremos uma relação similar entre dentes bonitos e renda mais alta.

E daí? Achemos um resultado estatisticamente expressivo, mas não que seja particularmente significativo. Para começar, US\$86 por ano não é uma quantia capaz de mudar a vida de ninguém. Do ponto de vista de políticas públicas, US\$86 também é provavelmente menos do que custaria para branquear os dentes de um indivíduo todo ano, então não podemos sequer recomendar que trabalhadores jovens façam tal investimento. E, embora esteja me antecipando um capítulo, eu também ficaria preocupado com alguns sérios problemas metodológicos. Por exemplo, ter dentes perfeitos pode estar associado a outros traços de personalidade que expliquem a vantagem nos rendimentos; o efeito de rendimentos pode ser causado pelo tipo de

gente que se preocupa com os dentes, não com os dentes em si. Por enquanto, o ponto é que devemos tomar nota do tamanho da associação que observamos entre a variável explicativa e o nosso resultado de interesse.

Significância. Será que o resultado observado é uma aberração baseada numa amostra de dados peculiar ou será que reflete uma associação significativa provável de ser observada para a população como um todo? Essa é a mesma pergunta básica que estamos fazendo ao longo dos últimos diversos capítulos. No contexto de altura e peso, pensamos que observaríamos uma associação positiva similar em outras amostras que sejam representativas da população? Para responder a essa pergunta, usamos as ferramentas básicas de inferência que já foram introduzidas. Nosso coeficiente de regressão baseia-se numa relação observada entre altura e peso para uma amostra particular de dados. Se fôssemos testar outra amostra grande de dados, quase com certeza obteríamos uma associação ligeiramente diferente entre altura e peso e, portanto, um coeficiente diferente. A relação entre altura e peso observada nos dados Whitehall (envolvendo os funcionários públicos britânicos) é provavelmente distinta da relação entre altura e peso observada nos participantes do estudo Changing Lives. No entanto, sabemos pelo teorema do limite central que a média para uma amostra grande, adequadamente tirada, em geral não se desviará muito da média da população como um todo. De maneira semelhante, podemos presumir que a relação observada entre variáveis como altura e peso em geral não oscilará muito de uma amostra para outra, pressupondo que essas amostras sejam grandes e adequadamente tiradas da mesma população.

Pense na intuição: é bastante improvável (embora ainda assim possível) que viéssemos a descobrir que cada centímetro de altura está associado a 0,8 quilo adicional entre os participantes do Changing Lives, mas que não existe associação entre altura e peso em alguma outra amostra representativa de 3 mil adultos americanos.

Isso deve proporcionar a você o primeiro lampejo de como testaremos se os nossos resultados de regressão são estatisticamente significativos ou não. Como em pesquisas de opinião e outras formas de inferência, podemos calcular um erro padrão para o coeficiente de regressão. O erro padrão é uma medida da dispersão provável que observaríamos no coeficiente se fôssemos conduzir a análise de regressão em amostras repetidas tiradas da mesma população. Se fôssemos medir e pesar outra amostra de 3 mil americanos, poderíamos descobrir na análise subsequente que cada centímetro de altura está associado com 0,7 quilo. Se fizéssemos a mesma coisa com outra amostra de 3 mil americanos, poderíamos descobrir que cada centímetro está associado com um quilo. Mais uma vez, a distribuição normal é nossa amiga. Para amostras grandes de dados, tais como o nosso conjunto de dados do Changing Lives, podemos presumir que os nossos vários coeficientes estarão distribuídos normalmente em torno da “verdadeira” associação entre altura e peso na população adulta americana. Com essa premissa, podemos calcular um erro padrão para o coeficiente de regressão que nos dê um senso de quanta dispersão podemos esperar nos coeficientes de uma amostra para outra. Não vou me aprofundar na fórmula de calcular o erro padrão aqui, não só porque nos desviará para uma direção que envolve muita matemática, mas também porque todos os pacotes básicos de estatística podem fazer os cálculos para você.

Todavia, devo advertir que, quando estamos trabalhando com uma amostra pequena de dados – tal como um grupo de vinte adultos em vez das mais de 3 mil pessoas no estudo Changing Lives

–, a distribuição normal não está mais disposta a ser nossa amiga. Especificamente, se conduzimos repetidamente análises de regressão em diferentes amostras pequenas, não podemos mais presumir que os nossos vários coeficientes estarão distribuídos normalmente em torno da “verdadeira” associação entre altura e peso na população adulta americana. Em vez disso, nossos coeficientes ainda estarão distribuídos em torno da “verdadeira” associação entre altura e peso para a população adulta americana naquela que é conhecida como distribuição t. (Basicamente, a distribuição t é mais dispersa que a distribuição normal e, portanto, tem “caudas mais gordas”.) Nada mais muda; qualquer pacote básico de estatística resolverá facilmente a complexidade adicional associada com o uso de distribuições t. Por esse motivo, a distribuição t será explicada mais detalhadamente no apêndice do capítulo.

Mantendo por enquanto o foco em amostras maiores (e, portanto, na distribuição normal), o fundamental é compreender por que o erro padrão tem importância. Da mesma maneira que ocorre nas pesquisas de opinião e outras formas de inferência, esperamos que mais da metade dos nossos coeficientes de regressão se situe dentro de um erro padrão a partir do verdadeiro parâmetro da população.^b Aproximadamente 95% se situarão dentro de dois erros padrões. E assim por diante. Com isso, quase chegamos lá, porque agora podemos fazer um pouquinho de teste de hipótese. (Falando sério, você achou mesmo que já tinha se livrado dos testes de hipótese?) Uma vez que temos um coeficiente e um erro padrão, podemos testar a hipótese nula de que não existe de fato nenhuma relação entre a variável explicativa e a variável dependente (o que quer dizer que a verdadeira associação entre as duas variáveis na população é zero).

No nosso exemplo simples de altura e peso, podemos testar a probabilidade de descobrir na nossa amostra do Changing Lives que cada centímetro está associado com 0,8 quilo se não existir realmente nenhuma associação entre altura e peso na população geral. Calculei a regressão usando um programa básico de estatística; o erro padrão sobre o coeficiente da altura é 0,05. Isso significa que, se fôssemos fazer essa análise repetidamente – digamos com cem amostras diferentes –, então seria de esperar que o nosso coeficiente de regressão estivesse dentro de dois erros padrões do verdadeiro parâmetro da população aproximadamente 95 vezes em cem.

Podemos, portanto, expressar os nossos resultados de duas maneiras diferentes, porém correlatas. Primeiro, podemos construir um intervalo de confiança de 95%. Podemos dizer que 95 vezes em cem esperamos que o nosso intervalo de confiança, que é $0,8 \pm 0,05$, contenha o verdadeiro parâmetro da população. Esse intervalo varia entre 0,75 e 0,85. Um pacote básico de estatística calculará também esse intervalo. Segundo, podemos ver que o nosso intervalo de confiança de 95% para a verdadeira associação entre altura e peso não inclui o zero. Logo, podemos rejeitar a hipótese nula de que não existe *nenhuma associação* entre altura e peso para a população geral num nível de confiança de 95%. Esse resultado pode ser expresso também como sendo estatisticamente significativo no nível 0,05; há somente 5% de chance de estarmos errados rejeitando a hipótese nula.

Na verdade, nossos resultados são ainda mais extremos que isso. O erro padrão (0,05) é extremamente baixo em relação ao tamanho do coeficiente (0,8). Uma regra prática grosseira é que o coeficiente tem probabilidade de ser estatisticamente significativo quando é pelo menos o dobro do valor do erro padrão.^c Um pacote de estatística também calcula o valor-p, que nesse caso é 0,000, o que significa que essencialmente há zero chance de obter um resultado tão (ou

mais) extremo quanto o que observamos se não houver uma associação real entre altura e peso na população geral. Lembre-se, não *provamos* que pessoas mais altas pesam mais na população geral, meramente mostramos que os nossos resultados para a amostra do Changing Lives seriam extremamente anômalos se esse não fosse o caso.

NOSSA ANÁLISE DE REGRESSÃO básica produz ainda outra estatística digna de nota: o R^2 , que é uma medida do tamanho total de variação explicado pela equação de regressão. Sabemos que temos uma ampla variação de peso na nossa amostra do Changing Lives. Muitas das pessoas na amostra pesam mais que a média para o grupo todo; muitas pesam menos. O R^2 nos diz quanto dessa variação em torno da média está associado apenas com diferenças de altura. No nosso caso, a resposta é 0,25, ou 25%. O ponto mais significativo pode ser que 75% da variação em peso para a nossa amostra permanece inexplicada. Existem claramente outros fatores além da altura que poderiam nos ajudar a entender os pesos dos participantes do Changing Lives. É aí que as coisas ficam mais interessantes.

Admito que comecei este capítulo vendendo a análise de regressão como o elixir milagroso da pesquisa em ciências sociais. Até aqui tudo que fiz foi usar um pacote de estatística e um conjunto impressionante de dados para demonstrar que gente alta pesa mais que gente baixa. Uma breve ida a um shopping provavelmente convenceria você da mesma coisa. Agora que você entende os fundamentos, podemos liberar o poder real da análise de regressão. É hora de botar os pneus de corrida!

Conforme prometi, a análise de regressão nos permite deslindar relações complexas nas quais fatores múltiplos afetam algum resultado que nos interessa, tal como renda, resultados de testes ou doenças do coração. Quando incluímos múltiplas variáveis na equação de regressão, a análise nos dá uma estimativa da associação linear entre *cada* variável explicativa e a variável dependente, enquanto mantemos outras variáveis dependentes constantes, ou “controlamos” esses outros fatores. Vamos nos ater por enquanto ao peso. Encontramos uma associação entre altura e peso; sabemos que há outros fatores que podem ajudar a explicar o peso (idade, sexo, alimentação, exercício, e assim por diante). A análise de regressão (frequentemente chamada análise de regressão múltipla quando há mais de uma variável explicativa envolvida, ou análise de regressão multivariada) nos dá um coeficiente para cada variável explicativa incluída na equação de regressão. Em outras palavras, *entre as pessoas que têm o mesmo sexo e idade*, qual é a relação entre idade e peso? Como temos mais de uma variável explicativa, não podemos mais representar esses dados num gráfico de duas dimensões. (Tente imaginar um gráfico que represente o peso, sexo, altura e idade de cada participante do estudo Changing Lives.) Contudo, a metodologia básica é igual à do nosso exemplo simples de altura e peso. Quando adicionarmos variáveis explicativas, um pacote estatístico calculará os coeficientes de regressão que minimizam a soma total dos residuais ao quadrado para a equação de regressão.

Trabalhemos por enquanto com os dados do Changing Lives; depois voltarei para lhe dar uma explicação intuitiva sobre como essa separação estatística do mar Vermelho pode funcionar. Podemos começar adicionando mais uma variável à equação que explica os pesos dos participantes do Changing Lives: idade. Quando escrevemos a regressão incluindo tanto altura quanto idade como variáveis explicativas para o peso, eis o que obtemos:

$$\text{PESO} = -66 + 0,82 \times (\text{ALTURA EM CENTÍMETROS}) \\ + 0,05 \times (\text{IDADE EM ANOS})$$

O coeficiente sobre a idade é 0,05. Isso pode ser interpretado como significando que cada ano adicional na idade é associado a 0,05 quilo (cinquenta gramas) adicional no peso, *mantendo a altura constante*. Em qualquer grupo de pessoas que tenham a mesma altura, aquelas que são dez anos mais velhas em média pesarão 0,5 quilo a mais. Não é um efeito enorme, mas é consistente com o que tendemos a ver na vida. O coeficiente é significativo no nível 0,05.

Você pode ter notado que o coeficiente sobre a altura aumentou ligeiramente. Incluindo a idade na nossa regressão, temos uma compreensão mais refinada da relação entre altura e peso. Entre pessoas da mesma idade na nossa amostra, ou “mantendo a idade constante”, cada centímetro adicional na altura está associado com 0,82 quilo a mais no peso.

Vamos adicionar mais uma variável: sexo. Esta será levemente diferente porque o sexo pode ter apenas duas possibilidades: masculino ou feminino. Como colocar M ou F numa regressão? A resposta é que usamos o que se chama de variável binária, ou variável simulada (*dummy variable*).^d No nosso conjunto de dados, entramos com 1 quando os participantes forem do sexo feminino e com 0 para os participantes do sexo masculino. (Não há intenção aqui de qualquer julgamento de valor.) O coeficiente de sexo pode ser então interpretado como o efeito que o fato de ser mulher exerce sobre o peso, *ceteris paribus*. O coeficiente é -2,2, o que não constitui surpresa. Podemos interpretar esse número como significando que, para indivíduos de mesma altura e idade, as mulheres tipicamente pesam 2,2 quilos a menos que os homens. Agora podemos começar a ver parte do poder da análise de regressão múltipla. Sabemos que mulheres tendem a ser mais baixas que homens, mas o nosso coeficiente leva isso em conta, pois já controlamos a altura. O que isolamos aqui é o efeito de ser mulher. A nova regressão fica:

$$\text{PESO} = -54 + 0,79 \times (\text{ALTURA EM CENTÍMETROS}) + 0,06 \times (\text{IDADE EM ANOS}) - 2,2 \text{ (SE FOR DO SEXO FEMININO)}$$

Nossa melhor estimativa para o peso de uma mulher de 53 anos com 1,62 metro de altura é: $-54 + 0,79 \times (162) + 0,06 \times (53) - 2,2 = -54 + 128 + 3,2 - 2,2 = 75$ quilos.

E o nosso melhor palpite para um homem de 35 anos com 1,88 metro de altura é: $-54 + 0,79 \times (188) + 0,06 \times (35) = -54 + 147,9 + 2,1 = 96$ quilos. Pulamos o último termo na nossa regressão (-2,2), pois não se trata de uma mulher.

AGORA podemos começar a testar coisas que são mais interessantes e menos previsíveis. Que tal educação? Como ela poderia afetar o peso? Eu faria a hipótese de que indivíduos mais bem-educados têm mais consciência sobre a saúde e, portanto, pesarão menos, *ceteris paribus*. E também ainda não testamos nenhuma medida de exercício; presumo que, mantendo outros fatores constantes, as pessoas na amostra que fazem mais exercício pesarão menos.

E a pobreza? Será que ser pobre nos Estados Unidos tem efeitos que se manifestam no peso? O estudo Changing Lives pergunta se os participantes recebem vale-alimentação, que é uma boa medida de pobreza nos Estados Unidos. Finalmente, estou interessado em raça. Sabemos que pessoas negras têm diferentes experiências de vida nos Estados Unidos *por causa da raça*. Há

fatores culturais e de moradia associados à raça nos Estados Unidos que têm implicações para o peso. Muitas cidades ainda se caracterizam por um alto grau de segregação racial; afro-americanos podem ter maior probabilidade do que outros moradores de viver em “desertos alimentares”, que são áreas com acesso limitado a mercearias que vendem frutas, verduras e outros produtos frescos.

Podemos usar a análise de regressão para separar os efeitos independentes de cada um dos fatores explicativos potenciais descritos acima. Por exemplo, podemos isolar a associação entre raça e peso, mantendo constantes outros atores socioeconômicos, como histórico educacional e pobreza. *Entre pessoas que terminaram o ensino médio e são elegíveis para receber vale-alimentação, qual é a associação estatística entre peso e ser negro?*

A esta altura, a nossa equação de regressão é tão longa que seria um trambolho imprimir aqui os resultados inteiros. Artigos acadêmicos costumam inserir grandes tabelas para sintetizar os resultados das várias equações de regressão. Incluí uma tabela com os resultados completos dessa equação de regressão no apêndice deste capítulo. Entrementes, eis os destaques do que acontece quando adicionamos educação, exercício, pobreza (medida pelo recebimento de vale-alimentação) e raça à nossa equação.

Todas as nossas variáveis originais (altura, idade e sexo) ainda são significativas. Os coeficientes mudam pouco quando adicionamos novas variáveis explicativas. Todas as nossas novas variáveis são estatisticamente significantes num nível 0,05. O R^2 sobre a regressão subiu de 0,25 para 0,29. (Lembre-se, um R^2 de 0 significa que a nossa equação de regressão não é melhor que a média para predizer o peso de qualquer indivíduo na amostra; um R^2 de 1 significa que a equação de regressão prediz perfeitamente o peso de toda pessoa na amostra.) Grande parte da variação de peso entre os indivíduos permanece inexplicada.

A educação revela ser negativamente associada com o peso, conforme a minha hipótese. Entre os participantes no estudo Changing Lives, cada ano de educação é associado com $-0,6$ quilo.

Não é surpresa que o exercício também tenha uma associação negativa com o peso. O estudo Changing Lives inclui um índice que avalia cada participante conforme seu nível de atividade física. Os indivíduos que estão no quintil inferior para atividade física pesam, em média, 2,1 quilos a mais que outros adultos na amostra, *ceteris paribus*. Os que se encontram no quintil inferior para atividade física pesam, em média, perto de 4,1 quilos a mais que os adultos no quintil superior para atividade física.

Indivíduos que recebem vale-alimentação (o sinal de pobreza nessa regressão) são mais pesados que outros adultos. Portadores de vale-alimentação pesam em média 2,6 quilos a mais que outros participantes do Changing Lives, *ceteris paribus*.

A variável raça revela-se particularmente interessante. Mesmo que se controlem todas as outras variáveis descritas até este ponto, a raça ainda influi muito quando se trata de explicar o peso. Os adultos negros não hispânicos na amostra do Changing Lives pesam, em média, aproximadamente 4,5 quilos a mais que outros adultos na amostra. Quatro quilos e meio é muito peso, tanto em termos absolutos quanto em comparação com os efeitos de outras variáveis explicativas na equação de regressão. Não é uma esquisitice dos dados. O valor-p da variável *dummy* para negros não hispânicos é 0,000 e o intervalo de confiança de 95% se estende de 3,5 a 7,3 quilos.

O que está acontecendo? Sinceramente, não tenho a menor ideia. Deixe-me reiterar um ponto que ficou soterrado numa nota de rodapé anterior: estou aqui só brincando com dados para ilustrar como funciona a análise de regressão. A análise aqui apresentada é para a verdadeira pesquisa acadêmica o que o hóquei de rua é para a Liga Nacional Americana de Hóquei (NHL, na sigla em inglês). Se este fosse um projeto de pesquisa real, haveria semanas ou meses de análise complementar para sondar esse achado. O que posso dizer é que demonstrei por que a análise de regressão múltipla é a melhor ferramenta que temos para encontrar padrões significativos em grandes e complexos conjuntos de dados. Começamos com um exercício ridiculamente banal: quantificar a relação entre altura e peso. Não demorou muito para estarmos metidos até os joelhos em assuntos de real relevância social.

Nessa linha, posso lhes oferecer um estudo real que utilizou a análise de regressão para sondar um assunto socialmente significativo: discriminação de gênero no local de trabalho. O curioso em relação à discriminação é que ela é difícil de observar diretamente. Nenhum empregador jamais afirma explicitamente que alguém está recebendo salário menor por causa de sua raça ou gênero, ou que alguém não foi contratado por razões discriminatórias (o que presumivelmente deixaria a pessoa em outro emprego com um salário mais baixo). Em vez disso, o que observamos são diferenças de pagamento por raça e gênero que podem ser resultado de discriminação: brancos ganham mais que negros; homens ganham mais que mulheres; e assim por diante. O desafio metodológico é que essas diferenças observadas podem ser também resultantes de diferenças subjacentes entre os trabalhadores que nada têm a ver com discriminação no local de trabalho, tais como o fato de mulheres tenderem a optar mais por trabalho em período parcial. Quanto dessa diferença de salários se deve a fatores associados à produtividade no emprego, e quanto da diferença, se houver, se deve à discriminação na força de trabalho? Ninguém pode alegar que se trata de uma questão trivial.

A análise de regressão pode nos ajudar na resposta. Entretanto, a nossa metodologia será ligeiramente mais arredondada do que foi na nossa análise explicando o peso. Como não podemos medir discriminação diretamente, examinaremos outros fatores que tradicionalmente explicam os salários, tais como educação, experiência, campo ocupacional, entre outros. Discriminação é um caso circunstancial: se uma diferença salarial significativa continuar a prevalecer depois de se controlarem os outros fatores que tipicamente explicam os salários, a discriminação é uma provável culpada. Quanto maior a porção inexplicada de qualquer diferença salarial, mais desconfiados devemos ficar. Como exemplo, vamos dar uma olhada num artigo de três economistas que examinam as trajetórias salariais de uma amostra de aproximadamente 2,5 mil homens e mulheres que se graduaram com MBA da Booth School of Business da Universidade de Chicago.¹ Ao se graduarem, homens e mulheres têm salários anuais médios iniciais muito semelhantes: US\$130 mil para os homens e US\$115 mil para as mulheres. No entanto, dez anos depois na força de trabalho, abriu-se uma enorme fenda: as mulheres estão ganhando em média espantosos 45% menos que seus colegas de classe do sexo masculino: US\$243 mil versus US\$442 mil. Numa amostra mais ampla, de mais de 18 mil graduados de MBA que entraram na força de trabalho entre 1990 e 2006, ser mulher está associado a um ganho 29% mais baixo. O que acontece com as mulheres uma vez que começam a trabalhar?

Segundo os autores do estudo (Marianne Bertrand, da Booth School of Business, Claudia

Goldin e Lawrence Katz, de Harvard), discriminação *não* é uma explicação provável para a maior parte da diferença. A diferença salarial em gênero vai sumindo à medida que os autores adicionam mais variáveis explicativas à análise. Por exemplo, os homens pegam mais cursos de finanças em programas de MBA e se graduam com médias de notas mais altas. Quando esses dados são incluídos como variáveis de controle na equação de regressão, a porção inexplicada da diferença entre salários de homens e mulheres cai para 19%. Quando são adicionadas à equação variáveis que levam em conta a experiência profissional pós-MBA, particularmente períodos fora da força de trabalho, a porção inexplicada da diferença salarial entre homens e mulheres cai para 9%. E quando são adicionadas variáveis explicativas para outras características de trabalho, tais como tipo de empregador e horas trabalhadas, a porção inexplicada para a diferença salarial em termos de gênero cai para menos de 4%.

Para trabalhadores que têm participado da força de trabalho por mais de dez anos, os autores conseguem explicar, em última instância, tudo exceto 1% da diferença salarial com fatores não relacionados com discriminação no emprego.^c Eles concluem: “Identificamos três razões aproximadas para a grande e crescente diferença nos ganhos: diferenças em qualificação anteriores à graduação no MBA; diferenças em termos de interrupção de carreira; e diferenças em horas semanais trabalhadas. Esses três determinantes podem explicar o grosso das diferenças salariais em gênero ao longo dos anos que se seguem ao término do MBA.”

ESPERO TER CONVENCIDO você do valor da análise de regressão múltipla, particularmente os insights de pesquisa que brotam de se poder isolar o efeito de uma variável explicativa enquanto controlamos os outros fatores envolvidos. Ainda não forneci uma explicação intuitiva para como funciona esse “elixir milagroso” estatístico. Quando usamos análise de regressão para avaliar a relação entre educação e peso, *ceteris paribus*, como um pacote estatístico mantém sob controle os fatores como altura, sexo, idade e renda quando sabemos que os nossos participantes do Changing Lives *não* são idênticos nesses outros aspectos?

Para lhe dar uma noção de como podemos isolar o efeito sobre o peso de uma única variável, digamos, educação, imagine a seguinte situação: suponha que todos os participantes do Changing Lives sejam reunidos num mesmo lugar – Framingham, Massachusetts, por exemplo. Agora imagine que homens e mulheres sejam separados. Suponha também que tanto homens como mulheres sejam divididos por altura. Haverá uma sala para homens de 1,80 metro de altura. Na sala ao lado, estarão reunidos os homens de 1,81 metro, e assim por diante para ambos os gêneros. Se tivermos participantes suficientes no estudo, podemos subdividir cada uma dessas salas por renda. Acabaremos tendo uma porção de salas, cada uma contendo indivíduos que são idênticos em todos os aspectos, *exceto educação e peso, que são as duas variáveis que nos interessam*. Haveria uma sala para homens de 45 anos com 1,65 metro que ganham de US\$30 mil a US\$40 mil por ano. Ao lado, estariam mulheres de 45 anos com 1,65 metro de altura que ganham de US\$30 mil a US\$40 mil por ano. E assim por diante (por diante e por diante).

Ainda assim haverá alguma variação em peso dentro de cada sala; pessoas do mesmo sexo e altura com a mesma renda ainda assim terão pesos de valores diferentes – embora presumivelmente deva haver muito menos variação no peso em cada sala do que na amostra total. Nossa meta agora é ver quanto da variação restante do peso em cada sala pode ser

explicada pela educação. Em outras palavras, qual é a melhor relação linear entre educação e peso em cada sala?

O desafio final, porém, é que não queremos coeficientes diferentes em cada “sala”. O principal ponto desse exercício é calcular um único coeficiente que melhor expresse a relação entre educação e peso para a amostra toda, mantendo os outros fatores constantes. O que gostaríamos de calcular é o coeficiente único para a educação que possamos usar *em toda sala* para minimizar a soma dos residuais ao quadrado para todas as salas combinadas. Que coeficiente para a educação minimiza o quadrado do peso inexplicado para cada indivíduo em todas as salas? Este torna-se o nosso coeficiente de regressão porque é a melhor explicação da relação linear entre educação e peso para essa amostra quando mantemos sexo, idade e renda constantes.

Como aparte, você pode ver por que grandes conjuntos de dados são tão úteis. Eles nos permitem controlar muitos fatores e ao mesmo tempo dispor de muitas observações em cada “sala”. Obviamente um computador pode fazer tudo isso numa fração de segundo sem distribuir milhares de pessoas em montes de salas diferentes.

VAMOS ENCERRAR O CAPÍTULO onde começamos, com a conexão entre estresse no emprego e doença cardíaca coronária. Os estudos Whitehall de funcionários públicos britânicos buscaram mensurar a associação entre escalão de emprego e morte por doença cardíaca coronária nos anos subsequentes. Um dos primeiros estudos acompanhou 17.530 funcionários por 7,5 anos.² Os autores concluíram que: “Homens nos escalões mais baixos de emprego eram mais baixos, mais pesados em relação à sua altura, tinham pressão sanguínea mais elevada, maior taxa de glicose no sangue, fumavam mais e relatavam menos atividade física em horas de lazer do que homens nos escalões mais altos. Todavia, mesmo fazendo-se o desconto da influência de todos esses fatores, incluindo ainda colesterol no sangue, sobre a mortalidade, ainda era forte a associação entre o escalão de emprego e mortalidade [devida a doença cardíaca coronária].” O “desconto” a que eles se referem para esses outros fatores de risco conhecidos é feito por meio da análise de regressão.^f O estudo demonstra que, mantendo os outros fatores de saúde constantes (inclusive altura, que é um indicador representativo para saúde e nutrição na primeira infância), trabalhar num emprego de “baixo escalão” pode literalmente nos matar.

Ceticismo é sempre uma boa primeira reação. Escrevi no início do capítulo que empregos de “baixo controle” são ruins para a saúde. Isso pode ou não ser sinônimo de estar na base do totem administrativo. Um estudo usando uma segunda amostra de 10.308 funcionários públicos britânicos buscou aprofundar-se nessa distinção.³ Os trabalhadores foram mais uma vez divididos em escalões administrativos – alto, intermediário e baixo –, só que dessa vez os participantes também receberam um questionário de quinze itens que avaliava o nível de “controle ou latitude de decisão”. O questionário incluía perguntas como “Você tem escolha para decidir como fazer seu serviço?” e respostas categóricas (variando de “nunca” para “frequentemente”) para afirmações do tipo “Eu posso decidir quando fazer um intervalo”. Os pesquisadores descobriram que trabalhadores de “baixo controle” tinham um risco muito mais alto de desenvolver alguma doença cardíaca coronária no decorrer do estudo do que os trabalhadores de “alto controle”. Contudo, os pesquisadores também descobriram que trabalhadores com rigorosas exigências no

emprego não tinham maior risco de desenvolver doença cardíaca e tampouco trabalhadores que informaram baixos níveis de apoio social no emprego. Falta de controle parece ser o assassino, literalmente.

Os estudos Whitehall têm duas características tipicamente associadas com uma pesquisa robusta. Primeira, os resultados foram replicados em outros lugares. Na literatura sobre saúde pública, a ideia de “baixo controle” evoluiu para se tornar um termo conhecido como “estresse no emprego”, que caracteriza empregos com “elevadas exigências psicológicas na carga de trabalho” e “baixa latitude de decisão”. Entre 1981 e 1993, foram publicados 36 estudos sobre o assunto; a maioria encontrou uma significativa associação positiva entre estresse no emprego e doença cardíaca.⁴

Segunda, os pesquisadores buscaram e encontraram evidência biológica corroboradora para explicar o mecanismo pelo qual esse tipo de estresse particular no emprego gera uma saúde ruim. Condições de trabalho que envolvem exigências rigorosas, mas baixo controle, podem provocar respostas fisiológicas (tais como liberação de hormônios relacionados com o estresse) que aumentam o risco de doença cardíaca no longo prazo. Mesmo a pesquisa animal desempenha algum papel; macacos e babuínos de baixa posição hierárquica (que guardam certa semelhança com os funcionários públicos na base da cadeia de autoridade) têm diferenças fisiológicas em relação a seus semelhantes de status elevado, diferenças essas que os colocam em condição de maior risco cardiovascular.⁵

Todo o resto sendo igual, é melhor não ser um babuíno de baixo status, que é um ponto que procuro enfatizar para os meus filhos com a maior frequência possível, particularmente meu filho. A mensagem mais ampla aqui é que a análise de regressão é indiscutivelmente a ferramenta mais importante que os pesquisadores possuem para encontrar padrões significativos em grandes conjuntos de dados. Geralmente não podemos fazer experimentos controlados para entender sobre discriminação no emprego ou fatores que causam doença cardíaca. Nossas percepções acerca desses assuntos socialmente significativos, bem como muitos outros, provêm das ferramentas estatísticas apresentadas neste capítulo. Na verdade, não seria exagero dizer que uma alta proporção de toda a pesquisa importante feita em ciências sociais no último meio século (particularmente desde o advento de computadores poderosos baratos) se baseia na análise de regressão.

A análise de regressão amplifica enormemente o método científico; como resultado, somos mais saudáveis, seguros e bem informados.


Então, o que possivelmente poderia sair errado com essa poderosa e impressionante ferramenta? Continue lendo.

APÊNDICE AO CAPÍTULO 11

A distribuição t

A vida fica um pouquinho mais complicada quando fazemos a nossa análise de regressão (ou outras formas de inferência estatística) com uma amostra pequena de dados. Suponha que estivéssemos analisando a relação entre peso e altura com base numa amostra de apenas 25 adultos, em vez de usar um conjunto de dados enorme como o estudo Changing Lives. A lógica sugere que devemos ter menos confiança em generalizar os nossos resultados para a população adulta inteira a partir de uma amostra de 25 do que a partir de uma amostra de 3 mil. Um dos temas ao longo deste livro tem sido que amostras menores tendem a gerar mais dispersão nos resultados. Nossa amostra de 25 ainda nos dará informação significativa, como daria uma amostra de cinco ou dez – mas quão significativa?

A distribuição t responde a essa pergunta. Ao analisarmos a associação entre altura e peso para repetidas amostras de 25 adultos, não podemos mais presumir que os vários coeficientes obtidos para altura estejam distribuídos normalmente em torno do “verdadeiro” coeficiente para a altura na população adulta. Eles ainda estarão distribuídos em torno do coeficiente verdadeiro para toda a população, *mas o formato dessa distribuição não será a nossa familiar curva normal em forma de sino*. Em vez disso, temos de pressupor que repetidas amostras de 25 produzirão mais dispersão ao redor do coeficiente verdadeiro da população – e portanto uma distribuição com “caudas mais grossas”. E repetidas amostras de dez produzirão uma dispersão ainda maior – e portanto caudas ainda mais grossas. A distribuição t é na verdade uma série, ou “família”, de funções de densidade de probabilidade que variam segundo o tamanho da nossa amostra. Especificamente, quanto mais dados temos na nossa amostra, mais “graus de liberdade” temos ao determinar a distribuição apropriada em relação à qual avaliamos os nossos resultados. Numa aula mais avançada, você aprenderá exatamente como calcular graus de liberdade; para o nosso propósito, eles são quase iguais ao número de observações da amostra. Por exemplo, uma análise de regressão básica com uma amostra de dez e uma única variável explicativa tem nove graus de liberdade. Quanto mais graus de liberdade temos, mais confiantes podemos ficar de que nossa amostra representa a população real, e “mais compacta” será a nossa distribuição, como ilustra o diagrama a seguir.



Quando o número de graus de liberdade fica maior, a distribuição t converge para a distribuição normal. É por isso que, quando estamos trabalhando com grandes conjuntos de dados, podemos usar a distribuição normal para os nossos diversos cálculos.

A distribuição t meramente acrescenta detalhes ao mesmo processo de inferência estatística que temos usado ao longo do livro. Continuamos formulando uma hipótese nula para então testá-la considerando alguns dados observados. Se os dados que observamos são altamente improváveis caso a hipótese nula fosse verdadeira, então rejeitamos a hipótese nula. A única coisa que muda com a distribuição t são as probabilidades subjacentes para avaliar os resultados observados. Quanto mais “grossa” a cauda numa particular distribuição de probabilidade (por exemplo, a distribuição t para oito graus de liberdade), mais dispersão podemos esperar nos nossos dados observados como mero resultado do acaso e, portanto, menos confiantes podemos ficar em rejeitar a nossa hipótese nula.

Por exemplo, suponha que estejamos compondo uma equação de regressão e que a hipótese nula é que o coeficiente para uma variável particular seja zero. Uma vez obtidos os resultados da regressão, calcularíamos a estatística t, que é a razão entre o coeficiente observado e o erro padrão para esse coeficiente.⁸ Essa estatística t é então avaliada em relação a qualquer que seja a distribuição t apropriada para o tamanho da amostra de dados (uma vez que é isso que determina em grande parte o número de graus de liberdade). Quando a estatística t é

suficientemente grande, significando que o nosso coeficiente observado está longe do que prediria a hipótese nula, podemos rejeitar a hipótese nula em algum nível de significância estatística. Mais uma vez, esse é o mesmo processo básico de inferência estatística que estamos empregando ao longo do livro.

Quanto menos graus de liberdade (e, portanto, “mais grossas” as caudas da distribuição t relevante), mais alta terá de ser a estatística t para podermos rejeitar a hipótese nula em algum nível de significância. No exemplo de regressão hipotética descrito acima, se tivéssemos quatro graus de liberdade, precisaríamos de uma estatística t de pelo menos 2,13 para rejeitar a hipótese nula no nível 0,05 (num teste unicaudal).

No entanto, se tivermos 20 mil graus de liberdade (o que essencialmente nos permite usar a distribuição normal), precisaríamos apenas de uma estatística t de 1,65 para rejeitar a hipótese nula num nível 0,05 no mesmo teste unicaudal.

Equação de regressão para o peso

Variável	Coefficiente	Erro padrão	Estatística t	Valor-p (teste bicaudal)	Intervalo de confiança de 95%
Altura	0,78	0,035	21,4	0,000	0,71 a 0,85
Idade	0,04	0,01	2,2	0,026	0,02 a 0,06
Sexo	-2,59	0,75	-3,4	0,001	-4,09 a -1,09
Anos de formação educacional	-0,32	0,09	-3,5	0,000	-0,50 a -0,14
Quintil inferior de atividade física	1,68	0,63	2,6	0,009	0,42 a 2,94
Dummy por receber vale-alimentação	2,55	0,95	2,7	0,007	0,65 a 4,09
Negro não hispânico	4,41	0,59	7,2	0,000	3,23 a 5,59
Intersecção	-53				

^a Você deve considerar esse exercício uma “diversão com dados”, em vez de uma exploração impositiva de qualquer uma das relações descritas nas equações de regressão subsequentes. O propósito aqui é fornecer um exemplo intuitivo de como a análise de regressão funciona, não fazer uma pesquisa significativa nos pesos dos cidadãos americanos.

^b “Parâmetro” é um nome rebuscado para qualquer estatística que descreva uma característica de alguma população; o peso médio de todos os homens adultos é um parâmetro dessa população. Igualmente é o desvio padrão. Nesse exemplo, a associação verdadeira entre altura e peso para a população é o parâmetro dessa população.

^c Quando a hipótese nula é que o coeficiente de regressão é zero (como é o caso mais frequente), a razão entre o coeficiente de regressão observado e o erro padrão é conhecida como *estatística t*. Isso também será explicado no apêndice do capítulo.

^d Usa-se em português também o termo “variável dummy”. (N.T.)

^e Forças discriminatórias mais amplas na sociedade podem afetar as carreiras que mulheres escolhem ou o fato de estarem mais propensas que os homens a interromper suas carreiras para cuidar de filhos. No entanto, esses importantes tópicos são distintos da questão mais restrita de as mulheres estarem sendo pagas menos que os homens para fazerem o mesmo tipo de serviço.

^f Esses estudos diferem ligeiramente das equações de regressão introduzidas anteriormente neste capítulo. O resultado de interesse, ou variável dependente, é binária nesses estudos. O participante ou tem ou não tem algum tipo de problema de saúde relacionado com o coração durante o período do estudo. Como resultado, os pesquisadores empregaram uma ferramenta chamada regressão logística multivariada. A ideia básica é a mesma que no modelo dos mínimos quadrados ordinários descrito neste capítulo. Cada coeficiente expressa o efeito de uma variável explicativa particular sobre a variável dependente, enquanto são mantidos constantes os efeitos das outras variáveis no modelo. A diferença-chave é que todas as variáveis na equação afetam a *probabilidade* de um evento acontecer, como ter um ataque do coração durante o período de estudo. Nesse estudo, por exemplo, os trabalhadores no grupo de baixo controle no emprego têm uma probabilidade 1,99 vez maior de ter “qualquer evento coronário” durante o período de estudo que trabalhadores no grupo de alto controle no emprego, mantidos constantes todos os outros fatores de risco.

^g A fórmula mais geral para calcular uma estatística *t* é a seguinte:

$$t_b = \frac{b - b_0}{EP_b}$$

onde *b* é o coeficiente observado, *b*₀ é a hipótese nula para esse coeficiente e *EP*_{*b*} é o erro padrão para o coeficiente *b* observado.

12. Erros comuns de regressão

O rótulo de advertência obrigatório

EIS AQUI UMA das coisas mais importantes para lembrar ao fazer alguma pesquisa que envolva análise de regressão: tente não matar ninguém. Você pode até pôr um pequeno adesivo amarelo como lembrete no seu computador: “Não mate gente com a sua pesquisa.” Porque algumas pessoas muito espertas já violaram inadvertidamente essa regra.

Começando nos anos 1990, o establishment médico consolidou-se em torno da ideia de que mulheres mais velhas deveriam tomar suplementos de estrogênio como proteção contra doenças cardíacas, osteoporose e outras condições associadas à menopausa.¹ Em 2001, o estrogênio estava sendo prescrito a cerca de 15 milhões de mulheres com base na crença de que as tornaria mais saudáveis. Por quê? Porque a pesquisa na época – utilizando a base metodológica exposta no capítulo anterior – sugeria que se tratava de uma estratégia médica sensata. Em particular, um estudo longitudinal de 122 mil mulheres (o Nurses’ Health Study – Estudo de Saúde da Enfermagem) descobriu uma associação negativa entre suplementos de estrogênio e ataques do coração. Mulheres que tomavam estrogênio tinham um terço de ataques cardíacos das mulheres que não tomavam. Não era um punhado de adolescentes usando o computador do papai para ver pornografia e montar equações de regressão. O Estudo de Saúde da Enfermagem é gerido pela Escola de Medicina de Harvard e pela Escola de Saúde Pública de Harvard.

Nesse ínterim, cientistas e médicos elaboraram uma teoria médica explicando o porquê de suplementos hormonais poderem ser benéficos para a saúde da mulher. Os ovários produzem menos estrogênio à medida que a mulher envelhece; se o estrogênio é importante para o corpo, então compensar esse déficit em idade mais avançada pode proteger a saúde da mulher no longo prazo. Daí o nome do tratamento: terapia de reposição hormonal. Alguns pesquisadores chegaram mesmo a sugerir que homens mais velhos deveriam receber uma carga de estrogênio.²

E então, enquanto milhões de mulheres recebiam a prescrição da terapia de reposição hormonal, o estrogênio foi submetido à mais rigorosa forma de escrutínio científico: testes clínicos. Em vez de pesquisar um grande conjunto de dados em busca de associações estatísticas que podem ou não ser casuais, como fez o Estudo de Saúde da Enfermagem, um teste clínico consiste num experimento controlado. Uma amostra recebe um tratamento, tal como a reposição hormonal; outra amostra recebe um placebo. Testes clínicos mostraram que mulheres tomando estrogênio tinham uma incidência maior de doenças cardíacas, derrames, coágulos sanguíneos, câncer no seio e outros resultados adversos em termos de saúde. Os suplementos de estrogênio traziam sim alguns benefícios, mas estes eram sobrepujados de longe por outros riscos. A partir de 2002, os médicos foram aconselhados a não prescrever estrogênio para suas pacientes mais idosas. A *New York Times Magazine* fez uma pergunta delicada, mas socialmente significativa:

quantas mulheres morreram prematuramente ou sofreram derrames ou tiveram câncer no seio porque estavam tomando uma pílula que seus médicos lhes prescreveram para mantê-las saudáveis?

A resposta: “uma estimativa razoável seria dezenas de milhares”.³

A ANÁLISE DE REGRESSÃO é a bomba de hidrogênio do arsenal estatístico. Qualquer pessoa com um computador pessoal e um grande conjunto de dados pode ser pesquisador em sua própria casa ou cubículo. O que poderia possivelmente dar errado? Todo tipo de coisas. A análise de regressão provê respostas precisas para questões complicadas. Essas respostas podem ou não ser acuradas. Em mãos erradas, a análise de regressão produzirá resultados que são enganosos ou simplesmente errados. E, como ilustra o exemplo do estrogênio, *mesmo em mãos certas* essa poderosa ferramenta estatística pode nos levar a correr perigosamente na direção errada. O balanço deste capítulo explicará os “erros” de regressão mais comuns. Ponho “erros” entre aspas porque, como ocorre em todos os outros tipos de análise estatística, pessoas espertas podem deliberadamente explorar esses pontos metodológicos para fins nefastos.


Aqui está uma lista dos “sete abusos mais comuns” de uma ferramenta que é, em outras circunstâncias, extraordinária.

Usar regressão para analisar uma relação não linear.^a Você alguma vez já leu o rótulo de advertência num secador de cabelo – a parte que avisa “Não use dentro da banheira”? E você pensa consigo mesmo: “Que idiota usa um secador de cabelo dentro da banheira?” *É um aparelho elétrico; não se usam aparelhos elétricos perto da água.* Eles não são projetados para isso. Se a análise de regressão tivesse um rótulo similar, diria: “Não use quando não houver associação linear entre as variáveis que você está analisando.” Lembre-se, o coeficiente de regressão descreve a inclinação da “reta que melhor se encaixa” naqueles dados; uma linha não reta terá inclinações diferentes em pontos diferentes. Como exemplo, considere a seguinte relação hipotética entre o número de aulas de golfe que tomei durante um mês (uma variável explicativa) e a minha pontuação média para uma rodada de dezoito buracos durante aquele mês (a variável dependente). Conforme você pode ver pelo gráfico, não há nenhuma relação *linear* consistente.

Há um padrão, mas não pode ser descrito facilmente com uma única linha reta. As primeiras aulas de golfe parecem diminuir minha pontuação rapidamente. Há uma associação negativa entre aulas e meus escores para esse trecho; a inclinação é negativa. Mais aulas produzem escores mais baixos (o que no golfe é bom).

Quando chego então ao ponto em que estou gastando entre US\$200 e US\$300 por mês em aulas, estas parecem não ter absolutamente nenhum efeito. Não há uma associação clara ao longo desse trecho entre instrução adicional e os meus escores no golfe; a inclinação é zero.

Efeito das aulas de golfe sobre a pontuação



E, finalmente, as aulas parecem se tornar contraproducentes. Uma vez já gastando US\$300 mensais em aulas, a instrução adicional está associada a escores mais altos; nesse trecho, a associação é positiva. (Discutirei mais adiante no capítulo a possibilidade distinta de que a falta de destreza no golfe é que pode estar exigindo as aulas, e não o contrário.)

O ponto mais importante aqui é que não podemos sintetizar acuradamente a relação entre aulas e pontuação com um coeficiente único. A melhor interpretação do padrão descrito anteriormente é que as aulas de golfe possuem diversas relações lineares diferentes com a minha pontuação. Você pode ver isso; um pacote estatístico não vê. Se você alimentar uma equação de regressão com esses dados, o computador lhe dará um coeficiente único. Esse coeficiente não refletirá acuradamente a verdadeira relação entre as variáveis de interesse. Os resultados que você obtém serão o equivalente estatístico de usar um secador de cabelo na banheira.

A análise de regressão foi feita para ser usada quando a relação entre variáveis for linear. Um manual ou um curso avançado de estatística poderão orientá-lo a respeito das outras premissas que fundamentam a análise de regressão. Como ocorre com qualquer outra ferramenta, quanto mais nos desviamos de sua finalidade original de uso, menos efetiva, ou até mesmo potencialmente perigosa, ela será.

Correlação não é a mesma coisa que causalidade. A análise de regressão só pode demonstrar uma associação entre duas variáveis. Como mencionei antes, não podemos provar apenas com

estatística que uma mudança numa variável esteja *causando* uma mudança na outra. Na verdade, uma equação de regressão negligente pode produzir uma associação grande e estatisticamente significativa entre duas variáveis que não têm nada a ver uma com a outra. Suponha que estivéssemos procurando causas potenciais para o aumento do índice de autismo nos Estados Unidos durante as duas últimas décadas. Nossa variável dependente – o resultado que estamos procurando explicar – seria alguma medida da incidência de autismo por ano, tal como o número de casos diagnosticados por cada mil crianças de certa idade. Se fôssemos incluir a renda anual per capita na China como variável explicativa, quase com certeza encontraríamos uma associação positiva e estatisticamente significativa entre o aumento de renda na China e o aumento do índice de autismo nos Estados Unidos nos últimos vinte anos.

Por quê? Porque ambos têm aumentado drasticamente no mesmo período. Contudo, duvido muito que uma recessão aguda na China reduziria o índice de autismo nos Estados Unidos. (Para ser justo, se eu observasse uma forte relação entre o rápido crescimento econômico na China e os índices de autismo *apenas na China*, poderia começar a buscar algum fator ambiental relacionado com crescimento econômico, tal como poluição industrial, que pudesse explicar a associação.)

O tipo de associação falsa entre duas variáveis que acabei de ilustrar é apenas um exemplo de um fenômeno mais geral conhecido como causalidade espúria. Há outros modos pelos quais uma associação entre A e B pode ser interpretada de maneira errada.

Causalidade reversa. Uma associação estatística entre A e B não prova que A causa B. Na verdade, é inteiramente plausível que B esteja causando A. Aludi a essa possibilidade anteriormente no exemplo das aulas de golfe. Suponha que, quando construo um modelo complexo para explicar minha pontuação no golfe, a variável para aulas de golfe esteja consistentemente associada com resultados piores. Quanto mais aulas eu tomo, pior meu desempenho! Uma explicação é que devo ter um instrutor de golfe realmente muito, muito ruim. Uma explicação mais plausível é que tenho a tendência de tomar mais aulas quando estou jogando mal; meu golfe ruim está causando mais aulas, e não o contrário. (Há algumas correções metodológicas simples para um problema dessa natureza. Por exemplo, posso incluir as aulas de golfe em certo mês como variável explicativa para os resultados *no mês seguinte*.)

Como foi observado antes neste capítulo, a causalidade pode ocorrer em ambos os sentidos. Suponha que você faça uma pesquisa demonstrando que os estados que gastam mais dinheiro em educação no ensino fundamental e médio têm índices de crescimento econômico mais elevados que estados que gastam menos. Uma associação positiva e significativa entre essas duas variáveis não fornece nenhuma percepção de qual é o sentido em que a relação ocorre. Investimentos em educação fundamental e média podem causar crescimento econômico. Ou, por outro lado, estados com economias fortes podem se permitir gastar mais em educação fundamental e média, de modo que a economia forte poderia estar causando os gastos em educação. Ou, gastos em educação impulsionam o crescimento econômico, o que possibilita gastos em educação adicionais – a causalidade pode caminhar nos dois sentidos.

O ponto é que não devemos usar variáveis explicativas que possam ser afetadas pelo resultado que estamos tentando explicar, senão os resultados estarão irremediavelmente

emaranhados. Por exemplo, seria inapropriado usar a taxa de desemprego numa equação de regressão explicando o crescimento do PIB, uma vez que o desemprego é claramente afetado pela taxa de crescimento do PIB. Ou, pensando no sentido inverso, uma análise de regressão que descubra que a redução do desemprego impulsiona o crescimento do PIB é uma descoberta tola e sem sentido, uma vez que impulsionar o crescimento do PIB geralmente é necessário para reduzir o desemprego.

Devemos ter razões para acreditar que as nossas variáveis explicativas afetam a variável dependente, e não o contrário.

Viés da variável omitida. Você deve ficar cético na próxima vez que vir uma manchete enorme proclamando: “Golfistas mais propensos a doenças do coração, câncer e artrite!” Eu não ficaria surpreso se os golfistas tivessem uma incidência mais alta de todas essas doenças do que não golfistas; desconfio também de que o golfe é provavelmente bom para a saúde porque é uma forma de socialização e exercício modesto. Como posso conciliar as duas afirmações? Muito facilmente. Qualquer estudo que tente medir os efeitos de jogar golfe sobre a saúde deve ter um controle adequado da idade. Em geral, as pessoas jogam mais golfe quando ficam mais velhas, particularmente quando se aposentam. Qualquer análise que deixe de fora a idade como uma variável explicativa deixará de levar em conta que jogadores de golfe, em média, são mais velhos que não golfistas. Não é o golfe que está matando as pessoas; é a velhice que está matando, e acontece que as pessoas gostam de jogar golfe enquanto isso ocorre. Desconfio que, ao inserir a idade na análise de regressão como variável de controle, iremos obter um resultado diferente. *Entre pessoas da mesma idade*, o golfe previne levemente doenças mais sérias. Uma diferença bastante grande.

Nesse exemplo, a idade é uma importante “variável omitida”. Quando deixamos de fora a idade numa equação de regressão explicando doenças cardíacas ou algum outro resultado de saúde adverso, a variável “jogar golfe” assume *dois papéis explicativos*, em vez de apenas um. Ela nos conta o efeito de jogar golfe sobre a doença cardíaca, assim como nos conta o efeito de ser velho sobre a doença cardíaca (já que jogadores de golfe tendem a ser mais velhos que o resto da população). No jargão estatístico, diríamos que a variável golfe está “pegando” o efeito da idade. O problema é que esses dois efeitos estão misturados. Na melhor das hipóteses, nossos resultados serão uma mistura bagunçada. Na pior, pressupomos de forma errada que o golfe é ruim para a saúde, quando na verdade o oposto é provavelmente verdade.

Os resultados da regressão serão enganosos e inacurados se a equação de regressão deixar de fora alguma variável explicativa importante, particularmente se outras variáveis na equação “pegarem” esse efeito. Suponha que estejamos tentando explicar qualidade escolar. Esse é um resultado importante de se entender: o que faz com que as escolas sejam boas? Nossa variável dependente – a medida quantificável de qualidade – provavelmente seria a pontuação nos exames. É quase certo que examinaríamos os gastos escolares como uma variável explicativa na esperança de quantificar a relação entre gastos e pontuação. Será que escolas que gastam mais obtêm resultados melhores? Se o gasto da escola fosse a única variável explicativa, não tenho dúvida de que encontraríamos uma relação grande e estatisticamente significativa entre gastos e pontuação. Todavia, esse achado, e a implicação de que poderíamos sair gastando em busca de

obter uma escola melhor, é profundamente falho.

Aqui há diversas variáveis muito significativas omitidas, mas a crucial é a educação dos pais. Famílias com maior grau de instrução tendem a viver em áreas abastadas que gastam muito dinheiro em suas escolas; tais famílias também tendem a ter filhos que se saem bem nos testes escolares (e famílias pobres têm maior probabilidade de ter alunos obrigados a lutar mais). Se não tivermos alguma medida do status socioeconômico do corpo estudantil como variável de controle, nossos resultados de regressão provavelmente mostrarão uma grande associação positiva entre gastos escolares e resultados de exames – quando na verdade esses resultados podem ser em função do tipo de alunos que entram pela porta da escola, e não do dinheiro que está sendo gasto no prédio.

Lembro-me de um professor de faculdade ressaltando que as notas do Teste de Raciocínio SAT estão altamente correlacionadas com o número de carros que a família possui. Ele insinuava que os exames, portanto, eram uma ferramenta injusta e inadequada para admissões universitárias. Tais exames têm suas falhas, mas a correlação entre resultados e carros da família não é a que mais me preocupa. Não me preocupo muito com que famílias ricas consigam colocar seus filhos na faculdade comprando três automóveis a mais. O número de carros na garagem da família é um indicador da sua renda, educação e outras medidas de status socioeconômico. Não é novidade o fato de que crianças ricas se saem melhor nos exames do SAT que crianças pobres. (Como foi observado anteriormente, o escore médio obtido na seção de leitura crítica dos exames SAT para alunos vindos de famílias com renda familiar acima de US\$200 mil anuais é 134 pontos superior ao escore médio para alunos de famílias com renda abaixo de US\$20 mil anuais.)⁴ A maior preocupação deveria ser se tais exames são ou não “treináveis”. Quanto os estudantes podem melhorar seus resultados tomando aulas particulares de preparação para as provas? Famílias abastadas são claramente mais capazes de mandar seus filhos para aulas preparatórias. Qualquer melhora causal entre essas aulas e os escores dos exames favoreceria estudantes de famílias ricas em relação aos menos privilegiados *de habilidades iguais* (que presumivelmente também poderiam ter melhorado seus resultados com aulas preparatórias, mas nunca tiveram essa oportunidade).

Variáveis explicativas altamente correlacionadas (multicolinearidade). Se uma equação de regressão inclui duas ou mais variáveis explicativas que são altamente correlacionadas entre si, a análise não será necessariamente capaz de discernir a verdadeira relação entre cada uma dessas variáveis e os resultados que estamos tentando explicar. Um exemplo deixará isto mais claro. Suponha que estejamos tentando avaliar o efeito do uso de drogas ilegais nos resultados do SAT. De modo específico, temos dados sobre se os participantes do nosso estudo já usaram cocaína e também se já usaram heroína. (É possível presumir que poderíamos ter igualmente outras variáveis de controle.) Qual é o impacto do uso de cocaína nos resultados dos exames, mantendo constantes outros fatores, inclusive o uso de heroína? E qual é o impacto do uso de heroína sobre os resultados dos exames, controlando o uso de cocaína e outros fatores?

Os coeficientes para uso de heroína e cocaína não poderiam de fato nos dizer isso. O desafio metodológico é que pessoas que usaram heroína provavelmente usaram também cocaína. Se pusermos ambas as variáveis na equação, teremos muito poucos indivíduos que só usaram uma

droga e não a outra, o que nos deixa muito pouca variação nos dados que usamos para calcular seus efeitos independentes. Volte a pensar por um momento na imagem mental usada para explicar a análise de regressão no capítulo passado. Nós dividimos nossa amostra de dados em diferentes “salas” nas quais cada observação é idêntica com exceção de uma variável, o que então nos permite isolar o efeito dessa variável enquanto mantemos sob controle os outros fatores potenciais de confusão. Podemos ter na nossa amostra 692 indivíduos que usaram tanto cocaína quanto heroína. No entanto, podemos ter apenas três indivíduos que usaram cocaína, mas não heroína, e dois indivíduos que usaram heroína, mas não cocaína. Qualquer inferência sobre o efeito independente de apenas uma droga ou outra terá de se basear nessas amostras ínfimas.

Temos pouquíssima probabilidade de obter coeficientes significativos seja na variável da cocaína, seja na da heroína; e podemos também obscurecer a relação maior e mais importante entre os resultados nos exames e o uso de qualquer uma dessas drogas. Quando duas variáveis explicativas estão muito correlacionadas, os pesquisadores em geral usam uma ou outra na equação de regressão, ou podem criar algum tipo de variável composta, tal como “usou cocaína ou heroína”. Por exemplo, quando os pesquisadores querem controlar o contexto socioeconômico geral do estudante, podem incluir variáveis tanto para “educação da mãe” como para “educação do pai”, pois essa inclusão fornece uma compreensão importante no histórico do nível educacional da família. Porém, se o objetivo da análise de regressão é isolar o efeito da educação da mãe ou do pai, então colocar ambas as variáveis na equação tem mais propensão a confundir o assunto do que esclarecê-lo. A correlação entre as realizações educacionais de marido e esposa é tão elevada que não podemos depender da análise de regressão para nos dar coeficientes que isolem significativamente o efeito da educação de um dos dois (da mesma forma que é difícil separar o impacto do uso de cocaína do impacto do uso de heroína).

Extrapolar para além dos dados. A análise de regressão, como todas as formas de inferência estatística, destina-se a nos oferecer percepções sobre o mundo ao nosso redor. Buscamos padrões que permaneçam verdadeiros para a população mais ampla. *No entanto, nossos resultados são válidos apenas para uma população que seja similar à amostra sobre a qual foi feita a análise.* No último capítulo, criei uma equação de regressão para prever o peso com base num número de variáveis independentes. O R^2 do meu modelo final foi 0,29, o que significa que foi feito um trabalho decente para explicar a variação de peso para uma amostra grande de indivíduos – sendo todos eles adultos.

Então, o que acontece se usarmos a nossa equação de regressão para prever o peso provável de um recém-nascido? Experimentemos. Minha filha tinha 53 centímetros ao nascer. Vamos dizer que sua idade naquele momento era zero; não tinha educação nem fazia exercício. Era branca e do sexo feminino. A equação de regressão baseada nos dados do Changing Lives prevê que seu peso no nascimento deveria ter sido 8,9 quilos negativos. (Ela pesava 3,9 quilos.)

Os autores de um dos estudos Whitehall mencionado no último capítulo foram notavelmente explícitos ao formular sua restrita conclusão: “Baixo controle no ambiente de trabalho está associado a um aumento no risco de futura doença cardíaca coronária *entre homens e mulheres empregados em agências governamentais*”⁵ (grifo meu).

Mineração de dados – “data mining” (variáveis demais). Se omitir variáveis importantes é um problema em potencial, então presume-se que adicionar a uma equação de regressão o maior número possível de variáveis deve ser a solução. Negativo.

Seus resultados podem ficar comprometidos se você incluir variáveis demais, especialmente variáveis explicativas alheias sem nenhuma justificativa teórica. Por exemplo, *não se deve* planejar uma estratégia de pesquisa construída em torno da seguinte premissa: já que não conhecemos a causa do autismo, devemos inserir na equação de regressão a maior quantidade possível de potenciais variáveis explicativas, apenas para ver o que pode se revelar estatisticamente significativo; então talvez obtenhamos alguma resposta. Se você inserir um monte de variáveis fajutas numa equação de regressão, correrá o risco de que uma delas satisfaça o limiar de significância estatística por mero acaso. O perigo adicional é que essas variáveis fajutas nem sempre são facilmente reconhecíveis como tal. Pesquisadores astutos podem sempre construir uma teoria *a posteriori* para justificar por que uma variável curiosa, que na realidade é absurda, revelase estatisticamente significativa.

Para enfatizar esse ponto, frequentemente faço o mesmo exercício de cara ou coroa que expliquei durante a discussão sobre probabilidade. Numa classe de mais ou menos quarenta alunos, faço cada um lançar uma moeda. Qualquer aluno que tire coroa é eliminado; o resto lança de novo. Na segunda rodada, aqueles que tiram coroa são novamente eliminados. Continuo as rodadas de lançamento da moeda até um aluno ter tirado cinco ou seis caras seguidas. Você deve se lembrar de algumas perguntas bobas que se seguiram, tipo: “Qual é o seu segredo? Está no seu pulso? Você pode nos ensinar a tirar cara o tempo todo? Talvez seja esse agasalho de Harvard que você está vestindo.”

Obviamente a sequência de caras é pura sorte; todos os alunos acompanharam o feito. No entanto, não é necessariamente assim que o resultado poderia ser ou seria interpretado num contexto científico. A probabilidade de tirar cinco caras seguidas é de $\frac{1}{32}$, ou 0,03. Isso está confortavelmente abaixo do limiar de 0,05 que tipicamente usamos para rejeitar a hipótese nula. A nossa hipótese nula nesse caso é que o aluno não tem nenhum talento especial para tirar cara; a sequência fortuita de caras (que está sujeita a acontecer para pelo menos um aluno quando começo com um grupo grande) nos permite rejeitar a hipótese nula e adotar a hipótese alternativa: esse aluno tem uma habilidade especial para lançar uma moeda e tirar cara. Depois de ele ter conseguido esse feito impressionante, podemos estudá-lo em busca de indícios acerca do seu sucesso no lançamento de moedas – seu jeito de lançar, seu treinamento atlético, sua extraordinária concentração enquanto a moeda está no ar, e assim por diante. E tudo não passa de absurdo.

Esse fenômeno pode contaminar até mesmo uma pesquisa legítima. A convenção aceita é rejeitar uma hipótese nula quando observamos algo que aconteceria por acaso apenas uma vez em vinte ou menos se a hipótese nula fosse verdadeira. É claro que, se conduzirmos vinte estudos, ou se incluirmos vinte variáveis fajutas numa única equação de regressão, então, em média, obteremos um falso achado estatisticamente significativo. A *New York Times Magazine* captou maravilhosamente essa tensão numa citação de Richard Peto, um médico estatístico e epidemiologista: “A epidemiologia é tão linda e oferece uma perspectiva tão importante sobre a vida e a morte humanas, mas uma quantidade incrível de lixo é publicada.”⁶

Mesmo os resultados de testes clínicos, que geralmente são experimentos aleatórios e, portanto, constituem o padrão-ouro da pesquisa médica, devem ser encarados com algum ceticismo. Em 2011, o *Wall Street Journal* publicou uma matéria de primeira página sobre o que descreveu como um dos “segredinhos sujos” da pesquisa médica: “A maioria dos resultados, inclusive aqueles que aparecem em revistas de primeira linha com revisão por pares, não podem ser reproduzidos.”⁷ (Uma revista com revisão por pares é aquela na qual estudos e artigos são revistos em busca de solidez metodológica por outros especialistas da mesma área antes de serem aprovados para publicação; tais veículos são considerados os guardiões da pesquisa acadêmica.) Um dos motivos para esse “segredinho sujo” é o viés de publicação positiva descrito no Capítulo 7. Se pesquisadores e revistas médicas prestam atenção a achados positivos e ignoram achados negativos, então podem muito bem publicar um estudo que aponte uma droga como sendo efetiva e ignorar os outros dezenove que atestam que essa mesma droga não tem efeito. Alguns testes clínicos também podem ter amostras pequenas (tais como no caso de doenças raras), o que amplifica as chances de que uma variação aleatória nos dados receba mais atenção do que merece. E, por cima de tudo, os pesquisadores podem ter algum viés consciente ou inconsciente, seja por causa de uma crença prévia fortemente sustentada ou porque um achado positivo seria melhor para sua carreira. (Ninguém fica rico ou famoso provando o que *não cura* o câncer.)

Por todas essas razões, uma quantidade chocante de pesquisa especializada acaba se revelando errada. John Ioannidis, um médico e epidemiologista grego, examinou 49 estudos publicados em três proeminentes revistas médicas.⁸ Cada estudo havia sido citado na literatura médica pelo menos mil vezes. Todavia, aproximadamente 1/3 das pesquisas foi subsequentemente refutado por algum trabalho posterior. (Por exemplo, alguns dos estudos que ele examinou promoviam a terapia de reposição de estrogênio.) O dr. Ioannidis estima que aproximadamente metade dos artigos científicos publicados acaba se revelando errada.⁹ Sua pesquisa foi publicada no *Journal of the American Medical Association*, uma das publicações nas quais os artigos por ele estudados haviam aparecido. Isso cria certa ironia de contradição: se a pesquisa do dr. Ioannidis está correta, então há uma boa chance de estar errada.

A ANÁLISE DE REGRESSÃO ainda assim é uma ferramenta estatística incrível. (Tudo bem, talvez minha descrição no capítulo anterior de que se trata de um “elixir milagroso” tenha sido um pouco hiperbólica.) A análise de regressão nos possibilita achar padrões básicos em grandes conjuntos de dados, e esses padrões muitas vezes são a chave para uma pesquisa importante em medicina e ciências sociais. A estatística nos dá parâmetros objetivos para avaliar esses padrões. Quando usada apropriadamente, a análise de regressão é uma parte importante do método científico. Considere este capítulo um rótulo de advertência obrigatório.

Todas as diversas advertências específicas nesse rótulo podem se resumir a duas lições fundamentais. Primeira, projetar uma boa equação de regressão – descobrindo quais variáveis devem ser examinadas e de onde devem vir os dados – é mais importante do que os cálculos estatísticos subjacentes. Esse processo é referido como estimando a equação, ou especificando uma boa equação de regressão. Os melhores pesquisadores são aqueles que sabem pensar logicamente sobre quais variáveis devem ser incluídas numa equação de regressão, o que pode

estar faltando e como os eventuais resultados podem e devem ser interpretados.

Segunda, como a maior parte das outras inferências estatísticas, a análise de regressão constrói apenas um caso circunstancial. Uma associação entre duas variáveis é como uma impressão digital numa cena de crime. Ela aponta na direção certa, mas raramente é suficiente para uma condenação. (E às vezes uma impressão digital numa cena de crime *não* pertence a quem o perpetrou.) Qualquer análise de regressão necessita de uma fundamentação teórica: por que as variáveis explicativas estão na equação? Quais fenômenos de outras disciplinas podem explicar os resultados observados? Por exemplo, por que pensamos que usar roxo melhoraria o desempenho na parte de matemática de um exame ou comer pipoca pode ajudar a prevenir câncer de próstata? Os resultados precisam ser replicados, ou pelo menos consistentes com outros achados.

Mesmo um elixir milagroso não funciona se não tomado conforme a prescrição.

^a Existem métodos mais sofisticados que podem ser utilizados para adaptar a análise de regressão para uso com dados não lineares. Antes de usar essas ferramentas, porém, você precisa avaliar por que o uso da abordagem padrão dos quadrados mínimos ordinários com dados não lineares lhe dará um resultado significativo.