

Introdução à Ciência dos Dados

Aula 08 – Regressão

Sumário

- Introdução
- Regressão linear uni-variada
- Regressão linear multi-variada
- Erros comuns

Regressão

- Será que estresse no trabalho pode matar?
 - Há fortes evidências que os rigores no trabalho podem levar a uma morte prematura
 - CEO x secretárias

Regressão

- Será que estresse no trabalho pode matar?
 - Há fortes evidências que os rigores no trabalho podem levar a uma morte prematura
 - CEO x **secretárias**
 - O tipo de estresse mais perigoso está associado a ter “baixo controle” sobre o trabalho, segundo um estudo com milhares de britânicos

Regressão

- Como os pesquisadores podem chegar a essa conclusão?

Regressão

- Como os pesquisadores podem chegar a essa conclusão?
 - Podemos forçar diferentes pessoas a fazer diferentes tipos de trabalho, e depois de vários anos ver quem morreu primeiro?

Regressão

- Como os pesquisadores podem chegar a essa conclusão?
 - Podemos forçar diferentes pessoas a fazer diferentes tipos de trabalho, e depois de vários anos ver quem morreu primeiro? Não
 - Coleta de dados ao longo do tempo de milhares de pessoas, e análise dos dados para identificar associações significativas, como por exemplo, entre o “emprego de baixo controle” e morte prematura
 - Porém, isso não é tão simples quanto parece....

Regressão

- Vários fatores podem estar envolvidos
 - Funcionários de “baixo escalão” podem ter menos educação, ser mais propensos a fumar, ter tido uma infância menos saudável, ter menos acesso a recursos de saúde (devido ao salário mais baixo),...
 - Ou seja, outras fontes de variação nos dados podem obscurecer a relação na qual estamos interessados
 - Será que o tipo do emprego está realmente causando a morte prematura? Ou são as características relacionadas a pessoas nesse tipo de emprego que estão?

Regressão

- A análise de regressão nos permite
 - Quantificar a relação entre uma variável e um resultado de nosso interesse, enquanto controlamos outros fatores
 - Podemos isolar o efeito de uma variável enquanto mantemos os efeitos das outras variáveis constantes
 - Se considerarmos pessoas com características similares em várias variáveis, o tipo de emprego afeta a morte prematura

Regressão

- Com os dados adequados, é muito fácil usar um programa para fazer uma análise de regressão
 - A parte difícil é determinar quais variáveis devem ser consideradas e como isso pode ser feito da melhor maneira
- Regressão: fácil de usar, mas difícil de usar bem, e perigosa quando usada de forma errada

Regressão

- Regressão é uma técnica de aprendizado de máquina supervisionado
 - Com base em dados conhecidos, cria um modelo para prever valores **contínuos** de objetos desconhecidos
 - Diferente de classificação (veremos nas próximas aulas) que prevê valores **discretos**

Regressão

- Regressão nos dá uma **estimativa** da associação entre variáveis
 - Podemos tirar conclusões mais amplas sobre uma população? Sim
 - Desde que tenhamos amostras representativas
 - Como em toda inferência, se temos uma grande amostra representativa e uma metodologia sólida, os resultados não devem desviar muito da população

Regressão

- **Exemplo:**

10000 pessoas que se exercitam regularmente.

10000 pessoas que não se exercitam.

- Semelhantes em todos os outros aspectos importantes

- Grupo que se exercita tem índices de doenças cardiovasculares muito menores

- Temos boas chances de o mesmo ser verdade para uma população mais ampla

Regressão

- Porém, não estamos **provando** que atividade física previne doenças cardíacas
 - Estamos rejeitando a hipótese de que exercícios não têm ligação com doenças cardíacas
 - Se a prática de exercícios não tivesse relação com a saúde cardíaca, a probabilidade de encontrar uma discrepância significativa nos resultados seria muito baixa

Regressão

- Atenção:
 - Será que a causalidade não acontece no sentido oposto? Ou seja, ter um coração saudável leva a pessoa a se exercitar?
 - Se a análise for mal conduzida, pode-se chegar a uma conclusão inválida
 - Nesse exemplo, atividade física não causaria menos doenças cardíacas, mas pessoas doentes não se exercitariam por indicação médica
 - Em breve veremos as principais armadilhas da regressão

Regressão

- A regressão permite isolar as associações de interesse, ao mesmo tempo em que leva em conta outros fatores que poderiam confundir a relação
 - Emprego 1 + fumantes x Emprego 2 + não fumantes
 - Como sabemos que o emprego, e não o fato de ser fumante, afeta a saúde?

Com regressão, é possível desentrelaçar esses fatores


Mas vamos começar com um exemplo mais simples!

Regressão Univariada

- **Objetivo:** encontrar um “melhor encaixe” para uma relação linear entre duas variáveis
- Exemplo: relação entre altura e peso

Gráfico de dispersão para altura e peso


Como você descreve a relação?



Regressão Univariada

- **Objetivo:** encontrar um “melhor encaixe” para uma relação linear entre duas variáveis
- Exemplo: relação entre altura e peso

Gráfico de dispersão para altura e peso



Como você descreve a relação?

O peso parece aumentar com a altura

Com regressão, podemos ir além e encaixar uma reta que melhor descreva a relação entre essas variáveis.


Regressão Univariada

- A análise de regressão usa uma metodologia chamada de mínimos quadrados ordinários
 - Encaixa a reta aos pontos, minimizando a soma dos residuais elevados ao quadrado

Regressão Univariada

- Quanto maior a soma dos residuais, pior é o encaixe da reta
 - O *quadrado* dos residuais eleva o peso negativo de *outliers*

Reta de melhor encaixe para altura e peso




A metodologia encaixa a reta que minimiza a soma dos residuais ao quadrado.

Regressão Univariada

- Quanto maior a soma dos residuais, pior é o encaixe da reta
 - O *quadrado* dos residuais eleva o peso negativo de *outliers*

Reta de melhor encaixe para altura e peso



A metodologia encaixa a reta que minimiza a soma dos residuais ao quadrado.

O resultado não é somente uma reta, mas uma equação que descreve a reta da forma:

$$y = a + bx$$

onde **y** é o peso em quilos, **a** é interseção da reta com o eixo y (quando $x=0$), **b** é a inclinação da reta e **x** é a altura em centímetros

Regressão Univariada

- A reta de regressão não descreve perfeitamente a relação entre as variáveis
 - Mas é a melhor opção
- A reta permite prever um peso desconhecido de uma pessoa como:
 - $PESO = a + b(ALTURA) + e$, onde **e** é o residual que representa a variação nos dados

Regressão Univariada

- Variável sendo explicada: variável dependente, pois depende de outras (ex. peso)
- Variáveis sendo usadas para explicar a variável dependente: variáveis explicativas (ex. altura)
- Exemplo com 3537 pessoas
 - Variável dependente: peso em quilos
 - Variável explicativa: altura em centímetros

Reta de regressão:

$$\text{peso} = -60 + (0,8) \times \text{altura}$$

Regressão Univariada

$$\text{peso} = -60 + (0,8) \times \text{altura}$$

- **a = -60**: interseção com eixo-x, sem significado particular. Pessoa com 0cm pesaria -60kg.
- **b = 0,8**: coeficiente de regressão. Um acréscimo de uma unidade na variável independente (altura), leva a um acréscimo de 0,8 na variável dependente (peso)

Qual a estimativa de peso para uma pessoa que mede 175cm?

Regressão Univariada

$$\text{peso} = -60 + (0,8) \times \text{altura}$$

- **a = -60**: interseção com eixo-x, sem significado particular. Pessoa com 0cm pesaria -60kg.
- **b = 0,8**: coeficiente de regressão. Um acréscimo de uma unidade na variável independente (altura), leva a um acréscimo de 0,8 na variável dependente (peso)

Qual a estimativa de peso para uma pessoa que mede 175cm?

$$\text{peso} = -60 + 0,8 \times (175) = 80 \text{ quilos}$$

Regressão Univariada

- Para qualquer coeficiente de regressão, temos 3 características importantes:
 - **Sinal (positivo ou negativo):** Sentido da associação
 - + Pessoas mais altas tendem a pesar mais
 - - Pessoas que exercitam mais pesam menos
 - **Tamanho:** efeito observado é relevante?
 - 0,8 quilos para cada centímetro de tamanho
 - R\$86/ano para pessoas com dentes mais brancos
 - **Significância:** o resultado pode ser extrapolado para uma população?
 - Vamos elaborar mais sobre isso em seguida....

Regressão Univariada

- Coeficiente de regressão:
 - Resultado com base em uma amostra de dados
 - amostras diferentes podem levar a coeficientes diferentes
 - Para amostras grandes e representativas
 - coeficiente não oscilará muito de uma amostra para outra
 - Podemos calcular o erro padrão do coeficiente
 - medida de dispersão entre várias amostras repetidas tiradas da mesma população
 - teorema central do limite: coeficientes estarão distribuídos normalmente em torno da “verdadeira” associação da população

Regressão Univariada

- Importância do erro padrão
 - Espera-se que mais da metade dos coeficientes se situem dentro de um erro padrão
 - Aproximadamente 95% se situarão dentro de dois erros padrões
 -
- Podemos então testar a hipótese: não existe nenhuma relação entre a variável explicativa e a variável dependente

Regressão Univariada

- Podemos então testar a hipótese: não existe nenhuma relação entre a variável explicativa e a variável dependente (coeficiente = 0)
 - Probabilidade de descobrir na nossa amostra que cada centímetro está associado a 0,8Kg se **não** existir realmente nenhuma associação entre altura e peso na população geral

Regressão Univariada

- Exemplo peso x altura: erro padrão = 0,05
 - A cada 100 amostras, o coeficiente estaria dentro de 2 erros padrões do verdadeiro valor da população aproximadamente 95 vezes

Regressão Univariada


- Exemplo peso x altura: erro padrão = 0,05
 - A cada 100 amostras, o coeficiente estaria dentro de 2 erros padrões do verdadeiro valor da população aproximadamente 95 vezes
 - Podemos então calcular o intervalo de confiança de 95%
 - 95 vezes em 100, o intervalo de confiança de $[0,70, 0,90]$ conterá o coeficiente verdadeiro da população
 - Intervalo não inclui zero
 - Podemos rejeitar a hipótese de que o peso não está associado com a altura
 - Há somente 5% de chance de estarmos errados

Regressão Univariada

- Exemplo peso x altura: erro padrão = 0,05
 - A cada 100 amostras, o coeficiente estaria dentro de 2 erros padrões do verdadeiro valor da população aproximadamente 95 vezes
 - Podemos então calcular o intervalo de confiança de 95%
 - 95 vezes em 100, o intervalo de confiança de [0,70, 0,90] conterá o coeficiente verdadeiro da população
 - Intervalo não inclui zero
 - Podemos rejeitar a hipótese de que o peso não está associado com a altura
 - Há somente 5% de chance de estarmos errados
 - valor-p = 0,000: a chance de se obter um resultado tão extremo caso não haja associação entre as duas variáveis é zero

Regressão Univariada

- R^2 (coeficiente de determinação): medida do tamanho total de variação explicada pela equação de regressão ($0 \leq R^2 \leq 1$, sendo 1 o melhor caso)



$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

Regressão Univariada

- R^2 (coeficiente de determinação): medida do tamanho total de variação explicado pela equação de regressão ($0 \leq R^2 \leq 1$, sendo 1 o melhor caso)
 - Algumas pessoas pesam mais que a média da amostra; outras menos
 - R^2 nos diz quanto dessa variação em torno da média está associado apenas a diferenças de altura
 - 0,25 para o nosso exemplo: 75% da variação em peso não é explicada pela variação na altura
 - Existem claramente outros fatores que afetam o peso além da altura

Regressão Multivariada

- Podemos incluir múltiplas variáveis na equação de regressão
 - Associação linear entre cada variável explicativa e a variável dependente
 - Outras variáveis constantes
- Regressão linear múltipla ou multivariada

Regressão Multivariada

- Peso pode ser associado a: altura, idade, horas de atividades físicas, sexo, alimentação,...)
 - Coeficiente para cada variável explicativa
 - Ex. Entre as pessoas que têm mesmo sexo e altura, qual a relação entre idade e peso?
 - Não é possível visualizar graficamente essas 4 dimensões, mas o processo de calcular a equação de regressão é o mesmo

Regressão Multivariada

- Vamos acrescentar mais uma variável: idade

$$\text{PESO} = -66 + 0,82 \times \text{ALTURA} + 0,05 \times \text{IDADE}$$

- Cada ano adicional leva a 0,05Kg no peso, *mantendo a altura constante*
 - Em qualquer grupo de pessoas com a mesma altura, as que são 10 anos mais velhas em média pesarão 0,5Kg a mais
- Coeficiente da altura aumentou para 0,82
 - Temos um entendimento melhor dos dados com uma variável a mais
 - Entre pessoas da mesma idade, qualquer 1cm a mais na altura leva a 0,82Kg a mais no peso

Regressão Multivariada

- Vamos acrescentar uma terceira variável: sexo
 - Variável binária: 1 para Feminino e 0 para Masculino
 - O coeficiente é interpretado como o efeito que o fato de ser mulher exerce sobre o peso, mantendo o resto constante

$$\text{PESO} = -54 + 0,79 \times \text{ALTURA} + 0,06 \times \text{IDADE} - 2,2 \text{ (SE FEM)}$$

- Se uma mulher e um homem possuem a mesma altura e idade, é esperado que a mulher pese 2,2Kg a menos

Regressão Multivariada

- Podemos então explorar análises mais interessantes e menos intuitivas
 - Educação, renda, atividade física, raça, ...

Equação de regressão para o peso

Variável	Coefficiente	Erro padrão	Estatística t	Valor-p (teste bicaudal)	Intervalo de confiança de 95%
Altura	0,78	0,035	21,4	0,000	0,71 a 0,85
Idade	0,04	0,01	2,2	0,026	0,02 a 0,06
Sexo	-2,59	0,75	-3,4	0,001	-4,09 a -1,09
Anos de formação educacional	-0,32	0,09	-3,5	0,000	-0,50 a -0,14
Quintil inferior de atividade física	1,68	0,63	2,6	0,009	0,42 a 2,94
<i>Dummy</i> por receber vale-alimentação	2,55	0,95	2,7	0,007	0,65 a 4,09
Negro não hispânico	4,41	0,59	7,2	0,000	3,23 a 5,59
Intersecção	-53				

Regressão Multivariada

- Análise de regressão multivariada
 - Excelente ferramenta para encontrar padrões significativos em grandes e complexos conjuntos de dados

Porém, a análise deve ser feita com cuidado

Erros comuns da regressão


- O uso incorreto da análise de regressão pode levar a sérias consequências
 - Ex. reposição de estrogênio a mulheres na década de 90
- É uma técnica fácil de ser aplicada; porém, respostas podem não ser acuradas, ou mesmo incorretas

Erros comuns da regressão

1. Relação não linear

- Não use regressão linear quando não houver relação linear entre as variáveis que você está analisando

Efeito das aulas de golfe sobre a pontuação




Erros comuns da regressão

1. Relação não linear

- Não use regressão linear quando não houver relação linear entre as variáveis que você está analisando

Efeito das aulas de golfe sobre a pontuação



Não há relação linear consistente

Você pode ver isso, mas o pacote estatístico que está usando para fazer a análise de regressão NÃO!

Programa irá gerar um coeficiente, que não será acurado.

Erros comuns da regressão


2. Correlação x Causalidade

- Regressão pode demonstrar uma relação entre duas variáveis
 - mas não prova se uma variável está causando a outra


Erros comuns da regressão

2. Correlação x Causalidade


US spending on science, space, and technology
correlates with
Suicides by hanging, strangulation and suffocation



Number of people who drowned by falling into a pool
correlates with
Films Nicolas Cage appeared in



Divorce rate in Maine
correlates with
Per capita consumption of margarine



Fonte: <https://www.tylervigen.com/spurious-correlations>

Erros comuns da regressão

3. Causalidade Reversa

- Uma associação positiva entre A e B não prova que A causa B
 - É possível que B esteja causando A
 - Ex. Investimento em educação x Crescimento do PIB
 - Pode ser que o crescimento do PIB que está levando a um investimento em educação
 - Às vezes é necessário correlacionar com um resultado futuro
 - **Devemos ter razões para acreditar que as nossas variáveis explicativas afetam a variável dependente, e não o contrário**

Erros comuns da regressão

4. Viés da variável omitida

- “Golfistas mais propensos a doenças do coração, câncer e artrite!”

Erros comuns da regressão

4. Viés da variável omitida

- “Golfistas mais propensos a doenças do coração, câncer e artrite!”
 - Idade é uma variável fundamental que afeta o surgimento de doenças, e não pode ficar de fora
- Análise de regressão não pode omitir variáveis relevantes para associação
 - idade x doenças, educação pais x educação filhos, renda x nível de violência, etc..

Erros comuns da regressão


5. Variáveis explicativas correlacionadas

- Exemplo: análise de notas no ENEM em relação ao uso de drogas
 - Se temos duas variáveis explicativas: uso de heroína e uso de cocaína, não será possível discernir entre o efeito de uma e da outra
 - As duas são correlacionadas: a chance de um usuário de cocaína ter usado heroína é alta; e vice-versa.
- Usar uma ou outra variável, ou criar uma variável composta

Erros comuns da regressão

6. Extrapolar para além dos dados

- A inferência é relativa aos dados que foram usados
- No exemplo do peso, a regressão foi feita com adultos
 - Recém-nascido: peso = -8,9Kg



Erros comuns da regressão

7. Excesso de variáveis

- Só inclua variáveis com justificativa teórica
 - Risco de encontrar uma correlação significativa simplesmente pelo acaso, com uma variável fajuta
 - E o pior, pesquisadores podem tentar justificar que essa variável fajuta faz algum sentido, depois do resultado

Regressão

- **Conclusão**

- Projetar a análise, decidindo quais variáveis devem ser examinadas e de onde devem vir os dados, é mais importante do que os cálculos estatísticos subjacentes
- Como a maior parte das inferências, a regressão constrói um caso com base nos dados utilizados

Sugestão de estudo

- Capítulos 11 e 12: Charles Wheelan
- [Playlist ZedStatistics](#)